

Data Mining Week 01 — Introduction

تنقيب عن البيانات — الأسبوع الأول: مقدمة

Comprehensive Bilingual Study Pack (English + Arabic) — FULL, Not Compressed

حزمة مراجعة شاملة ثنائية اللغة (إنكليزي + عربي) — كاملة بلا اختصار

Instructor: Asst. Prof. Dr. Ahmed Shakir Abd Al-Rida · Data Mining

الدكتور: أ.م.د. أحمد شاكر عبد الرضا — تنقيب عن البيانات

Built from vault comprehensive notes + lecture originals + Gemini frameworks + Dr. Ahmed exam layer.

WebUI MCQ platform check is NOT counted as a course exam.

مبني على الملاحظات الشاملة بالفلدر + نصوص المحاضرة + قوالب Gemini + طبقة امتحان د. أحمد.
اختبار منصة MCQ لا يُحسب امتحاناً للمادة.

For morning study · Koko · 2026-09-20

لمذاكرة الصباح — كوكو — 20-09-2026

1. Definition of Data Mining

1. تعريف التنقيب عن البيانات

The process of extracting information to identify patterns, trends, and useful data that would allow the business to take the data-driven decision from huge sets of data is called Data Mining.

In other words, is the process of investigating hidden patterns of information to various perspectives for categorization into useful data, which is collected and assembled in particular areas such as data warehouses, efficient analysis, data mining algorithm, helping decision making and other data requirement to eventually cost-cutting and generating revenue.

Is the act of automatically searching for large stores of information to find trends and patterns that go beyond simple analysis procedures.

Data mining utilizes complex mathematical algorithms for data segments and evaluates the probability of future events.

Data Mining is also called Knowledge Discovery of Data (KDD).

Data mining extracts information from huge datasets to find patterns, trends, and useful data for data-driven decisions. It automatically searches beyond simple analysis, uses complex mathematical algorithms, evaluates the probability of future events, works largely in data warehouses, and is also called KDD.

التنقيب عن البيانات يستخرج المعلومات من مجموعات بيانات ضخمة لاكتشاف أنماط واتجاهات وبيانات مفيدة تسمح بقرارات مبنية على البيانات. بحث تلقائي يتجاوز التحليل البسيط، يستخدم خوارزميات رياضية معقدة، يقيّم احتمال الأحداث المستقبلية، ويعمل غالباً في مستودعات البيانات، ويسمى أيضاً KDD.

بالعربي	Lecture text	الركيزة / Pillar
استخراج تلقائي مو يدوي	automatically searching	Automated search
خوارزميات رياضية معقدة	complex mathematical algorithms	Tool
تجزئة البيانات + تقييم احتمال المستقبل	data segments + probability of future events	Function
مستودعات البيانات	data warehouses	Place
اكتشاف المعرفة من البيانات	Knowledge Discovery of Data (KDD)	Alias

النوع/المخرج	Output	Works on	Type
استعلامات معروفة → إجابات مباشرة	Direct answers	Known queries	Simple analysis
يتجاوز التحليل البسيط → أنماط خفية + تنبؤات	Hidden patterns + predictions	Goes beyond simple analysis	Data Mining

Applications intro (slide 6)

مقدمة التطبيقات (سلايد 6)

Primarily used by organizations with intense consumer demands — Retail, Communication, Financial, Marketing — to determine price, consumer preferences, product positioning, and impact on sales, satisfaction, and profits. A retailer can use point-of-sale records to develop products and promotions that attract customers.

تستخدمه مؤسسات بشدة طلب استهلاكي — تجزئة، اتصالات، مالية، تسويق — لتحديد السعر وتفضيلات المستهلك وموقع المنتج وأثره على المبيعات والرضا والأرباح. التجزئة تستعمل سجلات نقاط البيع لتطوير منتجات وعروض تجذب الزبائن.

الكيانات/المخرجات	Outputs	Entities
تجزئة · اتصالات · مالية · تسويق	price · preferences · positioning · sales & profit	Retail · Communication · Financial · Marketing

2. Advantages — 7 points in 3 levels

2. الفوائد — 7 نقاط بـ3 مستويات

#	Original lecture advantage	النص الأصلي
1	knowledge-based data	بيانات مبنية على المعرفة
2	lucrative modifications in operation and production	تعديلات مربحة بالعمليات والإنتاج
3	cost-efficient vs other statistical applications	اقتصادي مقارنة بالتطبيقات الإحصائية
4	helps the decision-making process	يساعد عملية اتخاذ القرار
5	automated discovery of hidden patterns + prediction of trends/behaviors	اكتشاف تلقائي لأنماط خفية + تنبؤ
6	induced in new systems and existing platforms	يُدمج بالأنظمة الجديدة والقديمة
7	quick process; new users analyze huge data fast	سريع؛ حتى المستخدم الجديد يحلل ضخماً بسرعة

# Lecture	بالعربي	Gemini wording (EN)	Level
1,5	أنماط خفية وتنبؤ؛ تحويل الخام لبيانات معرفية	Hidden Patterns & Prediction; Knowledge-Based Data	Data / Discovery
2,4	دعم القرار؛ تعديلات مربحة	Decision-Making; Lucrative Modifications	Business / Decision
3,6,7	اقتصادي؛ دمج جديد/قديم؛ سريع وسهل	Cost-Efficient; System Integration; Speed & Usability	System / Feasibility

Mental anchor — advantages

مرساة الفوائد

Extract & Predict (Data) → Decide & Profit (Business) → Cheap, Integratable & Fast (Tech).

استخرج وتوقع (بيانات) → قرر واربح (عمل) → رخيص ويندمج وسريع (تقنية).

3. Disadvantages — Amex, tools, training, imprecision

3. العيوب — Amex والأدوات والتدريب وعدم الدقة

#	Original lecture point	النص الأصلي
-1 2	Organizations may sell useful customer data for money; American Express sold credit card purchases to other organizations	مؤسسات قد تباع بيانات العملاء؛ أم إكس بريس باعت مشتريات البطاقات لمنظمات خارجية
3	Analytics software difficult to operate; needs advanced training	برامج التحليلات صعبة وتحتاج تدريباً متقدماً
4	Different tools operate in distinct ways due to different algorithms — selecting the right tool is challenging	أدوات مختلفة بخوارزميات مختلفة — اختيار الأداة تحدي
5	Techniques are not precise → may lead to severe consequences	تقنيات غير دقيقة → نتائج وخيمة بظروف معينة

Level	Gemini wording	بالعربي
Privacy / Ethics	Customer Data Monetization; American Express example	بيع بيانات العملاء؛ مثال أم إكس بريس
Technical / Operational	Tool Selection Dilemma; Steep Learning Curve	معضلة اختيار الأداة؛ منحني تعلّم حاد
Reliability / Accuracy	Imprecision & Critical Consequences (probabilistic not exact)	احتمالية مو دقيقة؛ عواقب وخيمة

Exam-critical example

مثال امتحاني

Memorize: American Express + credit card purchases + sold to external organizations.

احفظ: American Express + credit card purchases + بيع لمنظمات خارجية.

Disadvantages anchor

مرساة العيوب

Selling the Data (Amex) → Selecting & Running Tools (Algorithms & Training) → Flawed Results (Imprecision).
بيع البيانات (Amex) → اختيار وتشغيل الأدوات (خوارزميات وتدريب) → نتائج معيبة (عدم الدقة).

4. Applications — 8 domains (2-keyword + full lecture)

4. التطبيقات — 8 مجالات (قاعدة الكلمتين + نص المحاضرة)

#	Domain	Core operation / keyword 1	Risk / keyword 2	بالعربي
1	Healthcare	Patient Forecasting — category triage for intensive care at right place/time	Fraud & Abuse in insurance claims	تحسين الصحة: توقع المرضى للرعاية المركزة؛ كشف احتيال التأمين
2	Market Basket	Product Associations	Purchase Behavior	فرضية سلة السوق؛ ربط المنتجات؛ إعادة تنظيم المتجر
3	Education (EDM)	Student Performance Prediction — what to teach & how to teach	Learning Behavior	تنقيب تعليمي ناشئ؛ تنبؤ أداء الطالب؛ ماذا وكيف ندرّس
4	Manufacturing	Process Patterns	Development Time & Cost	المعرفة أفضل أصل؛ أنماط التصنيع؛ توقع زمن/تكلفة التطوير
5	CRM	Acquisition & Retention	Churn / Loyalty	اكتساب والاحتفاظ بالعملاء؛ ولاء؛ استراتيجيات موجهة للزبون
6	Fraud Detection	Supervised Classification	Fraudulent vs Non-fraudulent	مليارات تضيق بالاحتيال؛ تعلّم موجّه يصنّف احتيالي/سليم
7	Lie Detection	Text Mining on unstructured text	Lie / Truth Model	تنقيب نصوص على غير مهيكّل؛ مقارنة تحقيقات سابقة؛ نموذج كشف الكذب
8	Banking & Finance	Trends, Causalities & Correlations	Customer Segmentation	بيانات ضخمة وسريعة؛ trends و causalities و correlations؛ تقسيم العملاء

1. Healthcare

تحسين الصحة

Lecture: Improve services + reduce costs; ML, multidimensional DB, visualization, soft computing, statistics

المحاضرة: تحسين الصحة؛ توقع المرضى للرعاية المركزة؛ كشف احتيال التأمين

Keywords: Patient Forecasting — category triage for intensive care at right place/time + Fraud & Abuse in insurance claims

الكلمتان: Patient Forecasting — category triage for intensive care at right place/time + Fraud & Abuse in insurance claims

2. Market Basket

فرضية سلة السوق

Lecture: Hypothesis: buy group A → more likely buy group B; understand purchase behavior; change store layout; compare stores/demographics

المحاضرة: فرضية سلة السوق؛ ربط المنتجات؛ إعادة تنظيم المتجر

Keywords: Product Associations + Purchase Behavior

الكلمتان: Product Associations + Purchase Behavior

3. Education (EDM)

تنقيب تعليمي ناشئ

Lecture: Newly emerging; explore knowledge from educational environments; affirm learning behavior; study support impact; promote learning science

المحاضرة: تنقيب تعليمي ناشئ؛ تنبؤ أداء الطالب؛ ماذا وكيف ندرّس

Keywords: Student Performance Prediction — what to teach & how to teach + Learning Behavior

الكلمات: Student Performance Prediction — what to teach & how to teach + Learning Behavior

4. Manufacturing

المعرفة أفضل أصل

Lecture: Knowledge is the best asset; find patterns in complex manufacturing; system-level design links architecture/portfolio/customer data needs; forecast development period/cost

المحاضرة: المعرفة أفضل أصل؛ أنماط التصنيع؛ توقع زمن/تكلفة التطوير

Keywords: Process Patterns + Development Time & Cost

الكلمات: Process Patterns + Development Time & Cost

5. CRM

اكتساب والاحتفاظ بالعملاء

Lecture: Obtaining and holding customers; loyalty; customer-oriented strategies; collect + analyze data

المحاضرة: اكتساب والاحتفاظ بالعملاء؛ ولاء؛ استراتيجيات موجهة للزبون

Keywords: Acquisition & Retention + Churn / Loyalty

الكلمات: Acquisition & Retention + Churn / Loyalty

6. Fraud Detection

مليارات تضيع بالاحتيال

Lecture: Billions lost to fraud; traditional methods slow; supervised sample records classified fraudulent/non-fraudulent; model checks documents

المحاضرة: مليارات تضيع بالاحتيال؛ تعلّم موجه يصنّف احتيالي/سليم

Keywords: Supervised Classification + Fraudulent vs Non-fraudulent

الكلمات: Supervised Classification + Fraudulent vs Non-fraudulent

7. Lie Detection

تنقيب نصوص على غير مهيكّل

Lecture: Hard to extract truth; law enforcement investigates offenses/terror comms; text mining on unstructured text; compare past investigations; build lie-detection model

المحاضرة: تنقيب نصوص على غير مهيكّل؛ مقارنة تحقيقات سابقة؛ نموذج كشف الكذب

Keywords: Text Mining on unstructured text + Lie / Truth Model

الكلمات: Text Mining on unstructured text + Lie / Truth Model

8. Banking & Finance

بيانات ضخمة وسريعة

Lecture: Digitalization generates huge transaction data; managers miss patterns because volume too large or produced too rapidly; mining finds trends, causalities, correlations; targeting/acquiring/retaining/segmenting profitable customers

المحاضرة: بيانات ضخمة وسريعة؛ trends و causalities و correlations؛ تقسيم العملاء

Keywords: Trends, Causalities & Correlations + Customer Segmentation

الكلمات: Trends, Causalities & Correlations + Customer Segmentation

3-Pillar + Safe answer + Fixed sentence

القالب الثلاثي + الجملة الآمنة

For each domain: Goal & Stack + Core Operation + Risk/Anomaly. Exam safe: write the two keywords + fixed sentence "Using techniques like Classification, Clustering, and Machine Learning." Marker looks for keywords, not filler.

لكل مجال: الهدف والتقنيات + العملية الأساسية + الخطر/الشذوذ. الإجابة الآمنة: الكلمتان + الجملة الثابتة «Using techniques like Classification, Clustering, and Machine Learning». المصحح يبحث عن كلمات دالة مو حشو.

عربي	Healthcare safe lines (EN)
تنبؤ أعداد المرضى لتوزيع أفضل للموارد	.Predicting patient volume for better resource allocation
كشف الاحتيال وإساءة استخدام مطالبات التأمين	.Detecting fraud and abuse in insurance claims

5. Challenges — 6 items (Nature → Root Cause → Consequence)

5. التحديات — 6 عناصر (طبيعة ← سبب ← أثر)

#	Challenge	Nature	Root cause	Consequence	بالعربي
1	Incomplete & Noisy Data	heterogeneous, incomplete, noisy; huge data inaccurate/unreliable	measuring instrument failure; human entry errors; users refuse to disclose	obstruct mining; distort pattern extraction	بيانات ناقصة/ مشوشة؛ أخطاء بشرية/ أجهزة/ رفض مشاركة؛ تشويه الأنماط
2	Data Distribution	data on various platforms/databases/internet	organizational + technical concerns; regional servers	central repo unfeasible → need distributed mining algorithms	بيانات موزعة؛ تجميع مركزي صعب → خوارزميات موزعة
3	Complex Data	multimedia, spatial, time series heterogeneous	diverse formats not standardized	traditional techniques fail → new tools/methodologies	وسائط/ مكانية/ زمنية متنوعة؛ التقنيات التقليدية تعجز
4	Performance	depends primarily on algorithm/technique efficiency	algorithm not up to the mark	adverse effect on efficiency/speed/accuracy	أداء يعتمد على كفاءة الخوارزميات؛ تصميم ضعيف يضر
5	Data Privacy & Security	issues in security, governance, privacy	analyze purchases without permission	reveals habits/preferences without consent	أمان وحوكمة وخصوصية؛ كشف عادات بدون إذن
6	Data Visualization	primary way to show output to user; hard to present complex I/O precisely/easily	complicated inputs and outputs	need efficient successful visualization → decision-ready	عرض النتائج للمستخدم؛ مدخلات/ مخرجات معقدة تحتاج تمثيلاً متقدماً

Store \$500 phone story (lecture)

قصة المتجر و500 دولار (المحاضرة)

Retail chain collects phones of customers spending >\$500; employee may mistype a digit (noisy/incomplete); customers may refuse to disclose (incomplete). All these make data mining challenging.

سلسلة تجزئة تجمع هواتف من يصرف <\$500؛ الموظف يمكن يغلط برقم (ضوضاء/ نقص)؛ العميل يمكن يرفض المشاركة (نقص). كل هذا يجعل التنقيب صعباً.

Outlier rule (from W02 lecture material, linked)

قاعدة القيمة الشاذة (مرتبطة بـ W02)

An outlier is not necessarily an error — e.g. high blood pressure may be a real medical condition. Investigate before removing.

القيمة الشاذة ليست بالضرورة خطأ — مثل ضغط دم مرتفع قد يكون حالة حقيقية. تحقق قبل الحذف.

Challenges anchor

مرساة التحديات

Data itself (noisy → distributed → complex) → Algorithm (performance) → Output (privacy → visualization).

البيانات نفسها (مشوشة → موزعة → معقدة) → الخوارزمية (أداء) → المخرج (خصوصية → تمثيل).

6. Exam quick sheet — Week 01

6. ورقة الامتحان السريعة — الأسبوع الأول

لازم تحفظ	Must know	Topic
تعريف كامل + KDD + خوارزميات warehouses +	extract info · huge data · patterns · beyond simple analysis · KDD · algorithms · warehouses · future-event probability	Definition
3 مستويات + المرساة	levels + anchor Extract&Predict → Decide&Profit → Cheap/Integratable/Fast 3	Advantages
Amex + أدوات + تدريب + عدم دقة	Amex credit cards · tool selection · training · probabilistic not exact	Disadvantages
8 مجالات × كلمتان + الجملة الثابتة	domains × 2 keywords + fixed techniques sentence 8	Applications
6 تحديات بثلاثة عناصر + قصة المتجر	\$500 store story + (Nature → Cause → Effect) × 6	Challenges
تعريفات دقيقة بلا حشو؛ معادلة إذا به أرقام	Han-style precise definitions; no filler; formulas if numbers appear	Doctor style

Coverage check (builder self-audit)

فحص التغطية (تحقق ذاتي)

- W1: Definition + KDD + warehouses + beyond simple analysis + applications intro entities — YES
- W1: 7 advantages + 3 Gemini levels + anchor — YES
- W1: Disadvantages including American Express + tools + training + imprecision + anchor — YES
- W1: 8 applications with 2-keyword + lecture detail + safe sentences — YES
- W1: 6 challenges Nature/Cause/Effect + \$500 story + outlier rule — YES
- W2: Object vs attribute — YES
- W2: Nominal/Ordinal/Binary/Numerical + decision template + URL=Nominal — YES
- W2: Interval/Ratio + Min-Max/Z-score/decimal + worked 0.5 — YES
- W2: 8 structures + separation rule + anchor — YES
- W2: Prep definition + dirty data + pipeline + not-only-missing — YES
- W2: Cleaning 6 missing + noise/binning + outlier≠error + duplicates + inconsistency — YES
- W2: Integration/Transformation/Reduction/Discretization + Selection vs Extraction + medical walkthrough — YES
- W2: Prep vs Preprocess + exam quick tables — YES

التحقق: الأقسام أعلاه موجودة كاملة في الملفين — بلا ضغط ولا حذف جوهري للمادة.