

وثيقة المراجعة والتلخيص الأكاديمي

Introduction to Data Mining

Week 01 - Introduction to Data Mining.pptx :**Sources** Asst. Prof. Dr. Ahmed Shakir Abd Al-Rida :**Instructor**

developed in the student's own smart-memorisation framework + (slides 25)

التنقيب عن البيانات. pdf :**Purpose** exam- keeps the the lecture text is long and unclear. This note .and drops the padding **relevant skeleton**

⚡ كيف تقرأ هذي الملاحظة

المحاضرة طويلة وملغطة — بس الحقيقة إنها 4 أقسام بس، وكل قسم عنده قالب ثابت، إذا حفظت القوالب، تقدر تعيد بناء أي جواب بالامتحان بدون ما تحفظ النصوص.

القسم	القالب	عدد العناصر
1. الفوائد	3 مستويات (Tech → Business → Data)	7 نقاط
2. العيوب	3 مستويات (Accuracy → Tools → Privacy)	4 نقاط
3. التطبيقات	8 مجالات × قاعدة الكلمتين	8 مجالات
4. التحديات	صيغة العناصر الثلاثة	6 تحديات

1 شنو هو التنقيب عن البيانات؟

التعريف: عملية استخراج معلومات لتحديد أنماط واتجاهات وبيانات مفيدة من مجموعات بيانات ضخمة، حتى تاخذ المنظمة قرارات مبنية على البيانات.

نقاط مفتاحية (احفظ هذي الأربعة):

النقطة	التفصيل
اسم آخر	KDD = Knowledge Discovery of Data
الأداة	خوارزميات رياضية معقدة (complex mathematical algorithms)
الوظيفة	تجزئة البيانات + تقييم احتمال الأحداث المستقبلية
المكان	مستودعات البيانات (data warehouses)

🎯 الخلاصة بجملة: "بحث تلقائي عن أنماط تتجاوز التحليل البسيط."

2 الفوائد (Advantages) — قالب المستويات الثلاثة

المحاضرة تسرد 7 فوائد مبعثرة. لكنها مو سبعة — هي ثلاثة مستويات، وكل مستوى بيّه 2-3 نقاط:

A المستوى الأول: الاكتشاف والتحليل (مستوى البيانات — *The Data Level*)

#	الفائدة
1	اكتشاف تلقائي للأنماط الخفية + التنبؤ بالاتجاهات والسلوكيات المستقبلية
2	تحويل المعلومات الخام → بيانات مبنية على المعرفة (knowledge-based data) قابلة للتنفيذ

B المستوى الثاني: التأثير على العمل (مستوى القرار — *The Decision Level*)

#	الفائدة
3	يدعم ويوجّه عملية اتخاذ القرار بالمؤسسة
4	يحقق تعديلات مربحة (lucrative modifications) بالعمليات الأساسية وخطوط الإنتاج

C المستوى الثالث: الجدوى العملية (مستوى النظام — *The System Level*)

#	الفائدة
5	اقتصادي (cost-efficient) — مقارنة بباقي تطبيقات الإحصاء
6	قابل للدمج بالأنظمة الجديدة و القديمة (legacy platforms)
7	سريع — حتى المستخدم الجديد يقدر يحلل كميات ضخمة بوقت قصير

مرساة الحفظ (Mental Anchor)

من الأرض للأعلى: Predict & Extract (بيانات) → Profit & Decide (عمل) → Cheap, Fast & Integratable (تقنية)

يعني: جمع وتوقع → قرار وإيرج → رخيص وسريع ويندمج.

3 العيوب (Disadvantages) — قالب المستويات الثلاثة

المحاضرة تسرد 4 عيوب. وهي همين ثلاثة مستويات:

A الخصوصية والأخلاقيات (مخاطر إساءة استخدام البيانات)

#	العيوب
1	المؤسسات تبيع بيانات العملاء لمنظمات ثانية مقابل فلوس
	 المثال بالمنهج: American Express باعت سجل مشتريات بطاقات عملائها لمنظمات خارجية

🔑 التعقيد التقني والتشغيلي (فجوة الاستخدام)

#	العيب
2	معضلة اختيار الأداة — الأدوات تختلف باختلاف الخوارزميات المستخدمة بتصميمها، فاختيار الأداة الصّحّ تحدّي صعب
3	منحنى تعلّم حاد (steep learning curve) — أغلب البرامج صعبة التشغيل وتحتاج تدريب متقدّم

🎯 الموثوقية والأثر الواقعي (دقة المخرجات)

#	العيب
4	التقنيات احتمالية مو دقيقة (not precise) — وهذا يمكن يؤدي ل نتائج كارثية بظروف معينة

🧠 مرساة الحفظ (Mental Anchor)

من الجمع للتنفيذ: (Amex) Selling the Data → Running Tools & Selecting (خوارزميات وتدريب) → Flawed Results (عدم دقة)

يعني: يبيعون بياناتك → الأدوات صعبة وتحتاج تدريب → والنتيجة مو مضمونة.

🎯 4 التطبيقات (Applications) — قاعدة الكلمتين

⚠️ المشكلة: أسئلة التطبيقات بالمناهج مليانة حشو مكرر. كل مجال تقريباً "يقلّل التكلفة، يحسّن الأداء، ويستخدم ML و Statistics". لو حفظتها كنصوص سردية، راح تخلط بين المجالات بعد الثالث.

🔑 القاعدة: كل مجال = كلمتين فقط

1. العملية الأساسية (Core Operation): شي يُصنّف أو يتوقّع
2. الخطر/الشذوذ (Risk/Anomaly): احتيال أو تسرّب أو خسارة يُمنع

📊 مصفوفة المجالات الثمانية — احفظ الجدول، مو النصوص

المجال	🎯 العملية الأساسية	⚠️ الخطر / الشذوذ	🔑 الفارق الجوهرى
🏥 Healthcare	Patient Forecasting — تصنيف وتوقع أعداد المرضى	Abuse & Fraud بمطالبات التأمين الصحي	المكوّنات: مريض + مطالبة تأمين
🛒 Market Basket	Product Associations — شراء مجموعة يزيد احتمال شراء ثانية	Purchase Behavior — سلوك الشراء	يعيد تخطيط شكل المتجر
🎓 Education (EDM)	Student Performance Prediction — التنبؤ بأداء ونتائج الطالب	Learning Behavior — سلوك التعلّم	يحدّد ماذا ندرّس وكيف
🏭 Manufacturing	Process Patterns — أنماط بعمليات التصنيع المعقّدة	Cost & Development Time — توقعات التطوير	المعرفة = الأصل الأهم

المجال	العملية الأساسية 🎯	الخطر / الشذوذ ⚠️	الفارق الجوهرى 🔑
CRM 🧡	Retention & Customer Acquisition — اكتساب والاحتفاظ	Churn / Loyalty — الولاء	استراتيجيات موجهة للزبون
Fraud Detection 🚨	Supervised Classification — تصنيف سجل/وثيقة: احتيالي أو سليم	Fraudulent vs Non-fraudulent	حماية بيانات المستخدمين
Lie Detection 🔍	Text Mining — أنماط بداخل نص غير مهيكّل	Lie / Truth Model — نموذج كشف الكذب	يقارن سجلات تحقيقات سابقة
Banking & Finance 🏦	Correlations & Causalities , Trends — أنماط بالمعاملات الضخمة	Customer Segmentation — تقسيم العملاء	البيانات ضخمة وسريعة تتجاوز التحليل اليدوي

نقطة الأمان بالامتحان (The Safe Answer) 🛡️

المصحح ما يقرأ الديباجات الإنشائية مثل "has excellent potential to improve". يدور على كلمات دالة (keywords). فاكتب:

جملة ثابتة تنطبق على الـ 8 كلها: "and Machine Learning ,Clustering ,Using techniques like Classification".

وبعدها سطرين لكل مجال: - "Detecting fraud and" + ".allocation Predicting patient volume for better resource" 🏥 - "abuse in insurance claims" - ".decisions Predicting student performance to guide curriculum" 🎓 - "Analyzing" - ".segmentation and retention transaction trends for customer

وبس. كلمتين لكل مجال = الدرجة الكاملة.

التقنيات المشتركة (Stack) — تذكرها مرة وحدة 🌱

ML · Statistics · Multidimensional Databases · Data Visualization · Soft Computing

(هذي تنطبق على كل المجالات تقريباً — فاحفظها مرة، واستعملها بأي جواب.)

5 التحديات (Challenges) — صيغة العناصر الثلاثة ⚠️

المشكلة: التحديات تضيق بـ"القصص والأمثلة الواقعية" (مثل الموظف اللي يغلط برقم الهاتف). الحل: كل تحدٍ = 3 عناصر ثابتة: 1. الطبيعة (Nature) — شئ العيب التقني؟ 2. السبب الجذري (Root Cause) — منين جاء؟ 3. الأثر (Consequence) — شلون يآثر على الدقة؟

#	التحدي	الطبيعة	السبب الجذري	الأثر
1	Incomplete & Noisy Data بيانات ناقصة ومشوشة	البيانات الواقعية غير متجانسة · ناقصة · مشوشة	فشل أدوات القياس · أخطاء إدخال بشرية · رفض المستخدم مشاركة بياناته	مجموعات البيانات الضخمة تصير غير دقيقة وغير موثوقة → تشوّه استخراج الأنماط
2	Data Distribution توزّع البيانات	البيانات موزّعة على منصات وقواعد بيانات متعددة والإنترنت	قيود تقنية + عوائق تنظيمية (كل فرع عنده سيرفره)	تجميعها مركزي غير ممكن → نحتاج خوارزميات تنقيب موزّعة

#	التحدي	الطبيعة	السبب الجذري	الأثر
3	Complex Data بيانات معقدة	بيانات غير متجانسة: وسائط متعددة (صوت/فيديو/صور) · مكانية · سلاسل زمنية	تنوع التنسيقات وعدم توحيدها	التقنيات التقليدية تعجز → نحتاج أدوات ومنهجيات جديدة
4	Performance الأداء	أداء المنظومة يعتمد أساساً على كفاءة الخوارزميات	تصميم خوارزمية ضعيف أو غير محسّن	تراجع حاد بالسرعة والدقة والكفاءة
5	Data Privacy & Security الخصوصية والأمن	ثغرات حرجية بالخصوصية وأمن النظام والحوكمة	تحليل مشتريات العملاء بدون إذن مسبق	كشف عادات وتفضيلات حساسة للمستهلكين
6	Data Visualization تمثيل البيانات	تمثيل المدخلات والمخرجات المعقدة ببساطة وبدون تشويه صعب جداً	تعقيد المدخلات والمخرجات	يحتاج آليات تمثيل بصري متقدمة حتى تكون النتائج جاهزة للقرار

🧠 مرساة الحفظ للتحديات: رتّبها بعقلك بهذا التسلسل:

البيانات نفسها (ناقصة → موزّعة → معقدة) → الخوارزمية (أداء) → النتيجة (خصوصية → تمثيل)

يعني: من المشكلة بالبيانات → للمشكلة بالحل → للمشكلة بالمخرجات.

📋 خلاصة قبل الامتحان

الأولوية	شئو تحفظ بالضبط	القسم
●	استخراج أنماط من بيانات ضخمة · KDD · خوارزميات رياضية	تعريف
●	3 مستويات (Tech → Business → Data) + المرساة	الفوائد
●	3 مستويات (Accuracy → Tools → Privacy) + مثال American Express	العيوب
●●	قاعدة الكلمتين لكل مجال + الجملة الثابتة	التطبيقات
●	صيغة العناصر الثلاثة × 6 تحديات	التحديات
●	ML · Statistics · Multidimensional DB · Visualization · Soft Computing	التقنيات المشتركة

🎯 استراتيجية الإجابة

لو جاء سؤال **"[X] Data mining in"**: 1. اكتب العملية الأساسية للقطاع (سطر واحد) 2. اكتب الخطر/الشذوذ للقطاع (سطر واحد) 3. أضف الجملة الثابتة عن التقنيات 4. وبس — لا تحشي

لو جاء سؤال **"Challenges of Data Mining"**: 1. عدّ الستة بأسمائها 2. لأي واحد تريد توسّع، استعمل الطبيعة → السبب → الأثر

بني 18-09-2026 بواسطة Koko، من سلايدات د. أحمد شاكر (25 سلايد) + إطار الحفظ الذكي اللي طوّره أبو الحسن مع Gemini.