

وثيقة المراجعة والتلخيص الأكاديمي

ملاحظة مهمة قبل تبدأ: الدكتور ما يعلم — هو يوزع بحث. كل كلمة أو مصطلح على الشريحة = "زر بحث" لازم تفتحه وتعرفه بعمق (شنو هو / شلون يشتغل / كيف يرتبط بالمحاضرة). هالوثيقة هي "البحث" نفسه. كل قسم فيه بطاقة بحث تحتها ثلاثة خطوط: **شنو هو**, **شلون يشتغل** (مع مثال صغير)، وارتباطه بالمحاضرة. اقراها كأنك باحث، مو كأنك طالب يحفظ.

القسم 1 — التصنيف الكبير: عائلتان من البيانات

قبل أي شي، الدكتور ي divide البيانات لـ عائلتين (هذا أساس كل المحاضرة، وغالباً يسأل عنه):

العائلة	المعنى الحرفي	شلون نعرفها؟
Nondependency-Oriented (غير معتمدة على بعض)	القيم مستقلة، كل سجل وحده ما يعتمد على الثاني	جدول مرضى: العمر والضغط والكوليسترول — كل مريض رقمه بحد نفسه
Dependency-Oriented (معتمدة على بعض)	القيم بينها علاقة / ترتيب / وقت / بنية	سعر السهم عبر الأيام — اليوم يعتمد على الأمس


حفظ سريع: Nondependency = "كل واحد بحده". Dependency = "بينهم خيوط" (وقت، ترتيب، أو بنية شبكية).

القسم 2 — العائلة الأولى: Nondependency-Oriented (4 أنواع)

2.1 Quantitative Multidimensional Data (بيانات كمية متعددة الأبعاد)

التعريف: بيانات تتمثل بأكثر من سمة رقمية (vector). مثال الدكتور: مجموعة طبية فيها Age, Blood Pressure, Cholesterol, BMI. **الخصائص:** قيم مستمرة (أرقام حقيقية)، تتمثل على شكل متجه (vector)، استخداماتها: Regression, anomaly detection, clustering.

Quantitative Multidimensional — numeric vector



Age=25, BP=80, Chol=190, BMI=22 → [25,80,190,22]

شكل: بيانات كمية متعددة الأبعاد — كل سجل = متجه أرقام

جدول بيانات حقيقي (مجموعة طبية — كل صف متجه أرقام):

Patient	Age	Blood Pressure	Cholesterol	BMI
P1	25	120	190	22.1
P2	41	135	210	26.4
P3	33	118	175	23.0
P4	58	150	240	29.8

كل صف = نقطة بـ 4 أبعاد، مثلاً $P1 = [25, 120, 190, 22.1]$.

بطاقة بحث: Regression (الانحدار)

- **شئو هو:** عائلة من النماذج تحاول تتنبأ بقيمة رقمية مستمرة من مدخلات. الفرق الجوهرى عن التصنيف (classification): التصنيف يجاوب "نعم/لا" أو "فئة"، الانحدار يجاوب "كم؟" (سعر، عمر، ضغط).
- **شئون يشتغل (مثال):** لو عندك أعمار وضغط لمرضى، تبني خط $BP \approx a \cdot Age + b$. تعطيه عمر جديد فيتوقع الضغط. أبسط نوع = Linear Regression (أقل مربعات). أنواع ثانية: Lasso, Ridge, Polynomial.
- **ارتباطه بالمحاضرة:** هذا النوع (Quantitative Multidimensional) هو "الوقود" الطبيعى للانحدار لأنه أرقام متجهة. لهذا الدكتور خليه ضمن الـ use cases.

بطاقة بحث: Clustering (التجميع)

- **شئو هو:** تقسيم البيانات لـ groups بحيث اللي داخل المجموعة الوحدة يكونون متشابهين، وكل مجموعة تختلف عن الثانية — بدون ما نعرف مقدماً أسماء المجموعات (unsupervised).
- **شئون يشتغل (مثال):** K-Means: تختار K مركز عشوائى، توزع كل نقطة لأقرب مركز، تحسب مراكز جديدة، تكرر لحد يستقر. النتيجة: عناقيد.

- ارتباطه بالمحاضرة: ينطبق على البيانات الكمية لأننا نحتاج "مسافة" بين النقاط (Euclidean distance) — وهذا متوفر بس لما البيانات رقمية متجهة.

بطاقة بحث: Anomaly Detection (كشف الشذوذ)

- شئو هو: اكتشاف النقاط اللي "ما تطابق" باقي البيانات — اللي هي نادرة أو غريبة (تسمى outliers أو anomalies).
- شلون يشتغل (مثال): قيمة ضغط = 300 تعتبر شذوذ لأنها بعيدة جداً عن توزيع باقي المرضى. طرق: statistical (z-score)، أو clustering (نقطة ما انتمت لأي عنقود)، أو Isolation Forest.
- ارتباطه بالمحاضرة: يظهر مرتين بالمحاضرة (هنا، وفي Time-Series) لأن الشذوذ يهم بكل أنواع البيانات — طبي (مرض)، مالي (احتيال)، حساس للوقت (إنذار مبكر).

2.2 Categorical and Mixed Attribute Data (بيانات تصنيفية ومختلطة)

التعريف: Categorical = سمات تمثل تصنيفات منفصلة (Red/Green/Blue، أو Kenya/India/USA). Mixed = تجمع رقمي + تصنيفي (مثال: {Age=21، Gender=Male، GPA=3.4، Major=CS}). **التحدي:** نحتاج تقنيات ترميز خاصة (مثل one-hot، وقياس المسافة أصعب من الرقمي).

Categorical & Mixed — labels + numbers

Red

Green

Blue

Mixed record:

Age = 21 (numeric)

GPA = 3.4 (numeric)

Gender = Male (category)

Major = CS (category)

شكل: بيانات تصنيفية ومختلطة — فئات + أرقام

جدول بيانات حقيقي (سجلات طلاب — مختلطة رقمي + تصنيفي):

Student	Age	Gender	GPA	Major
S1	21	Male	3.4	CS
S2	22	Female	3.1	Math
S3	20	Male	2.9	CS
S4	23	Female	3.7	Physics

العمود Gender و Major تصنيفي (nominal)؛ الباقي رقمي. هذا بالضبط اللي يحتاج one-hot.

بطاقة بحث: One-Hot Encoding (الترميز الساخن الواحد)

- **شنو هو:** لكل فئة نسوي عمود ثنائي (0/1). اللون {Green,Blue,Red} يصير 3 أعمدة: $[1,0,0]=\text{Red}$, $[0,1,0]=\text{Blue}$, $[0,0,1]=\text{Green}$.
- **شلون يشتغل:** المريض P1 بفصيلة A يصير $[1,0,0]$, P2 بفصيلة B يصير $[0,1,0]$. الـ 1 يعني "هذا الفئة موجود"، الـ 0 "غائب".
- **ليش ما نكتب $A=1, B=2, O=3$ ؟** لأن هذا يوهم النموذج إنه فيه ترتيب عددي (B أكبر من A؟ ما منطق). فصائل الدم nominal ما بينها ترتيب، ف one-hot هو الصح للـ nominal.
- **ارتباطه بالمحاضرة:** هذا هو الحل لمشكلة "الخوارزميات تريد أرقام" مع البيانات التصنيفية. تذكره دائماً كجسر Numeric → Categorical (راجع نشوفه بالقسم 6).

بطاقة بحث: Distance Metrics for Categorical (قياس المسافة للتصنيفي)

- **شنو هو:** كيف "نقيس تقارب" سجلين فيهم حقول تصنيفية. بالرقمي نستخدم Euclidean، بالتصنيفي نستخدم مثلاً Hamming distance (عدد الحقول المختلفة) أو Jaccard.
- **شلون يشتغل:** سجلان {CS, Male} و {Math, Male} — يختلفون بـ حقل واحد من 2 → مسافة 0.5.
- **ارتباطه بالمحاضرة:** الدكتور ذكر إن "المسافة أصعب تعريفها" للتصنيفي — لأن مفهوم "البعد" ما ينطبق مباشرة، ف لازم نحول أو نستخدم مقاييس بديلة.

2.3 Binary and Set Data (بيانات ثنائية وبيانات مجموعات)

التعريف: Binary = قيمتين بس {0,1} أو {False,True} (مثال: Smoker نعم/لا، Loan Defaulted نعم/لا). Set = كل غرض يوصف بـ مجموعة عناصر (مثال: سلة تسوق {Eggs, Bread, Milk}). **التطبيقات:** Association rule mining, recommender systems.

Binary & Set — 0/1 matrix + item set

Smoker	Loan	Fraud
1	0	0
0	1	1
1	0	1
0	0	0

Market Basket

- Milk
- Bread
- Eggs

شكل: بيانات ثنائية (مصفوفة 0/1) وبيانات مجموعات (سلة)

جدول بيانات حقيقي (مصفوفة شرائية — كل صف binary set):

Customer	Milk	Bread	Eggs	Cheese
C1	1	1	1	0

Customer	Milk	Bread	Eggs	Cheese
C2	0	1	0	1
C3	1	0	1	0
C4	0	0	0	0

سلة C1 = {Eggs ,Bread ,Milk}. خوارزمية Apriori تبحث الأنماط بين هالسلات.

بطاقة بحث: Association Rule Mining / Market Basket Analysis (تنقيب القواعد الارتباطية / تحليل سلة التسوق)

- **شنو هو:** اكتشاف قواعد من نوع "إذا اشترى X فغالباً يشتري Y" من بيانات المعاملات. أشهر مثال: "حفاضات ← بيرة" (أسطورة Walmart).
- **شلون يشتغل:** خوارزمية Apriori: تعدّ تكرار العناصر المفردة، ثم الأزواج، ثم الثلاثيات، وتصفية بالـ support (نسبة الظهور) و الـ confidence (احتمال Y إذا ظهر X) و الـ lift.
- **ارتباطه بالمحاضرة:** بيانات الـ Set (السلة) هي الوقود الطبيعي لها — كل سلة = set، ونبحث الأنماط بين السلات.


بطاقة بحث: Recommendation Systems (أنظمة التوصية)

- **شنو هو:** نظام يقترح عناصر (فيلم، منتج) بناءً على سلوك المستخدم. نوعان رئيسيان: collaborative filtering (بناءً على مستخدمين مشابهين) و content-based (بناءً على خصائص العنصر).
- **ارتباطه بالمحاضرة:** يذكره الدكتور لأنه يأكل بيانات ثنائية/مجموعات (user-item matrix مليون 0/1 = شاف/ما شاف).

2.4 Text Data (بيانات نصية) — ★ أهم نوع عند الدكتور

التعريف: بيانات مخزنة كمعلومات نصية غير مهيكلة (tweets , reviews , articles , emails). **التحدي:** النص غير مهيكل ولا بد نحوله لأرقام (word embeddings , TF-IDF , Bag of Words). **التطبيقات:** Sentiment analysis , topic modeling , chatbots , search engines.

Text — unstructured → numeric vector



← تحويل لأرقام </>
شكل: نص غير مهيكّل ← تحويل لأرقام

جدول بيانات حقيقي (مستندات + تمثيلها):

Doc	Text (raw)	Bag-of-Words vector (cat, dog, mat, log, sat, the, on)
D1	"The cat sat on the mat"	[1, 0, 1, 0, 1, 2, 1]
D2	"The dog sat on the log"	[0, 1, 0, 1, 1, 2, 1]

النص الخام ما يقرّاه النموذج — نحوله لأرقام (BoW/TF-IDF) أولاً.

بطاقة بحث: Bag of Words (BoW) — حقيبة الكلمات

- **شنو هو:** تمثيل النص كـ vector من عدد مرات كل كلمة. نسوي "قاموس" (vocabulary) لكل الكلمات الفريدة، وكل جملة تصير متجه أطواله = حجم القاموس.
- **شلون يشتغل (مثال):**
- ج1: "The cat sat on the mat" — ج2: "The dog sat on the log"
- القاموس: [on, the, sat, log, mat, dog, cat]
- ج1 → [1, 0, 1, 0, 1, 2, 1] (the ظهر مرتين)
- ج2 → [0, 1, 0, 1, 1, 2, 1]
- **المشكلة:** يتجاهل ترتيب الكلمات ومعناها (cat و dog يهمشون بنفس البعد). وهذا يؤدي لـ **sparsity** (أغلب الخانات صفر).

بطاقة بحث: TF-IDF (Inverse Document Frequency – Term Frequency) — ★★ اللي سألت عنه

- **شنو هو:** وزن إحصائي لكل كلمة داخل مستند ضمن مجموعة مستندات (corpus). يكافئ الكلمات المهمة بوزن عالي، والكلمات الشائعة (مثل "is", "the") بوزن منخفض. هو تطوير على BoW يحل مشكلة الكلمات التافهة.
- **شلون يشتغل (المعادلة والخطوات):**

- $TF(t, d) = \text{عدد مرات الكلمة } t \text{ بالمستند } d \div \text{مجموع كلمات } d$.
- $IDF(t) = \log\left(\frac{N}{1 + df(t)}\right)$ حيث $N = \text{عدد المستندات}$, $df(t) = \text{عدد المستندات التي تحتوي } t$.
- $TF-IDF(t, d) = TF(t, d) \times IDF(t)$.
- **مثال:** مستندان — د1 "the cat sat"، د2 "the dog ran". كلمة "the" بكليهما $\rightarrow IDF = \log(2/3)$ ، $df=2, N=2 \rightarrow IDF = \log(2/2)=0$ بس بد1 لا، بالصيغة ب $1+$ سلبى صغير $\rightarrow$ وزن "the" ضعيف. كلمة "cat" بس بد1 $\rightarrow IDF = \log(2/2)=0$ ، بالصيغة ب $1+$ بالمقام تطلع موجبة ومرتفعة $\rightarrow$ "cat" تاخذ وزن عالي لأنها نادرة ومميزة.
- **ليش أحسن من BoW:** يقلل تأثير الكلمات المتكررة لكن غير المفيدة. "cancer" بورقة طبية أهم من "the" رغم إن "the" أكثر عدداً.
- **ارتباطه بالمحاضرة:** هذا هو الجسر الأساسي **Text** $\rightarrow$ **Numeric** اللي الدكتور يذكره دائماً. أي خوارزمية ML تريد أرقام، و IDF-TF يحول النص لأرقام مع الاحتفاظ بأهمية الكلمة.

بطاقة بحث: Word Embeddings (تضمين الكلمات — Word2Vec, GloVe, FastText)

- **شنو هو:** تمثيل كل كلمة كـ vector كثيف (dense) بأبعاد قليلة (مثل 100–300)، بحيث الكلمات القريبة بالمعنى يكون لها vectors قريبة بالفضاء.
- **شلون يشتغل (مثال الخرافة المعروفة):** queen $\approx$ woman + man – king. النموذج التقط العلاقة الدلالية.
- Word2Vec يتعلم من السياق (الكلمات اللي تطلع جنب بعض)، GloVe من مصفوفة التشارك الإحصائي.
- **ارتباطه بالمحاضرة:** بديل أعمق من BoW/TF-IDF لأنه يفهم المعنى والسياق، يستخدم بـ chatbots والترجمة.

بطاقة بحث: Sentiment Analysis (تحليل المشاعر)

- **شنو هو:** تصنيف النص حسب المشاعر (إيجابي/سلبى/محايد). تطبيق كلاسيكي: مراجعات الأفلام.
- **شلون يشتغل:** نحول المراجعة إلى TF-IDF أو embeddings $\rightarrow$ نممرها لنموذج (Bayes Naïve أو BERT) $\rightarrow$ يصنفها.
- **ارتباطه بالمحاضرة:** من تطبيقات Text $\rightarrow$ Numeric؛ الدكتور يذكره كدليل عملي إن تحويل النص لأرقام يقود لمهام حقيقية.

بطاقة بحث: Topic Modeling (نمذجة المواضيع)

- **شنو هو:** اكتشاف "مواضيع مخفية" داخل مجموعة وثائق (مثال: أخبار مقسمة لرياضة/سياسة/اقتصاد بدون تسمية مسبقة). أشهر خوارزمية: LDA (Latent Dirichlet Allocation).
- **ارتباطه بالمحاضرة:** تطبيق نصي يعتمد على التمثيل الرقمي للوثائق.

بطاقة بحث: Search Engines & Chatbots


- **Chatbots:** نظام يفهم ويرد على النص. يعتمد على embeddings/transformers (BERT/GPT) لتحويل سؤال المستخدم لنص "قابل للمعالجة".
- **Search Engines:** تحول استعلامك والصفحات لأرقام (sentence embeddings) وتقرن التشابه. الدكتور يذكرها لأنها أضخم تطبيق عملي لـ Text $\rightarrow$ Numeric.

القسم 3 — العائلة الثانية: Dependency-Oriented (4 أنواع)

3.1 Time-Series Data (بيانات سلاسل زمنية)

التعريف: سلسلة قيم مسجلة عبر الزمن (أسعار أسهم، طقس، إشارات ECG). **الخصائص:** اعتماد زمني (الماضي يؤثر بالمستقبل).
تُحلل بـ ARIMA, LSTMs, Transformers. **التطبيقات:** Forecasting, anomaly detection.

Time-Series — values across time



example: stock price / ECG signal / temperature

شكل: سلسلة زمنية — قيم عبر الزمن

جدول بيانات حقيقي (سعر سهم عبر 8 أيام):

Day	1	2	3	4	5	6	7	8
Price	100	102	99	105	103	107	110	108

الترتيب مهم: 100→102→99 له معنى، ما يصير نعيد ترتيبه عشوائي.

بطاقة بحث: ARIMA / LSTM / Transformers

- **ARIMA** (AutoRegressive Integrated Moving Average): نموذج إحصائي كلاسيكي للتنبؤ يعتمد على القيم السابقة والفروق بينها.
- **LSTM** (Long Short-Term Memory): نوع من الشبكات العصبية المتكررة (RNN) "يتذكر" السياق الطويل — ممتاز للسلاسل الزمنية.
- **Transformers** (مثل BERT/GPT لكن للزمن): أحدث نماذج، تلتقط الاعتماديات بعيدة المدى.
- **ارتباطه بالمحاضرة:** الدكتور يذكرها لأن Time-Series تحتاج نماذج "تفهم الترتيب" — عكس الـ Quantitative اللي كل صف وحده.

3.2 Discrete Sequences and Strings (سلاسل رموز منفصلة)

التعريف: تسلسل رموز منفصلة (DNA: ATCG, clickstreams: سلسلة صفحات). **التحدي:** alignment, pattern matching.
تحليل الأنظمة الفرعية. **التطبيقات:** Bioinformatics, web usage mining, NLP.

Discrete Sequence — ordered symbols



شكل: سلسلة رموز منفصلة — ترتيب مهم

جدول بيانات حقيقي (سلاسل منفصلة):

ID	Type	Sequence
S1	DNA	A → T → C → G → A → C → G
S2	Clickstream	Home → Search → Product → Cart
S3	DNA	A → T → G → G → A → C → T

تبدیل رمز واحد یغیر المعنى (مثل الطفرة بالـ DNA) — لذلك الترتیب أساسی.

بطاقة بحث: Pattern Matching / Alignment (مطابقة الأنماط / المحاذاة)

- **شنو هو:** إيجاد تشابه بين تسلسلين (مثل محاذاة تسلسلين DNA لاكتشاف طفرة). أدوات: Wunsch–Needleman, BLAST.
- **ارتباطه بالمحاضرة:** التحدي هنا هو "المسافة" بس، بل "الترتيب مهم" — فلازم خوارزميات تسلسل لا خوارزميات جدول.

Spatial Data 3.3 (بيانات مكانية)

التعريف: بيانات بسياق جغرافي/مكاني (خرائط، صور أقمار، إحداثيات lat/long). **التحدي:** Spatial autocorrelation (الأشياء القريبة مكانياً أكثر ارتباطاً). **التطبيقات:** GIS، مراقبة المرور، النمذجة البيئية.

Spatial — coordinates on a grid



lat/long
32.50, 45.82

شكل: بيانات مكانية — إحداثيات على شبكة

جدول بيانات حقيقي (مواقع مستشفيات — lat/long):

Hospital	Latitude	Longitude	Type
H1	32.50	45.82	General
H2	32.48	45.85	Children
H3	32.55	45.79	Cardiac
H4	32.46	45.90	General

نحسب "المسافة" بينها بالإحداثيات — أقرب مستشفى = الأهم للتحليل المكاني.

بطاقة بحث: Spatial Autocorrelation (الارتباط الذاتي المكاني)

- **شنو هو:** مبدأ "القريب من القريب أقرب" — مدينة تشبه جيرانها أكثر من مدينة بعيدة. يقاس بـ Moran's I.
- **ارتباطه بالمحاضرة:** هذا يكسر فرضية "كل سجل وحده" (independence) وبالتالي يصنفها الدكتور Dependency.

3.4 Network and Graph Data (شبكات ورسوم بيانية) — ★★ مهم جداً ومرتب بنقطة توقفك

التعريف: بيانات ممثلة بـ nodes (عقد) و edges (روابط). مثال: Facebook (المستخدمون = nodes، الصداقة = edges)، شبكات الاقتباس. **الخصائص:** بيانات "بنية قوية"، تتطلب خوارزميات رسوم (PageRank, community detection, GNN). **التطبيقات:** تحليل التواصل الاجتماعي، كشف الاحتيال، recommender systems.


Network & Graph — nodes + edges

nodes =

objects

edges =

links



شكل: شبكة/رسم بياني — عقد + روابط

جدول بيانات حقيقي (شبكة تواصل — قائمة روابط):

Edge	From (node)	To (node)	Relation
e1	Ahmed	Sara	friend
e2	Sara	Omar	friend
e3	Omar	Ahmed	friend
e4	Lina	Omar	colleague

الجدول يحتوي عقد (From/To) وروابط — هذا تمثيل "edge list" لـ graph.

بطاقة بحث: PageRank

- **شئو هو:** خوارزمية جوجل لترتيب الصفحات: العقدة "مهمة" إذا ربطت بها عقد مهمة. تعطي كل node درجة أهمية.
- **ارتباطه بالمحاضرة:** مثال على "قياس أهمية node" داخل graph — راح نحتاجه بالقسم 6 (Numeric → Graph).

بطاقة بحث: Community Detection (كشف المجتمعات)

- **شئو هو:** تقسيم graph لمجموعات (communities) فيها روابط كثيفة داخلياً وخفيفة خارجياً. خوارزميات: Louvain, Newman–Girvan.
- **ارتباطه بالمحاضرة:** يظهر كتطبيق وكتقنية cluster لكن على graphs بدل نقاط إحداثيات.

بطاقة بحث: Graph Neural Networks (GNN — شبكات عصبية رسومية)


- **شئو هو:** شبكات عصبية "تتعلم" من بنية graph نفسها (لكل node تجمع معلومات جيرانها). أمثلة: GCN, GAT, GraphSAGE.
- **ارتباطه بالمحاضرة:** الطريقة الحديثة لتحويل graph → numeric embeddings (نرجع لها بالقسم 6).

القسم 4 — تجهيز البيانات (Data Preparation) — 6 خطوات

هذا إجرائي (مو بحثي)، الدكتور يذكره كـ pipeline. الست خطوات (بالترتيب غالباً):

1. **Data Collection** — جمع البيانات من مصادر (قواعد، ملفات، APIs، sensors).
2. **Data Cleaning** — معالجة القيم المفقودة، إزالة المكرر، تصحيح الأخطاء، حل التناقضات. (نفسها بالقسم 7)
3. **Data Integration** — دمج بيانات من مصادر مختلفة بـ dataset واحد متماسك.
4. **Data Transformation** — تحويل لصيغة متسقة (scaling, normalization, encoding).
5. **Data Reduction** — تقليل الحجم/الأبعاد بحذف سمات غير مهمة أو تجميع قيم. (نفسها بالقسم 7)
6. **Data Splitting** — تقسيم لـ training / validation / test (بمهام ML).

Data Preparation



Data Preparation pipeline (6–7 steps before modeling)

شكل: خطوة تجهيز البيانات (pipeline)

كل خطوة تأخذ مخرجات السابقة — هذا هو "الأنبوب" قبل ما تدخل البيانات للنموذج.
لماذا مهم؟ يضمن الدقة (يزيل الأخطاء)، يحسّن الكفاءة (أسرع)، يرفع أداء النموذج، يدعم قرار أفضل.

القسم 5 — استخراج السمات (Feature Extraction)

شنو هو: اشتقاق سمات جديدة "أكثر إفادة" من البيانات الخام لتحسين التحليل/النموذج — بدل استخدام الخام مباشرة. **ليش مهم:** الخام معقد/مزعج؛ يقلل الأبعاد؛ يظهر الأنماط؛ يحسّن الدقة. **أمثلة من المحاضرة:** - من صورة: استخراج edges/textures/color histograms أو deep embeddings (من طبقات CNN). مثال: من صورة سرطان ثدي نستخرج shape و texture. - من نص: TF-IDF, BoW, embeddings (BERT, Word2Vec). مثال: استخراج كلمات مفتاحية من ملاحظات طبية. - من صوت/إشارة: MFCC, amplitude, frequency. مثال: كشف murmur بالقلب من ECG. - من جدول: سمات مشتقة مثل BMI = $height^2/weight$ ، أو "فئة العمر" من العمر الخام.

مكانه بال pipeline: Collection → Cleaning → Integration → Transformation → **Feature Extraction** → Reduction → Splitting.

القسم 6 — قابلية نقل نوع البيانات (Data Type Portability) — ★★ الضعف الأساسي

هذا قلب المحاضرة 2 و 3. **المعنى:** تحويل البيانات من تمثيل لنوع إلى تمثيل آخر علمود الخوارزمية تقدر تعالجه.

العملية العامة: أنواع بيانات مختلفة → تحويل → تمثيل مناسب → خوارزمية تنقيب.

الجدول المرجعي الشامل (من المحاضرة 3 — احفظه)

من (From)	إلى (To)	التقنية
Numerical	Categorical	Discretization (تقطيع)
Categorical	Numerical	One-Hot Encoding
Text	Numerical	Vectorization (BoW / TF-IDF / embeddings)
Time Series	Numerical	Feature extraction (DFT/DWT)
Time Series	Sequence	Symbolic representation (SAX)
Image	Numerical	Feature extraction
Sequence	Numerical	Sequence encoding
Spatial	Numerical	Distance / shape features
Graph	Numerical	Graph embedding
أي نوع	Graph	Similarity graph


انتبه للسطرين الأخيرين — هما الاتجاهين المختلفين اللي الدكتور قفز بينهم وهذا سبب تشتتك (نفصل تحت).

6.1 Discretization: Categorical → Numerical (التقطيع)

شئو هو: تحويل قيم رقمية مستمرة إلى فئات ب تقسيم المدى إلى bins intervals). **أنواعه:** - **Equal-Width:** فترات متساوية (Age 0 → 100, [20-0], [40-21], ...). - **(Quantile) Equal-Frequency:** كل bin فيه نفس عدد النقاط تقريباً. - **Clustering-Based:** نستخدم k-means لتجميع القيم. - **Supervised:** نأخذ التصنيف (class label) بالحسبان (مثال: نقسم الدخل ليفصل "مقبول قرض" عن "مرفوض"). **مثال:** Age = [15, 18, 22, 35, 42, 50, 63, 70] ب Equal-Width = 20 → [Senior, Senior, Middle, Middle, Young, Young, Teen, Teen] العيب: ضياع معلومة (21 و 39 يصيرون نفس الفئة "Adult").

Discretization

Numeric → Categorical (Discretization)



← فئات (Discretization) </p>
</div>
<div data-bbox="352 319 641 337" data-label="Text">
<div data-bbox="568 360 939 379" data-label="Text">
<div data-bbox="66 389 930 634" data-label="Table">
<div data-bbox="432 658 913 677" data-label="Text">
<div data-bbox="66 702 558 722" data-label="Section-Header">
<div data-bbox="66 727 939 767" data-label="Text">
<div data-bbox="66 965 370 982" data-label="Page-Footer">
<div data-bbox="847 965 939 981" data-label="Page-Footer">

One-Hot Encoding (Categorical → Numeric)

Categories:

Red

Blue

Green

	Red	Blue	Green
Red	1	0	0
Blue	0	1	0
Green	0	0	1

</>(Numeric →

One-Hot Encoding (Categorical → Numeric): شكل

جدول بيانات حقيقي (فصائل دم → One-Hot):

Patient	Blood Type	A	B	O
P1	A	1	0	0
P2	B	0	1	0
P3	O	0	0	1
P4	A	1	0	0

ثلاثة أعمدة بدل رقم واحد — ما كتبنا A=1,B=2,O=3 عمداً.

6.3 Text → Numerical

(غطيناه بالقسم 2.4 — TF-IDF ,BoW ,embeddings. هذا أهم تحويل عند الدكتور.)

TF-IDF (Text → Numeric)

TF-IDF

weights

	Doc1	Doc2	
the	0.10	0.08	rare word → HIGH
cat	0.91	0.05	common word → LOW
dog	0.04	0.88	

شكل: TF-IDF (Text → Numeric) — الكلمة النادرة وزنها أعلى
(Numeric → الكلمة النادرة وزنها أعلى)

جدول بيانات حقيقي (مصفوفة Document–Term بأوزان TF-IDF):


ملاحظة	Doc2	Doc1	Term
شائعة → وزن منخفض	0.08	0.10	the
نادرة بـ Doc1 → وزن عالي	0.05	0.91	cat
نادرة بـ Doc2 → وزن عالي	0.88	0.04	dog

الجدول هو التمثيل الرقمي الذي ياكله النموذج — كل خلية = وزن الكلمة بالمستند.

6.4 Time Series → Numerical / → Sequence

- **Numerical** → نستخرج إحصائيات (skewness, min/max, std, mean) أو ميزات ترددية (Fourier/Wavelet) أو shapelets. النتيجة vector ثابت الطول.
- **Sequence (رمزي)**: نحول الأرقام لرموز. مثال: [N, N, H, L, L, H] → [75, 77, 80, 60, 58, 90]. تقنية شهيرة: **SAX** (Symbolic Aggregate Approximation) — تطبيع، تقسيم لقطاعات، أخذ المتوسط، ربطه برمز.

Time-Series → Sequence Time-Series → Symbolic Sequence (SAX)



← سلسلة رمزية (SAX) </p>
 <\/p>

جدول بيانات حقيقي (Symbolic Sequence → Time-Series):

Time	1	2	3	4	5	6
Heart Rate	75	77	80	60	58	90
Symbol	N	N	H	L	L	H

بدل الأرقام الخام، صارت رموز — أسهل لاكتشاف الأنماط والشذوذ.

6.5 Image → Numerical

الصورة أساساً matrix من شدة البكسل (grayscale: 0=أسود، 255=أبيض؛ RGB: 3 قنوات). بدل كل بكسل، نستخرج .vector → shape/texture/edges

6.6 Spatial → Numerical

إحداثيات مباشرة (long,lat)، أو مسافات لنقاط مرجعية، أو shape features (compactness, perimeter, area)، أو grid/raster.

6.7 Sequence → Numerical

One-hot لكل رمز، أو k-mer counts (نكسر التسلسل لقطع طول k ونعدها — مفيد بـ DNA)، أو embeddings (DNA2Vec).

★★ القسم 6.8 — Graph Embedding: Numerical → Graph (الأهم للفهم الأول)


هنا نحول الرسم البياني نفسه إلى أرقام علمود الخوارزميات. طرق:

- **Node-Level**: درجة العقدة (degree), clustering coefficient, (betweenness/closeness/eigenvector) centrality, PageRank. مثال: node → [degree=5, clustering=0.3, betweenness=0.12].
- **Edge-Level**: وزن الحافة، edge betweenness، تشابه العقدتين.
- **Graph-Level**: عدد العقد/الروابط، density = $2 \cdot |E| / (|V| \cdot (|V| - 1))$ ، diameter، متوسط clustering.
- **Adjacency / Laplacian flattening**: نفرد مصفوفة الجوار لأرقام (أو نأخذ eigenvalues).

- **Graph Embedding (Node2Vec / GNN):** نتعلم vectors كثيفة. random walks على graph = Node2Vec. Node A: المحاضرة: مثال الجيران. = Word2Vec (GCN/GraphSAGE/GAT) = تجمع ميزات الجيران. مثال المحاضرة: Node A: $[0.21, 0.75, 0.43]$ →

ارتباطه بالمحاضرة: الدكتور يذكر Node2Vec/GNN كحل لمشكلة "الخوارزميات تريد أرقام وال graph مو أرقام".

Graph Embedding Graph → Numeric (Graph Embedding)



→ Numeric (Graph Embedding) </p>
 <\/p>

جدول بيانات حقيقي (Graph → Numeric vector):

Node	Embedding (dense vector)
A	[0.21, 0.75, 0.43]
B	[0.19, 0.81, 0.39]
C	[0.24, 0.70, 0.51]
D	[0.22, 0.78, 0.44]

كل عقدة صارت متجه أرقام — النموذج يقدر يشتغل عليه.

★★★ القسم 6.9 — Converting Different Data Types INTO a Graph (النقطة اللي وقفت عندها)

هذا هو السبب الحقيقي لتشتتك: المحاضرة 2 كلها كانت "حوّل كل شي إلى أرقام" (Numerical → Graph). بس المحاضرة 3 فجأة قلبت الاتجاه: "بدل ما نحول كل شي أرقام، نمثّل العلاقات ك graph". الدكتور سماها "Converting Different Data Types into a Graph". هذي نقطة التحول واللي ما فهمتها.

شنو يعني (What)?


بدل التمثيل الرقمي، نمثل الأغراض (objects) ك nodes و العلاقات بينها ك edges. أشهر شكل: **Similarity Graph** (رسم التشابه) — نربط كل غرضين متشابهين بـ edge.

شلون يشتغل (How) — بالخطوات والمثال:

1. عندنا 5 مرضى، كل واحد عنده سمات رقمية (مثلاً العمر، الضغط، الكوليسترول).
2. نختار مقياس تشابه أو مسافة (مثلاً Euclidean distance على السمات).
3. لكل زوج (P_i, P_j) : إذا $\text{distance}(P_i, P_j) > \text{threshold}$ إذن نربطهم بـ edge.
4. النتيجة: graph يمثل أي مريض يشبه أي مريض.

شكل الرسم الناتج (بالكلمات): العقد $P1, P2, P3, P4$ متصلين ببعض ($P1-P2, P2-P4, P4-P3, P3-P1$) فيتشكل عنقود واحد، بينما $P5$ عقدة معزولة ما انبثت بأحد لأن مسافتها عن الكل فوق ال threshold.

Similarity Graph Converting Data INTO a Graph — Similarity Graph



شكل: 5 — Similarity Graph مرضى، 4 عنقود + $P5$ معزول (outlier)

جدول بيانات حقيقي (5 مرضى + مسافات ← روابط):

Pair	Distance	?Connected
P1-P2	0.12	✓ (نفس العنقود)
P2-P4	0.18	✓
P4-P3	0.15	✓
P3-P1	0.20	✓
P5-الكل	0.95	X (معزول → outlier)

المسافة $> \text{threshold}$ → نربط. $P5$ بعيدة عن الكل → ما انبثت → شذوذ.

- $P1, P2, P3, P4$ قريبين من بعض ← عنقود (cluster).

- P5 معزول (ما انربط بأحد) ← مرشح شذوذ (outlier) — وهذا يربطنا ببطاقة Anomaly Detection من القسم 2.1!

التطبيقات (ليش نسويها؟):

- **Clustering**: كل مكون متصل (connected component) = عنقود.
- **Classification**: ننشر لصنف من العقد المعروفة لباقي العقد.
- **Nearest-neighbor analysis**: الجيران = العقد المتصلة.
- **Outlier detection**: العقدة المعزولة = شاذة.

الفكرة الجوهرية: التحويل لـ graph يعكس الاتجاه — هنا نحول إلى graph (من أي نوع بيانات)، بينما بالقسم 6.8 حولنا من graph إلى numbers. الدكتور يدّرس الاتجاهين لأن بعض الخوارزميات (spectral clustering, community detection, k-NN على graph) تشتغل على البنية العلاقتية أحسن من المتجهات.

تحذير الدكتور (مهم للفهم):

"التحويل ممكن يضيّع معلومة." مثال: الأعمار [21,22,39] بعد discretization تصير [Adult,Adult,Adult] — الفرق الدقيق ضاع. لذلك اختيار طريقة التحويل لازم يكون حسب البيانات والمهمة، مو عشوائي.

القسم 7 — التنظيف، التحجيم، والتخفيض


7.1 Data Cleaning (تنظيف البيانات)

المشاكل الشائعة: missing entries, incorrect entries (typos), inconsistent entries (تواريخ بصيغ مختلفة), outliers, redundancy (تكرار). **التعامل مع المفقود (Missing Data):** - **MCAR** (Missing Completely at Random): عشوائي تماماً. - **MAR** (Missing at Random): يعتمد على قيم موجودة (الدخل مفقود أكثر عند الشباب). - **MNAR** (Missing Not at Random): يعتمد على القيمة المفقودة نفسها (أصحاب الدخل العالي يخفونه). **الاستراتيجيات:** - **Deletion**: حذف الصفوف (listwise) أو الأعمدة (إذا > 50% مفقود). - **Imputation**: تعبئة بـ mean/median/mode، أو KNN imputation، أو regression، أو multiple imputation.

7.2 Normalization & Scaling (التحجيم والتطبيع)

ليش؟ الخوارزميات (neural nets, SVM, KNN) تفترض الميزات بنفس المقياس؛ بدونه الميزة الكبيرة تسيطر. **Min-Max**:
$$\frac{x - x_{\min}}{x_{\max} - x_{\min}} \rightarrow [0,1]$$
 مدى حساس للـ outliers. **(Standardization) Z-Score**:
$$\frac{x - \mu}{\sigma} \rightarrow$$
 متوسط 0 وانحراف 1. أقل حساسية للـ outliers. **Max Abs / Robust / Decimal Scaling**: بدائل حسب الحالة.

Scaling — Min-Max vs Z-Score



شكل: التحجيم — Min-Max مقابل Z-Score

جدول بيانات حقيقي (Scaling على ميزة واحدة):

Raw	Min-Max (0-1)	Z-Score
10	0.00	-1.22
20	0.50	0.00
30	1.00	1.22

بدون التحجيم، القيمة 30 تسيطر على الخوارزمية — بعده كل الميزات بمدى متقارب.

7.3 Transformation & Data Reduction (تخفيض وتحويل)

- **Sampling**: أخذ عيّنة ممثلة (streams, reservoir, cluster, systematic, stratified, random).
- **Feature Subset Selection (3 أنواع — مهمة جداً)**:
- **Filter**: مقاييس إحصائية (mutual information, chi-square, correlation) — سريع، يتجاهل التفاعلات.
- **Wrapper**: نستخدم النموذج لتقييم الأنواع الفرعية (RFE) — أدق بس مكلف حسابياً.
- **Embedded**: الاختيار يصير أثناء التدريب (Random Forest importance, Lasso/L1) — فعال.
- **Dimensionality Reduction** بالـ **Axis Rotation**:
- **PCA**: إسقاط على مكونات رئيسية تلتقط أقصى تباين (orthogonal). خطوات: standardize → covariance matrix → اختر top-k eigenvectors/eigenvalues.
- **SVD**: $A = U\Sigma V^T$, يقلل الأبعاد. أساس LSA بالنصوص.
- **Dimensionality Reduction** بالـ **Type Transformation**:
- **Haar Wavelet**: متوسط والفرق بين قيم متجاورة → ضغط.
- **MDS**: يحافظ على المسافات الزوجية للتصور.
- **Spectral Graph Embedding**: eigenvectors للمصفوفة Laplacian → تمثيل رقمي للـ graph (يرجع لنفس موضوع 6.8).

خاتمة — ملخص سريع للمراجعة

1. عائلتان: Nondependency (كل سجل وحده) و Dependency (بينهم خيوط وقت/ترتيب/بنية).
2. 8 أنواع: $4 + 4$ كما فصلنا.
3. **Data Preparation**: 6 خطوات.
4. **Feature Extraction**: اشتقاق سمات أفضل من الخام.
5. **Portability**: جدول التحويل (استوعب اتجاهين: $\rightarrow$ numeric و $\rightarrow$ graph).
6. نقطة التحول: Similarity Graph = Converting INTO a Graph (بنبي edges بالمسافة $>$ threshold) — هذا اللي وقفت عنده.
7. **Cleaning / Scaling / Reduction**: المكمل الإجرائي.

نصيحة للدكتور: هو "يوزع بحث" — فكل كلمة بسمتها (ARIMA, PageRank, TF-IDF, ...SAX) هي بطاقة بحث بهالوثيقة. راجع البطاقة قبل أي محاضرة جاية.

Retrieval Set (بطاقات للمراجعة السريعة — لامتحان)

RS-01 ما الفرق بين Nondependency و Dependency data؟

Nondependency: كل سجل مستقل (مثل جدول مرضى). Dependency: القيم بينها علاقة/وقت/بنية (مثل سلسلة زمنية).

RS-02 اذكر الـ 4 أنواع من كل عائلة.

Nondependency: Quantitative Multidimensional, Categorical & Mixed, Binary & Set, Text. Dependency: Time-Series, Discrete Sequences, Spatial, Network & Graph.

RS-03 لماذا نستخدم One-Hot بدل $A=1, B=2, O=3$ ؟

لأن $A=1, B=2$ يخلق ترتيباً عددياً غير موجود بالفئات الاسمية (nominal)، فالنموذج يفهمه غلط.

RS-04 اشرح TF-IDF بكلمتين.

يوزن الكلمة بـ تكرارها بالمستند $\times$ ندرتها بال corpus؛ يرفع المهم ويخفض التافه ("the").

RS-05 ما هو Similarity Graph ولماذا بنبيه؟

نمّثل الأغراض nodes والعلاقات edges؛ نربط كل زوج مسافته $>$ threshold. يفيد clustering, classification, NN, outlier detection.

اذكر 3 أنواع Feature Selection. RS-06

(Filter إحصاء)، Wrapper (نموذج يقيّم)، Embedded (أثناء التدريب ك Lasso).