

وثيقة المراجعة والتلخيص الأكاديمي

ملاحظة مهمة قبل تبدأ: الدكتور ما يعلم — هو يوزع بحث. في هالنسخة v3، كل اقتباس إنكليزي داخل صندوق Verbatim هو حرفياً من كلام الدكتور بالمصادر (ملفات الـ docx الأصلية) — ما انجم من راسي. تحتها مباشرة الشرح العربي الفهمي. باقي الملزمة كله عربي (والمصطلحات الإنكليزية كما هي بالمحاضرة). قراها كأنك باحث: كل قسم فيه بطاقة بحث تحتها ثلاثة خطوط — **شنو هو، شلون يشتغل (مع مثال)، وارتباطه بالمحاضرة.**

القسم 1 — التصنيف الكبير: عائلتان من البيانات

قبل أي شي، الدكتور ي divide البيانات لـ **عائلتين** (هذا أساس كل المحاضرة، وغالباً يسأل عنه). هما التصنيف الحرفي من كلامه:

Verbatim (Doctor — Week 02): "Nondependency-Oriented Data → Data where values are independent of each other."

Verbatim (Doctor — Week 02): "Dependency-Oriented Data → Data where values are related or dependent on each other, often involving order, time, or structure."

العائلة	المعنى الحرفي	شلون نعرفها؟
Nondependency-Oriented (غير معتمدة على بعض)	القيم مستقلة، كل سجل وحده ما يعتمد على الثاني	جدول مرضى: العمر والضغط والكوليسترول — كل مريض رقمه بحد نفسه
Dependency-Oriented (معتمدة على بعض)	القيم بينها علاقة / ترتيب / وقت / بنية	سعر السهم عبر الأيام — اليوم يعتمد على الأمس

حفظ سريع: Nondependency = "كل واحد بحده". Dependency = "بينهم خيوط" (وقت، ترتيب، أو بنية شبكية).

الشرح الفهمي: الدكتور يفتح المحاضرة بالخطوة — يقسم البيانات أولاً. العائلة الأولى "ما يهمها الثاني": كل صف بجدول يقف لحاله. العائلة الثانية "بين عناصرها خيوط": ترتيب، أو وقت، أو بنية شبكية (زي الروابط بـ graph). هالفارق هو اللي يحدد أي خوارزمية نستخدم.

القسم 2 — العائلة الأولى: Nondependency-Oriented (4 أنواع)


2.1 Quantitative Multidimensional Data (بيانات كمية متعددة الأبعاد)

Verbatim (Doctor — Week 02): "Definition: Data represented by multiple numerical attributes."

Verbatim (Doctor — Week 02): "Characteristics: Continuous values (real numbers). Can be represented in a vector form. Use cases: Regression, clustering, anomaly detection."

التعريف: بيانات تمثّل بأكثر من سمة رقمية (vector). **مثال الدكتور:** مجموعة طبية فيها Age, Blood Pressure, Cholesterol, BMI. **الخصائص:** قيم مستمرة (أرقام حقيقية)، تمثّل على شكل متجه (vector)، استخداماتها: Regression, anomaly detection, clustering.

Quantitative Multidimensional — numeric vector



Age=25, BP=80, Chol=190, BMI=22 → [25,80,190,22]

شكل: بيانات كمية متعددة الأبعاد — كل سجل = متجه أرقام

جدول بيانات حقيقي (مجموعة طبية — كل صف متجه أرقام):

Patient	Age	Blood Pressure	Cholesterol	BMI
P1	25	120	190	22.1
P2	41	135	210	26.4
P3	33	118	175	23.0
P4	58	150	240	29.8

كل صف = نقطة بـ 4 أبعاد، مثلاً $P1 = [25, 120, 190, 22.1]$.

بطاقة بحث: Regression (الانحدار)

- **شئو هو:** عائلة من النماذج تحاول تتنبأ بقيمة رقمية مستمرة من مدخلات. الفرق الجوهرى عن التصنيف (classification): التصنيف يجاوب "نعم/لا" أو "فئة"، الانحدار يجاوب "كم؟" (سعر، عمر، ضغط).
- **شلون يشتغل (مثال):** لو عندك أعمار وضغط لمرضى، تبني خط $BP \approx a \cdot Age + b$. تعطيه عمر جديد فيتوقع الضغط. أبسط نوع = Linear Regression (أقل مربعات). أنواع ثانية: Lasso, Ridge, Polynomial.
- **ارتباطه بالمحاضرة:** هذا النوع (Quantitative Multidimensional) هو "الوقود" الطبيعى للانحدار لأنه أرقام متجهة. لهذا الدكتور خليه ضمن الـ use cases.

بطاقة بحث: Clustering (التجميع)

- **شنو هو:** تقسيم البيانات لـ groups بحيث اللي داخل المجموعة الوحدة يكونون متشابهين، وكل مجموعة تختلف عن الثانية — بدون ما نعرف مقدماً أسماء المجموعات (unsupervised).
- **شلون يشتغل (مثال):** K-Means: تختار K مركز عشوائي، توزع كل نقطة لأقرب مركز، تحسب مراكز جديدة، تكرر لحد يستقر. النتيجة: عناقيد.
- **ارتباطه بالمحاضرة:** ينطبق على البيانات الكمية لأننا نحتاج "مسافة" بين النقاط (Euclidean distance) — وهذا متوفر بس لما البيانات رقمية متجهة.

بطاقة بحث: Anomaly Detection (كشف الشذوذ)

- **شنو هو:** اكتشاف النقاط اللي "ما تطابق" باقي البيانات — اللي هي نادرة أو غريبة (تسمى outliers أو anomalies).
- **شلون يشتغل (مثال):** قيمة ضغط = 300 تعتبر شذوذ لأنها بعيدة جداً عن توزيع باقي المرضى. طرق: statistical (z-score)، أو clustering (نقطة ما انتمت لأي عنقود)، أو Isolation Forest.
- **ارتباطه بالمحاضرة:** يظهر مرتين بالمحاضرة (هنا، وفي Time-Series) لأن الشذوذ يهم بكل أنواع البيانات — طبي (مرض)، مالي (احتيا)، حساس للوقت (إنذار مبكر).

2.2 Categorical and Mixed Attribute Data (بيانات تصنيفية ومختلطة)

Verbatim (Doctor — Week 02): "Categorical Data: Attributes represent discrete categories/labels."

Verbatim (Doctor — Week 02): "Mixed Attribute Data: Contains both numerical and categorical variables."

Verbatim (Doctor — Week 02): "Challenges: Need special encoding techniques (e.g., one-hot encoding). Distance metrics are harder to define compared to numerical data."

التعريف: Categorical = سمات تمثل تصنيفات منفصلة (Red/Green/Blue، أو Kenya/India/USA). Mixed = تجمع رقمي + تصنيفي (مثال: {Age=21, Male=Gender, GPA=3.4, CS=Major}). **التحدي:** نحتاج تقنيات ترميز خاصة (مثل one-hot)، وقياس المسافة أصعب من الرقمي.

Categorical & Mixed — labels + numbers



Mixed record:

Age = 21 (numeric)	GPA = 3.4 (numeric)
Gender = Male (category)	Major = CS (category)

شكل: بيانات تصنيفية ومختلطة — فئات + أرقام

جدول بيانات حقيقي (سجلات طلاب — مختلطة رقمي + تصنيفي):

Student	Age	Gender	GPA	Major
S1	21	Male	3.4	CS
S2	22	Female	3.1	Math
S3	20	Male	2.9	CS
S4	23	Female	3.7	Physics

العمود Gender و Major تصنيفي (nominal)؛ الباقي رقمي. هذا بالضبط اللي يحتاج one-hot.

بطاقة بحث: One-Hot Encoding (الترميز الساخن الواحد)

- **شنو هو:** لكل فئة نسوي عمود ثنائي (0/1). اللون {Green, Blue, Red} يصير 3 أعمدة: $[1,0,0]=\text{Red}$, $[0,1,0]=\text{Blue}$, $[0,0,1]=\text{Green}$.
- **شلون يشتغل:** المريض P1 بفصيلة A يصير $[1,0,0]$, P2 بفصيلة B يصير $[0,1,0]$. الـ 1 يعني "هذا الفئة موجود"، الـ 0 "غائب".
- **ليش ما نكتب $A=1, B=2, O=3$ ؟** لأن هذا يوهم النموذج إنه فيه ترتيب عددي (B أكبر من A؟ ما منطق). فصائل الدم nominal ما بينها ترتيب، ف one-hot هو الصح للـ nominal.
- **ارتباطه بالمحاضرة:** هذا هو الحل لمشكلة "الخوارزميات تريد أرقام" مع البيانات التصنيفية. تذكره دائماً كجسر Numeric → Categorical (راح نشوفه بالقسم 6).

بطاقة بحث: Distance Metrics for Categorical (قياس المسافة للتصنيفي)

- **شنو هو:** كيف "نقيس تقارب" سجلين فيهم حقول تصنيفية. بالرقمي نستخدم Euclidean، بالتصنيفي نستخدم مثلاً Hamming distance (عدد الحقول المختلفة) أو Jaccard.
- **شلون يشتغل:** سجلان {CS, Male} و {Math, Male} — يختلفون بـ حقل واحد من 2 → مسافة 0.5.
- **ارتباطه بالمحاضرة:** الدكتور ذكر إن "المسافة أصعب تعريفها" للتصنيفي — لأن مفهوم "البعد" ما ينطبق مباشرة، فلازم نحول أو نستخدم مقاييس بديلة.

2.3 Binary and Set Data (بيانات ثنائية وبيانات مجموعات)

Verbatim (Doctor — Week 02): "Binary Data: Attributes with only two possible values {0,1} or {True, False}."

Verbatim (Doctor — Week 02): "Set Data: Each object described by a set of items."

Verbatim (Doctor — Week 02): "Applications: Association rule mining (e.g., Market Basket Analysis). Recommendation systems."

التعريف: Binary = قيمتين بس {0,1} أو {False, True} (مثال: Smoker نعم/لا، Loan Defaulted نعم/لا). Set = كل غرض يوصف بمجموعة عناصر (مثال: سلة تسوق {Eggs, Bread, Milk}). **التطبيقات:** Association rule mining, recommender systems.

Binary & Set — 0/1 matrix + item set

Smoker	Loan	Fraud
1	0	0
0	1	1
1	0	1
0	0	0

Market Basket

- Milk
- Bread
- Eggs

شكل: بيانات ثنائية (مصفوفة 0/1) وبيانات مجموعات (سلة)

جدول بيانات حقيقي (مصفوفة شرائية — كل صف binary set):

Customer	Milk	Bread	Eggs	Cheese
C1	1	1	1	0
C2	0	1	0	1
C3	1	0	1	0
C4	0	0	0	0

سلة C1 = {Eggs, Bread, Milk}. خوارزمية Apriori تبحث الأنماط بين هالسلات.

بطاقة بحث: Association Rule Mining / Market Basket Analysis (تنقيب القواعد الارتباطية / تحليل سلة التسوق)

- **شئ هو:** اكتشاف قواعد من نوع "إذا اشترى X فغالباً يشتري Y" من بيانات المعاملات. أشهر مثال: "حفاضات ← بيرة" (أسطورة Walmart).
- **شئون يشتغل:** خوارزمية Apriori: تعدّ تكرار العناصر المفردة، ثم الأزواج، ثم الثلاثيات، وتصفية بال support (نسبة الظهور) و ال confidence (احتمال Y إذا ظهر X) و ال lift.
- **ارتباطه بالمحاضرة:** بيانات ال Set (السلة) هي الوقود الطبيعي لها — كل سلة = set، ونبحث الأنماط بين السلات.

بطاقة بحث: Recommendation Systems (أنظمة التوصية)

- **شئ هو:** نظام يقترح عناصر (فيلم، منتج) بناءً على سلوك المستخدم. نوعان رئيسيان: collaborative filtering (بناءً على مستخدمين مشابهين) و content-based (بناءً على خصائص العنصر).
- **ارتباطه بالمحاضرة:** يذكره الدكتور لأنه يأكل بيانات ثنائية/مجموعات (user-item matrix مليون 0/1 = شاف/ما شاف).

2.4 Text Data (بيانات نصية) — ★ أهم نوع عند الدكتور


Verbatim (Doctor — Week 02): "Definition: Data stored as unstructured textual information."

Verbatim (Doctor — Week 02): "Text is unstructured and must be converted into numerical form (Bag of Words, TF-IDF, word embeddings)."

Verbatim (Doctor — Week 02): "Applications: Sentiment analysis, topic modeling, chatbots, search engines."

التعريف: بيانات مخزنة كمعلومات نصية غير مهيكلة (emails, reviews, articles, tweets). **التحدي:** النص غير مهيكل ولا بد نحوله لأرقام (Bag of Words, TF-IDF, word embeddings). **التطبيقات:** Sentiment analysis, topic modeling, chatbots, search engines.

Text — unstructured → numeric vector



← تحويل لأرقام "/"
شكل: نص غير مهيكل ← تحويل لأرقام

جدول بيانات حقيقي (مستندات + تمثيلها):

Doc	Text (raw)	Bag-of-Words vector (cat, dog, mat, log, sat, the, on)
D1	"The cat sat on the mat"	[1, 0, 1, 0, 1, 2, 1]
D2	"The dog sat on the log"	[0, 1, 0, 1, 1, 2, 1]

النص الخام ما يقرأه النموذج — نحوله لأرقام (BoW/TF-IDF) أولاً.

بطاقة بحث: Bag of Words (BoW) — حقيبة الكلمات

- **شئ هو:** تمثيل النص كـ vector من عدد مرات كل كلمة.

— **Doctor) Verbatim** "Represents text as a vector of word counts" : **(Week 02 — Doctor) Verbatim**

"[1, 0, 1, 0, 1, 2, 1] → Sentence 1 — [on ,the ,sat ,log ,mat ,dog ,cat] :Vocabulary" : **(Week 02**

- شلون يشتغل (مثال):
- ج1: "The cat sat on the mat" — ج2: "The dog sat on the log"
- القاموس: [on ,the ,sat ,log ,mat ,dog ,cat]
- ج1 → [1, 0, 1, 0, 1, 2, 1] (the ظهر مرتين)
- ج2 → [0, 1, 0, 1, 1, 2, 1]
- المشكلة: يتجاهل ترتيب الكلمات ومعناها (cat و dog يمشون بنفس البعد). وهذا يؤدي لـ **sparsity** (أغلب الخانات صفر).

بطاقة بحث: **TF-IDF (Inverse Document Frequency – Term Frequency)** ★★ اللي سألت عنه

- **شنو هو:** وزن إحصائي لكل كلمة داخل مستند ضمن مجموعة مستندات (corpus). يكافئ الكلمات المهمة بوزن عالي، والكلمات الشائعة (مثل "is", "the") بوزن منخفض. هو **تطوير** على BoW يحل مشكلة الكلمات التافهة.

— **Doctor) Verbatim** "TF(t,d) × IDF(t) = (t,d)TF-IDF" : **(Week 02 — Doctor) Verbatim**

"frequent but uninformative words Better than BoW because it reduces the impact of"

- شلون يشتغل (المعادلة والخطوات):
- $TF(t,d) = \text{عدد مرات الكلمة } t \text{ بالمستند } d \div \text{مجموع كلمات } d$
- $IDF(t) = \log\left(\frac{N}{1 + df(t)}\right)$ حيث $N = \text{عدد المستندات}$, $df(t) = \text{عدد المستندات اللي تحتوي } t$.
- $TF-IDF(t,d) = TF(t,d) \times IDF(t)$.
- **مثال:** مستندان — د1 "the cat sat"، د2 "the dog ran". كلمة "the" بكليهما $df=2$, $N=2 \rightarrow IDF = \log(2/3)$ → سلبي صغير → وزن "the" ضعيف. كلمة "cat" بس بد1 $df=1 \rightarrow IDF = \log(2/2)=0$ → لا، بالصيغة بـ $1+$ بالمقام تطلع موجبة ومرتفعة → "cat" تاخذ وزن عالي لأنها نادرة ومميزة.
- **ليش أحسن من BoW:** يقلل تأثير الكلمات المتكررة لكن غير المفيدة. "cancer" بورقة طبية أهم من "the" رغم إن "the" أكثر عدداً.

بطاقة بحث: **Word Embeddings (تضمين الكلمات — FastText ,GloVe ,Word2Vec)**

- **شنو هو:** تمثيل كل كلمة كـ vector كثيف (dense) بأبعاد قليلة (مثل 100–300)، بحيث الكلمات القريبة بالمعنى يكون لها vectors قريبة بالفضاء.

— **Doctor) Verbatim** "Advantage" : Captures semantic relationships : **(Week 02 — Doctor) Verbatim**

"('queen ≈ woman + man – king")

- شلون يشتغل (مثال الخرافة المعروفة): $queen \approx woman + man - king$. النموذج التقط العلاقة الدلالية.
- Word2Vec يتعلم من السياق (الكلمات اللي تطلع جنب بعض)، GloVe من مصفوفة التشارك الإحصائي.
- ارتباطه بالمحاضرة: بديل أعمق من BoW/TF-IDF لأنه يفهم المعنى والسياق، يستخدم بـ chatbots والترجمة.

بطاقة بحث: **Sentiment Analysis (تحليل المشاعر)**

- **شنو هو:** تصنيف النص حسب المشاعر (إيجابي/سلبي/محايد). تطبيق كلاسيكي: مراجعات الأفلام.
- **شلون يشتغل:** تحول المراجعة إلى TF-IDF أو embeddings → نمررها لنموذج (Bayes Naïve أو BERT) → يصنفها.
- **ارتباطه بالمحاضرة:** من تطبيقات Numeric → Text؛ الدكتور يذكره كدليل عملي إن تحويل النص لأرقام يقود لمهام حقيقية.

بطاقة بحث: Topic Modeling (نمذجة المواضيع)

- **شنو هو:** اكتشاف "مواضيع مخفية" داخل مجموعة وثائق (مثال: أخبار مقسمة لرياضة/سياسة/اقتصاد بدون تسمية مسبقة). أشهر خوارزمية: LDA (Latent Dirichlet Allocation).
- **ارتباطه بالمحاضرة:** تطبيق نصي يعتمد على التمثيل الرقمي للوثائق.

بطاقة بحث: Search Engines & Chatbots

- **Chatbots:** نظام يفهم ويرد على النص. يعتمد على embeddings/transformers (BERT/GPT) لتحويل سؤال المستخدم لنص "قابل للمعالجة".
- **Search Engines:** تحول استعلامك والصفحات لأرقام (sentence embeddings) وتقارن التشابه. الدكتور يذكرها لأنها أضخم تطبيق عملي ل Numeric → Text.

القسم 3 — العائلة الثانية: Dependency-Oriented (4 أنواع)


3.1 Time-Series Data (بيانات سلاسل زمنية)

Verbatim (Doctor — Week 02): "Definition: A sequence of values recorded over time."

Verbatim (Doctor — Week 02): "Characteristics: Temporal dependency (past values influence future values). Often analyzed using ARIMA, LSTMs, Transformers. Applications: Forecasting, anomaly detection."

التعريف: سلسلة قيم مسجلة عبر الزمن (أسعار أسهم، طقس، إشارات ECG). **الخصائص:** اعتماد زمني (الماضي يؤثر بالمستقبل). تُحلل بـ ARIMA, LSTMs, Transformers. **التطبيقات:** Forecasting, anomaly detection.

Time-Series — values across time



ample: stock price / ECG signal / temperature

شكل: سلسلة زمنية — قيم عبر الزمن

جدول بيانات حقيقي (سعر سهم عبر 8 أيام):

Day	1	2	3	4	5	6	7	8
Price	100	102	99	105	103	107	110	108

الترتيب مهم: 100→102→99 له معنى، ما يصير نعيد ترتيبه عشوائي.

بطاقة بحث: ARIMA / LSTM / Transformers

- **ARIMA** (AutoRegressive Integrated Moving Average): نموذج إحصائي كلاسيكي للتنبؤ يعتمد على القيم السابقة والفروق بينها.
- **LSTM** (Long Short-Term Memory): نوع من الشبكات العصبية المتكررة (RNN) "يتذكر" السياق الطويل — ممتاز للسلاسل الزمنية.
- **Transformers** (مثل BERT/GPT لكن للزمن): أحدث نماذج، تلتقط الاعتماديات بعيدة المدى.
- **ارتباطه بالمحاضرة:** الدكتور يذكرها لأن Time-Series تحتاج نماذج "تفهم الترتيب" — عكس الـ Quantitative اللي كل صف وحده.

3.2 Discrete Sequences and Strings (سلاسل رموز منفصلة)

Verbatim (Doctor — Week 02): "Definition: Data represented as sequences of discrete symbols."

Verbatim (Doctor — Week 02): "Challenges: Pattern matching, alignment, and subsequence analysis."

التعريف: تسلسل رموز منفصلة (DNA: ATCG, clickstreams: سلسلة صفحات). **التحدي:** alignment, pattern matching, تحليل الأنظمة الفرعية. **التطبيقات:** Bioinformatics, web usage mining, NLP.

Discrete Sequence — ordered symbols



شكل: سلسلة رموز منفصلة — ترتيب مهم

جدول بيانات حقيقي (سلاسل منفصلة):

ID	Type	Sequence
S1	DNA	A → T → C → G → A → C → G
S2	Clickstream	Home → Search → Product → Cart
S3	DNA	A → T → G → G → A → C → T

تبدیل رمز واحد یغیر المعنى (مثل الطفرة بالـ DNA) — لذلك الترتیب أساسی.

بطاقة بحث: Pattern Matching / Alignment (مطابقة الأنماط / المحاذاة)

- **شنو هو:** إيجاد تشابه بين تسلسلين (مثل محاذاة تسلسلين DNA لاكتشاف طفرة). أدوات: Wunsch–Needleman, BLAST.
- **ارتباطه بالمحاضرة:** التحدي هنا هو "المسافة" بس، بل "الترتيب مهم" — فلازم خوارزميات تسلسل لا خوارزميات جدول.

Spatial Data 3.3 (بيانات مكانية)

Verbatim (Doctor — Week 02): "Definition: Data representing objects in a spatial or geographical context."

Verbatim (Doctor — Week 02): "Challenges: Spatial autocorrelation (nearby objects are more related)."

التعريف: بيانات بـسياق جغرافي/مكاني (خرائط، صور أقمار، إحداثيات lat/long). **التحدي:** Spatial autocorrelation (الأشياء القريبة مكانياً أكثر ارتباطاً). **التطبيقات:** GIS، مراقبة المرور، النمذجة البيئية.

Spatial — coordinates on a grid



lat/long
32.50, 45.82

شكل: بيانات مكانية — إحداثيات على شبكة

جدول بيانات حقيقي (مواقع مستشفيات — lat/long):

Hospital	Latitude	Longitude	Type
H1	32.50	45.82	General
H2	32.48	45.85	Children
H3	32.55	45.79	Cardiac
H4	32.46	45.90	General

نحسب "المسافة" بينها بالإحداثيات — أقرب مستشفى = الأهم للتحليل المكاني.

بطاقة بحث: Spatial Autocorrelation (الارتباط الذاتي المكاني)

- **شنو هو:** مبدأ "القريب من القريب أقرب" — مدينة تشبه جيرانها أكثر من مدينة بعيدة. يقاس بـ Moran's I.
- **ارتباطه بالمحاضرة:** هذا يكسر فرضية "كل سجل وحده" (independence) — وبالتالي يصنفها الدكتور Dependency.

3.4 Network and Graph Data (شبكات ورسوم بيانية) — ★★ مهم جداً ومرتب بنقطة توقفك

Verbatim (Doctor — Week 02): "Definition: Data represented as nodes and edges."

Verbatim (Doctor — Week 02): "Characteristics: Strongly structured data. Requires graph algorithms (PageRank, community detection, Graph Neural Networks)."

التعريف: بيانات ممثلة بـ nodes (عقد) و edges (روابط). مثال: Facebook (المستخدمون = nodes، الصداقة = edges)، شبكات الاقتباس. **الخصائص:** بيانات "بنية قوية"، تتطلب خوارزميات رسوم (PageRank, community detection, GNN). **التطبيقات:** تحليل التواصل الاجتماعي، كشف الاحتيال، recommender systems.


Network & Graph — nodes + edges

nodes =

objects

edges =

links



شكل: شبكة/رسم بياني — عقد + روابط

جدول بيانات حقيقي (شبكة تواصل — قائمة روابط):

Edge	From (node)	To (node)	Relation
e1	Ahmed	Sara	friend
e2	Sara	Omar	friend
e3	Omar	Ahmed	friend
e4	Lina	Omar	colleague

الجدول يحتوي عقد (From/To) وروابط — هذا تمثيل "edge list" لـ graph.

بطاقة بحث: PageRank

- **شئو هو:** خوارزمية جوجل لترتيب الصفحات: العقدة "مهمة" إذا ربطت بها عقد مهمة. تعطي كل node درجة أهمية.
- **ارتباطه بالمحاضرة:** مثال على "قياس أهمية node" داخل graph — راح نحتاجه بالقسم 6 (Numeric → Graph).

بطاقة بحث: Community Detection (كشف المجتمعات)

- **شئو هو:** تقسيم graph لمجموعات (communities) فيها روابط كثيفة داخلياً وخفيفة خارجياً. خوارزميات: Louvain, Newman–Girvan.
- **ارتباطه بالمحاضرة:** يظهر كتطبيق وكتقنية cluster لكن على graphs بدل نقاط إحداثيات.

بطاقة بحث: Graph Neural Networks (GNN — شبكات عصبية رسومية)

- **شئو هو:** شبكات عصبية "تتعلم" من بنية graph نفسها (لكل node تجمع معلومات جيرانها). أمثلة: GCN, GAT, GraphSAGE.
- **ارتباطه بالمحاضرة:** الطريقة الحديثة لتحويل graph → numeric embeddings (نرجع لها بالقسم 6).


القسم 4 — تجهيز البيانات (Data Preparation) — 6 خطوات

هذا إجرائي (مو بحثي)، الدكتور يذكره كـ pipeline. الست خطوات (بالترتيب غالباً) — بالكلام الحرفي للدكتور:

Verbatim (Doctor — Week 02): "Data Collection – Gathering data from multiple sources (databases, files, APIs, sensors, etc.)." **Verbatim (Doctor — Week 02):** "Data Cleaning – Handling missing values, removing duplicates, correcting errors, and resolving inconsistencies." **Verbatim (Doctor — Week 02):** "Data Integration – Combining data from different sources into a single coherent dataset." **Verbatim (Doctor — Week 02):** "Data Transformation – Converting data into a consistent format (e.g., encoding categorical variables, normalization, scaling)." **Verbatim (Doctor — Week 02):** "Data Reduction – Reducing the size/dimensionality of data by removing irrelevant features or aggregating values." **Verbatim (Doctor — Week 02):** "Data Splitting – Dividing data into training, validation, and test sets (in machine learning tasks)."

1. **Data Collection** — جمع البيانات من مصادر (قواعد، ملفات، APIs، sensors).
2. **Data Cleaning** — معالجة القيم المفقودة، إزالة المكرر، تصحيح الأخطاء، حل التناقضات. (نفسها بالقسم 7)
3. **Data Integration** — دمج بيانات من مصادر مختلفة بـ dataset واحد متماسك.
4. **Data Transformation** — تحويل لصيغة متسقة (encoding، normalization، scaling).
5. **Data Reduction** — تقليل الحجم/الأبعاد بحذف سمات غير مهمة أو تجميع قيم. (نفسها بالقسم 7)
6. **Data Splitting** — تقسيم لـ training / validation / test (بمهام ML).

Data Preparation



Data Preparation pipeline (6–7 steps before modeling)

شكل: خطوة تجهيز البيانات (pipeline)

كل خطوة تأخذ مخرجات السابقة — هذا هو "الأنبوب" قبل ما تدخل البيانات للنموذج.
لماذا مهم؟ (بكلام الدكتور الحرفي): **Verbatim (Doctor — Week 02):** "removes errors and) Ensures accuracy" Enhances model performance. (organized data is faster to process) Improves efficiency. (inconsistencies reliable) Supports better decision-making. (and relevant data leads to better predictions ,balanced ,clean) ".(insights come from well-prepared data"

القسم 5 — استخراج السمات (Feature Extraction)

Verbatim (Doctor — Week 03): "Feature extraction is the process of creating new features from existing data to represent its important characteristics in a form suitable for data mining or machine learning algorithms."

Verbatim (Doctor — Week 03): "Instead of giving the complete image directly to a traditional algorithm, we can represent it using useful features."

شئو هو: اشتقاق سمات جديدة "أكثر إفادة" من البيانات الخام لتحسين التحليل/النموذج — بدل استخدام الخام مباشرة. **ليش مهم:** الخام معقد/مزعج؛ يقلل الأبعاد؛ يظهر الأنماط؛ يحسن الدقة. **أمثلة من المحاضرة:** - من صورة: استخراج edges/textures/color histograms أو deep embeddings (من طبقات CNN). مثال: من صورة سرطان ثدي نستخرج shape و texture. - من نص: BoW, TF-IDF, embeddings (BERT, Word2Vec). مثال: استخراج كلمات مفتاحية من ملاحظات طبية. - من صوت/إشارة: MFCC, amplitude, frequency. مثال: كشف murmur بالقلب من ECG. - من جدول: سمات مشتقة مثل BMI = height²/weight، أو "فئة العمر" من العمر الخام.

مكانه بال **pipeline**: Collection → Cleaning → Integration → Transformation → **Feature Extraction** → Splitting → Reduction.

القسم 6 — قابلية نقل نوع البيانات (Data Type Portability) ★★ الضعف الأساسي

هذا قلب المحاضرة 2 و 3. التعريف الحرفي من الدكتور:

Verbatim (Doctor — Week 03): "Data Type Portability means converting data from one representation or type into another representation so that it can be processed by a data mining algorithm."

المعنى: تحويل البيانات من تمثيل لنوع إلى تمثيل آخر علمود الخوارزمية تقدر تعالجه.

العملية العامة: أنواع بيانات مختلفة → تحويل → تمثيل مناسب → خوارزمية تنقيب.

الدكتور يذكر قائمة التحويلات الشائعة (بكلامه):

Verbatim (Doctor — Week 03): "Numerical → Categorical: Discretization. Categorical → Numerical: Encoding. Text → Numerical: Vectorization. Time Series → Sequence: Symbolic representation. Time Series → Numerical features: DFT / DWT or feature extraction. Image → Numerical features: Feature extraction. Graph → Numerical representation: Graph embedding. Any data type → Graph: Similarity graph."

الجدول المرجعي الشامل (من المحاضرة 3 — احفظه)

من (From)	إلى (To)	التقنية
Numerical	Categorical	Discretization (تقطيع)
Categorical	Numerical	One-Hot Encoding

التقنية	إلى (To)	من (From)
Vectorization (BoW / TF-IDF / embeddings)	Numerical	Text
Feature extraction (DFT/DWT)	Numerical	Time Series
Symbolic representation (SAX)	Sequence	Time Series
Feature extraction	Numerical	Image
Sequence encoding	Numerical	Sequence
Distance / shape features	Numerical	Spatial
Graph embedding	Numerical	Graph
Similarity graph	Graph	أي نوع

انتبه للسطرين الأخيرين — هما الاتجاهين المختلفين اللي الدكتور قفز بينهم وهذا سبب تشتتك (نفصل تحت).

6.1 Discretization: Categorical → Numerical (التقطيع)


Verbatim (Doctor — Week 02): "Discretization is the process of converting continuous numeric data into discrete categorical data by dividing the range of values into intervals (bins)."

Verbatim (Doctor — Week 02): "Example: Age = [15, 18, 22, 35, 42, 50, 63, 70]. Equal-Width Binning (width=20): Categories: Teen (0–20), Young (21–40), Middle-aged (41–60), Senior (61–80). Result: [Teen, Teen, Young, Young, Middle-aged, Middle-aged, Senior, Senior]."

شئو هو: تحويل قيم رقمية مستمرة إلى فئات ب تقسيم المدى إلى bins). **أنواعه:** - **Equal-Width:** فترات متساوية (Age 0 → [20–0], [21–40], ..., [61–80]). - **Equal-Frequency (Quantile):** كل bin فيه نفس عدد النقاط تقريباً. - **Clustering-Based:** نستخدم k-means لتجميع القيم. - **Supervised:** نأخذ التصنيف (class label) بالحسبان (مثال: نقسم الدخل ليفصل "مقبول قرض" عن "مرفوض"). **العيب:** ضياع معلومة (21 و 39 يصيرون نفس الفئة "Adult").

Discretization

Numeric → Categorical (Discretization)



← فئات (Discretization) </p>
</div>
<div data-bbox="352 884 640 901" data-label="Text">
<p>شكل: تقطيع رقمي ← فئات (Discretization)</p>
</div>
<div data-bbox="67 965 369 981" data-label="Page-Footer">
<p>كلية علوم الحاسوب وتكنولوجيا المعلومات — جامعة واسط</p>
</div>
<div data-bbox="847 965 938 980" data-label="Page-Footer">
<p>Page 15 of 26</p>
</div>

جدول بيانات حقيقي (Categorical → Numeric):

Age	Bin (Equal-Width=20)
15	Teen (0–20)
18	Teen (0–20)
22	Young (21–40)
35	Young (21–40)
42	Middle-aged (41–60)
50	Middle-aged (41–60)
63	Senior (61–80)
70	Senior (61–80)

العمر 21 و 39 كلهن "Young" — الفرق الدقيق ضاع (هذا هو العيب).

6.2 Categorical → Numerical: Binarization / One-Hot

(غطيناه بالقسم 2.2 — راجع بطاقة One-Hot. النقطة الإضافية من المحاضرة 3 — لا تكتب $A=1, B=2, O=3$ لل nominal). كلام الدكتور الحرفي:

Verbatim (Doctor — Week 03): "Why Not Simply Use $A = 1, B = 2, O = 3$? Using $A = 1, B = 2, O = 3$ may incorrectly suggest that the categories have a numerical order. For nominal categories such as blood type, there is no meaningful order. Therefore, one-hot encoding is usually more appropriate for nominal categorical data."

Verbatim (Doctor — Week 02): "One-Hot Encoding: Each category gets a new binary column. Example: Color = {Red, Blue, Green} → Red 1 0 0, Blue 0 1 0, Green 0 0 1."

One-Hot Encoding (Categorical → Numeric)

Categories:

Red

Blue

Green

	Red	Blue	Green
Red	1	0	0
Blue	0	1	0
Green	0	0	1

</"(Numeric →

One-Hot Encoding (Categorical → Numeric): شكل

جدول بيانات حقيقي (فصائل دم → One-Hot):

Patient	Blood Type	A	B	O
P1	A	1	0	0
P2	B	0	1	0
P3	O	0	0	1
P4	A	1	0	0

ثلاثة أعمدة بدل رقم واحد — ما كتبنا $A=1, B=2, O=3$ عمداً.

6.3 Text → Numerical

(غطينه بالقسم 2.4 — TF-IDF, BoW, embeddings. هذا أهم تحويل عند الدكتور.)

TF-IDF (Text → Numeric)

TF-IDF

weights

	Doc1	Doc2	
the	0.10	0.08	rare word → HIGH
cat	0.91	0.05	common word → LOW
dog	0.04	0.88	

شكل: TF-IDF (Text → Numeric) — الكلمة النادرة وزنها أعلى
(Numeric → الكلمة النادرة وزنها أعلى)

جدول بيانات حقيقي (مصفوفة Document–Term بأوزان TF-IDF):

ملاحظة	Doc2	Doc1	Term
شائعة → وزن منخفض	0.08	0.10	the
نادرة بـ Doc1 → وزن عالي	0.05	0.91	cat
نادرة بـ Doc2 → وزن عالي	0.88	0.04	dog

الجدول هو التمثيل الرقمي الذي ياكله النموذج — كل خلية = وزن الكلمة بالمستند.


6.4 Time Series → Numerical / → Sequence

- **Numerical** → نستخرج إحصائيات (mean, std, min/max, skewness) أو ميزات ترددية (Fourier/Wavelet) أو shapelets. النتيجة vector ثابت الطول.
- **Sequence (رمزي)**: نحول الأرقام لرموز. مثال الدكتور الحرفي للقلب:

Verbatim (Doctor — Week 02): "Instead of keeping raw heart rate values [75, 77, 80, 60, 58, 90], we can convert them into symbols like: [N, N, H, L, L, H] (where N = Normal, H = High, L = Low)."

Verbatim (Doctor — Week 02): "SAX Steps: Normalize the series (mean = 0, variance = 1). Divide series into equal-sized segments. Compute average value for each segment. Map averages into symbols using breakpoints."

Time-Series → Sequence Time-Series → Symbolic Sequence (SAX)



← سلسلة رمزية (SAX) "</p>
 </div>
 <div data-bbox="481 378 938 396" data-label="Section-Header">
 <h3>جدول بيانات حقيقي (Symbolic Sequence → Time-Series):</h3>
 </div>
 <div data-bbox="67 406 930 489" data-label="Table">
 <table>
 <tr>
 <th>Time</th>
 <th>1</th>
 <th>2</th>
 <th>3</th>
 <th>4</th>
 <th>5</th>
 <th>6</th>
 </tr>
 <tr>
 <td>Heart Rate</td>
 <td>75</td>
 <td>77</td>
 <td>80</td>
 <td>60</td>
 <td>58</td>
 <td>90</td>
 </tr>
 <tr>
 <td>Symbol</td>
 <td>N</td>
 <td>N</td>
 <td>H</td>
 <td>L</td>
 <td>L</td>
 <td>H</td>
 </tr>
 </table>
 </div>
 <div data-bbox="447 514 913 533" data-label="Text">
 <p>بدل الأرقام الخام، صارت رموز — أسهل لاكتشاف الأنماط والشذوذ.</p>
 </div>
 <div data-bbox="67 559 291 578" data-label="Section-Header">
 <h3>6.5 Image → Numerical</h3>
 </div>
 <div data-bbox="67 584 938 622" data-label="Text">
 <p>الصورة أساساً matrix من شدة البكسل (grayscale: 0=أسود، 255=أبيض؛ RGB: 3 قنوات). بدل كل بكسل، نستخرج vector → shape/texture/edges.</p>
 </div>
 <div data-bbox="67 638 297 656" data-label="Section-Header">
 <h3>6.6 Spatial → Numerical</h3>
 </div>
 <div data-bbox="77 663 938 682" data-label="Text">
 <p>إحداثيات مباشرة (long,lat)، أو مسافات لنقاط مرجعية، أو shape features (compactness,perimeter,area)، أو grid/raster.</p>
 </div>
 <div data-bbox="67 697 322 716" data-label="Section-Header">
 <h3>6.7 Sequence → Numerical</h3>
 </div>
 <div data-bbox="92 723 938 742" data-label="Text">
 <p>One-hot لكل رمز، أو k-mer counts (نكسر التسلسل لقطع طول k ونعدها — مفيد بـ DNA)، أو embeddings (DNA2Vec).</p>
 </div>
 <div data-bbox="123 770 938 794" data-label="Section-Header">
 <h2>★★ القسم 6.8 — Graph Embedding: Numerical → Graph (الأهم للفهم الأول)</h2>
 </div>
 <div data-bbox="400 807 938 826" data-label="Text">
 <p>هنا نحول الرسم البياني نفسه إلى أرقام علمود الخوارزميات. التعريف الحرفي:</p>
 </div>
 <div data-bbox="90 848 860 884" data-label="Text">
 <p>Verbatim (Doctor — Week 02): "A graph $G = (V, E)$ consists of nodes (V) and edges (E) that connect them."</p>
 </div>
 <div data-bbox="67 965 369 981" data-label="Page-Footer">
 <p>كلية علوم الحاسوب وتكنولوجيا المعلومات — جامعة واسط</p>
 </div>
 <div data-bbox="847 965 938 981" data-label="Page-Footer">
 <p>Page 19 of 26</p>
 </div>
 </div>

طرق:

- **Node-Level**: درجة العقدة (degree), clustering coefficient, (betweenness/closeness/eigenvector) centrality, PageRank. مثال الدكتور:

(Week 02 — Doctor) Verbatim: "Example" : Social network node → [0.3=clustering, 5=degree], [0.12=betweenness]

- **Edge-Level**: وزن الحافة, edge betweenness, تشابه العقدتين.
- **Graph-Level**: عدد العقد/الروابط, density = $2 / (|V|(|V|-1))$, diameter, متوسط clustering.


(Week 02 — Doctor) Verbatim: " $E / (|V|(|V|-1)) = \text{Density}$ "

- **Adjacency / Laplacian flattening**: نفرد مصفوفة الجوار لأرقام (أو نأخذ eigenvalues).
- **(Node2Vec / GNN) Graph Embedding**: نتعلم vectors كثيفة.

(Week 02 — Doctor) Verbatim: "Node2Vec / DeepWalk" : Random walks on the graph → treat as sentences → use Word2Vec to get node embeddings → Graph " : (Week 02 — Doctor) Verbatim " : sentences → Aggregate features from neighbors (GNNs) Neural Networks → node-level or graph-level → embeddings. Examples : GAT, GraphSAGE, GCN.

ارتباطه بالمحاضرة: الدكتور يذكر Node2Vec/GNN كحل لمشكلة "الخوارزميات تريد أرقام وال graph مو أرقام".

Graph Embedding Graph → Numeric (Graph Embedding)



→ "Numeric (Graph Embedding)"
شكل: Graph → Numeric (Graph Embedding)

جدول بيانات حقيقي (Numeric vector → Graph):

Node	Embedding (dense vector)
A	[0.21, 0.75, 0.43]

Node	Embedding (dense vector)
B	[0.19, 0.81, 0.39]
C	[0.24, 0.70, 0.51]
D	[0.22, 0.78, 0.44]

كل عقدة صارت متجه أرقام — النموذج يقدر يشتغل عليه.

★★★ القسم 6.9 — Converting Different Data Types INTO a Graph (النقطة اللي وقفت عندها)

هذا هو السبب الحقيقي لتشتتك: المحاضرة 2 كلها كانت "حوّل كل شي إلى أرقام" (Numerical → Graph). بس المحاضرة 3 فجأة قلبت الاتجاه: "بدل ما نحول كل شي أرقام، نمثّل العلاقات كـ graph". الدكتور سماها "Converting Different Data Types into a Graph". هذي نقطة التحول واللي ما فهمتها. كلام الدكتور الحرفي (وهذا اللي لازم تحفظه زين):

Verbatim (Doctor — Week 03): "Instead of converting everything into numerical data, relationships between objects can be represented using a graph."

Verbatim (Doctor — Week 03): "Suppose we have five patients. If two patients are sufficiently similar, we connect them. The nodes represent objects, and the edges represent similarity."

Verbatim (Doctor — Week 03): "A similarity graph can be created using a similarity or distance measure. For example: If $\text{distance}(P_1, P_2) < \text{threshold}$ → Connect P_1 and P_2 . The graph represents which objects are similar to each other."

Verbatim (Doctor — Week 03): "Applications: Clustering. Classification. Nearest-neighbor analysis. Outlier detection."

شنو يعني (What)?

بدل التمثيل الرقمي، نمثّل الأغراض (objects) كـ nodes و العلاقات بينها كـ edges. أشهر شكل: Similarity Graph (رسم التشابه) — نربط كل غرضين متشابهين بـ edge.


شلون يشتغل (How) — بالخطوات والمثال:

1. عندنا 5 مرضى، كل واحد عنده سمات رقمية (مثلاً العمر، الضغط، الكوليسترول).
2. نختار مقياس تشابه أو مسافة (مثلاً Euclidean distance على السمات).
3. لكل زوج (P_i, P_j) : إذا $\text{distance}(P_i, P_j) > \text{threshold}$ إذن نربطهم بـ edge.
4. النتيجة: graph يمثل أي مريض يشبه أي مريض.

شكل الرسم الناتج (بالكلمات): العقد P_1, P_2, P_3, P_4 متصلين ببعض ($P_1-P_2, P_2-P_4, P_4-P_3, P_3-P_1$) فيتشكل عنقود واحد، بينما P_5 عقدة معزولة ما انربطت بأحد لأن مسافتها عن الكل فوق الـ threshold.

Similarity Graph

Converting Data INTO a Graph — Similarity Graph



شكل: 5 — Similarity Graph مرضى، 4 عنقود + P5 معزول (outlier)

جدول بيانات حقيقي (5 مرضى + مسافات ← روابط):

Pair	Distance	?Connected
P1-P2	0.12	✓ (نفس العنقود)
P2-P4	0.18	✓
P4-P3	0.15	✓
P3-P1	0.20	✓
P5-الكل	0.95	✗ (معزول → outlier)

المسافة > threshold → ربط. P5 بعيدة عن الكل → ما انربتت → شذوذ.

- P1, P2, P3, P4 قريبين من بعض ← عنقود (cluster).
- P5 معزول (ما انربط بأحد) ← مرشح شذوذ (outlier) — وهذا يربطنا ببطاقة Anomaly Detection من القسم 2.1!

التطبيقات (ليش نسويها؟):

- **Clustering**: كل مكون متصل (connected component) = عنقود.
- **Classification**: نشر لصنف من العقد المعروفة لباقي العقد.
- **Nearest-neighbor analysis**: الجيران = العقد المتصلة.
- **Outlier detection**: العقدة المعزولة = شاذة.

الفكرة الجوهرية: التحويل لـ graph يعكس الاتجاه — هنا نحول إلى graph (من أي نوع بيانات)، بينما بالقسم 6.8 حولنا من graph إلى numbers. الدكتور يدّرس الاتجاهين لأن بعض الخوارزميات (community, spectral clustering, detection, k-NN على graph) تشتغل على البنية العلاقتية أحسن من المتجهات.

تحذير الدكتور (مهم للفهم):

Verbatim (Doctor — Week 03): "Data type conversion is useful, but it may result in information loss.

Example: Original ages: 21, 22, 39. After discretization: Adult, Adult, Adult. The exact ages have disappeared.

Therefore: A good conversion should preserve the important information needed for the mining task."

القسم 7 — التنظيف، التحجيم، والتخفيض

7.1 Data Cleaning (تنظيف البيانات)

Verbatim (Doctor — Week 02): "MCAR – Missing Completely at Random: The missingness has no relationship with the data (observed or unobserved)." **Verbatim (Doctor — Week 02):** "MAR – Missing at

Random: The missingness depends on observed data but not on the missing data itself." **Verbatim (Doctor**

— Week 02): "MNAR – Missing Not at Random: The missingness depends on the missing data itself."

المشاكل الشائعة: missing entries, incorrect entries (typos), inconsistent entries (تواريخ بصيغ مختلفة), outliers, redundancy (تكرار). **التعامل مع المفقود (Missing Data):** **MCAR** (Missing Completely at Random): عشوائي تماماً. - **MAR** (Missing at Random): يعتمد على قيم موجودة (الدخل مفقود أكثر عند الشباب). - **MNAR** (Missing Not at Random): يعتمد على القيمة المفقودة نفسها (أصحاب الدخل العالي يخفونه). **الاستراتيجيات:**

(Week 02 — Verbatim (Doctor with missing values. Column (row) Remove any record :Listwise Deletion" **values are missing in a 50%< with too many missing values. Useful if (columns) Remove attributes :Deletion** **column** - "column **:Deletion** : حذف الصفوف (listwise) أو الأعمدة (إذا <50% مفقود). - **Imputation** : تعبئة بـ mean/median/mode، أو KNN imputation، أو regression imputation، أو multiple imputation.


7.2 Normalization & Scaling (التحجيم والتطبيع)

Verbatim (Doctor — Week 02): "Min-Max Scaling: Rescales values to a fixed range, usually [0, 1]. Formula:

$x' = (x - x_{\min}) / (x_{\max} - x_{\min})$." **Verbatim (Doctor — Week 02):** "Z-Score Standardization: Centers the data at 0 and scales to unit variance. Formula: $x' = (x - \mu) / \sigma$."

ليش؟ الخوارزميات (neural nets, SVM, KNN) تفترض الميزات بنفس المقياس؛ بدونه الميزة الكبيرة تسيطر. - Min-Max **:Scaling** $(x_{\min} - x_{\max}) / x' = (x - x_{\min})$ → مدى [0,1]. حساس للـ outliers. **(Standardization) Z-Score** $(x - \mu) / \sigma =$ → متوسط 0 وانحراف 1. أقل حساسية للـ outliers. **Max Abs / Robust / Decimal Scaling** : بدائل حسب الحالة.

Scaling — Min-Max vs Z-Score



شكل: التحجيم — Min-Max مقابل Z-Score

جدول بيانات حقيقي (Scaling على ميزة واحدة):

Raw	Min-Max (0–1)	Z-Score
10	0.00	-1.22
20	0.50	0.00
30	1.00	1.22

بدون التحجيم، القيمة 30 تسيطر على الخوارزمية — بعده كل الميزات بمدى متقارب.

7.3 Transformation & Data Reduction (تخفيض وتحويل)

Verbatim (Doctor — Week 02): "Sampling: Selecting a subset of data to represent the entire dataset."

Verbatim (Doctor — Week 02): "Filter methods: Evaluate features using statistical measures (correlation, chi-square). Wrapper methods: Use ML algorithms to test feature subsets (e.g., recursive feature elimination). Embedded methods: Feature selection is part of model training (e.g., Lasso regression)."

- **Sampling:** أخذ عيّنة ممثلة (streams, reservoir, cluster, systematic, stratified, random).
- **Feature Subset Selection (3 أنواع — مهمة جداً):**
- **Filter:** مقاييس إحصائية (mutual information, chi-square, correlation) — سريع، يتجاهل التفاعلات.
- **Wrapper:** نستخدم النموذج لتقييم الأنواع الفرعية (RFE) — أدق بس مكلف حسابياً.
- **Embedded:** الاختيار يصير أثناء التدريب (Random Forest importance, Lasso/L1) — فعال.
- **Dimensionality Reduction بالـ Axis Rotation:**
- **PCA:** إسقاط على مكونات رئيسية تلتقط أقصى تباين (orthogonal). خطوات الدكتور:

(Week 02 — Doctor) Verbatim: "PCA Steps: Standardize the data (mean = 0, variance = 1). Compute the covariance matrix. Compute eigenvectors and eigenvalues. Sort eigenvectors by eigenvalues. principal components choose top-k components. Project data onto these → eigenvectors".

• **SVD**: $A = U \Sigma V^T$, يقلل الأبعاد. أساس LSA بالنصوص.

(Week 02 — Doctor) Verbatim: "SVD Factorizes the data matrix A into three matrices: $A = U \Sigma V^T$ ".

- **Dimensionality Reduction** بال **Type Transformation**
- **Haar Wavelet**: متوسط والفرق بين قيم متجاورة → ضغط.
- **MDS**: يحافظ على المسافات الزوجية للتصور.
- **Spectral Graph Embedding**: eigenvectors للمصفوفة Laplacian → تمثيل رقمي لل graph (يرجع لنفس موضوع 6.8).

خاتمة — ملخص سريع للمراجعة

1. عائلتان: Nondependency (كل سجل وحده) و Dependency (بينهم خيوط وقت/ترتيب/بنية).
2. 8 أنواع: 4 + 4 كما فصلنا.
3. **Data Preparation**: 6 خطوات.
4. **Feature Extraction**: اشتقاق سمات أفضل من الخام.
5. **Portability**: جدول التحويل (استوعب اتجاهين: numeric → و graph →).
6. نقطة التحول: Similarity Graph = Converting INTO a Graph (بنبي edges بالمسافة > threshold) — هذا اللي وقفت عنده.
7. **Cleaning / Scaling / Reduction**: المكمل الإجرائي.

نصيحة للدكتور: هو "يوزع بحث" — فكل كلمة بسمتها (ARIMA, PageRank, TF-IDF, SAX, ...) هي بطاقة بحث بهالوثيقة. راجع البطاقة قبل أي محاضرة جاية.

Retrieval Set (بطاقات للمراجعة السريعة — لامتحان)

RS-01 ما الفرق بين Nondependency و Dependency data؟

Nondependency: كل سجل مستقل (مثل جدول مرضى). Dependency: القيم بينها علاقة/وقت/بنية (مثل سلسلة زمنية).

RS-02 اذكر ال 4 أنواع من كل عائلة.

Nondependency: Quantitative Multidimensional, Categorical & Mixed, Binary & Set, Text. Dependency: Time-Series, Discrete Sequences, Spatial, Network & Graph.

RS-03 لماذا نستخدم One-Hot بدل $A=1, B=2, O=3$ ؟

لأن $A=1, B=2$ يخلق ترتيباً عددياً غير موجود بالفئات الاسمية (nominal)، فالنموذج يفهمه غلط.

RS-04 اشرح TF-IDF بكلمتين.

يوزن الكلمة ب تكرارها بالمستند $\times$ ندرتها بال corpus؛ يرفع المهم ويخفض التافه ("the").

RS-05 ما هو Similarity Graph ولماذا نبنيه؟

نمّثل الأغراض nodes والعلاقات edges؛ نربط كل زوج مسافته $> \text{threshold}$. يفيد outlier, NN, classification, clustering, detection.

RS-06 اذكر 3 أنواع Feature Selection.

(Filter إحصاء)، Wrapper (نموذج يقيّم)، Embedded (أثناء التدريب ك Lasso).