

WEEK 2 & 3

أنواع البيانات وقابلية النقل (كيف نفهم البيانات ونهيئها للتنقيب)

فهمي للملزمة — تصنيف أنواع البيانات (عائلتان، ثمانية أنواع) وتجهيزها، ثم استخراج السمات وقابلية نقل الأنواع حتى تصبح جاهزة للتنقيب

ملاحظة مهمة قبل تبدأ: الدكتور ما يعلم — هو يوزع بحث. في هالنسخة v4.2، كل اقتباس إنكليزي معلّم بـ $W_n P_x$ (الملزمة n، الصفحة x) هو حرفياً من كلام الدكتور بالمصادر (ملفات الـ docx الأصلية) — ما انجم من راسي. تحته مباشرة الشرح العربي الفهمي. باقي الملزمة كله عربي (والمصطلحات الإنكليزية كما هي بالمحاضرة). قراها كأنك باحث: كل قسم فيه بطاقة بحث تحتها ثلاثة خطوط — **شنو هو، شلون يشتغل** (مع مثال)، وارتباطه بالمحاضرة.

القسم 1 — التصنيف الكبير: عائلتان من البيانات

قبل أي شي، الدكتور ي divide البيانات لـ عائلتين (هذا أساس كل المحاضرة، وغالباً يسأل عنه). هما التصنيف الحرفي من كلامه:

W2 P1 "Nondependency-Oriented Data → Data where values are independent of each other."

W2 P1 "Dependency-Oriented Data → Data where values are related or dependent on each other, often involving order, time, or structure."

العائلة	المعنى الحرفي	شلون نعرفها؟
Nondependency-Oriented (غير معتمدة على بعض)	القيم مستقلة، كل سجل وحده ما يعتمد على الثاني	جدول مرضى: العمر والضغط والكوليسترول — كل مريض رقمه بحد نفسه
Dependency-Oriented (معتمدة على بعض)	القيم بينها علاقة / ترتيب / وقت / بنية	سعر السهم عبر الأيام — اليوم يعتمد على الأمس

حفظ سريع: Nondependency = "كل واحد بحده". Dependency = "بينهم خيوط" (وقت، ترتيب، أو بنية شبكية).

الشرح الفهمي: الدكتور يفتح المحاضرة بالخطوة — يقسم البيانات أولاً. العائلة الأولى "ما يهمها الثاني": كل صف بجدول يقف لحاله. العائلة الثانية "بين عناصرها خيوط": ترتيب، أو وقت، أو بنية شبكية (زي الروابط بـ graph). هالفارق هو اللي يحدد أي خوارزمية نستخدم.

القسم 2 — العائلة الأولى: Nondependency-Oriented (4 أنواع)


2.1 Quantitative Multidimensional Data (بيانات كمية متعددة الأبعاد)

W2 P1 "Definition: Data represented by multiple numerical attributes."

W2 P1 "Characteristics: Continuous values (real numbers). Can be represented in a vector form. Use cases: Regression, clustering, anomaly detection."

التعريف: بيانات تمثل بأكثر من سمة رقمية (vector). **مثال الدكتور:** مجموعة طبية فيها Age, Blood Pressure, Cholesterol, BMI. **الخصائص:** قيم مستمرة (أرقام حقيقية)، تمثل على شكل متجه (vector)، استخداماتها: Regression, anomaly detection, clustering.

Quantitative Multidimensional — numeric vector



: Age=25, BP=80, Chol=190, BMI=22 → [25,80,190,22]

شكل: بيانات كمية متعددة الأبعاد — كل سجل = متجه أرقام

جدول بيانات حقيقي (مجموعة طبية — كل صف متجه أرقام):

Patient	Age	Blood Pressure	Cholesterol	BMI
P1	25	120	190	22.1
P2	41	135	210	26.4
P3	33	118	175	23.0
P4	58	150	240	29.8

كل صف = نقطة بـ 4 أبعاد، مثلاً $P1 = [25, 120, 190, 22.1]$.

بطاقة بحث: Regression (الانحدار)

- **شئو هو:** عائلة من النماذج تحاول تتنبأ بقيمة رقمية مستمرة من مدخلات. الفرق الجوهرى عن التصنيف (classification): التصنيف يجاوب "نعم/لا" أو "فئة"، الانحدار يجاوب "كم؟" (سعر، عمر، ضغط).
- **شئون يشتغل (مثال):** لو عندك أعمار وضغط لمرضى، تبني خط $BP \approx a \cdot Age + b$. تعطيه عمر جديد فيتوقع الضغط. أبسط نوع Linear Regression (أقل مربعات). أنواع ثانية: Lasso, Ridge, Polynomial.
- **ارتباطه بالمحاضرة:** هذا النوع (Quantitative Multidimensional) هو "الوقود" الطبيعى للانحدار لأنه أرقام متجهة. لهذا الدكتور خليه ضمن الـ use cases.

بطاقة بحث: Clustering (التجميع)

- **شئو هو:** تقسيم البيانات لـ groups بحيث اللي داخل المجموعة الوحدة يكونون متشابهين، وكل مجموعة تختلف عن الثانية — **بدون ما نعرف مقدماً أسماء المجموعات** (unsupervised).
- **شئون يشتغل (مثال):** K-Means: تختار K مركز عشوائى، توزع كل نقطة لأقرب مركز، تحسب مراكز جديدة، تكرر لحد يستقر. النتيجة: عناقيد.
- **ارتباطه بالمحاضرة:** ينطبق على البيانات الكمية لأننا نحتاج "مسافة" بين النقاط (Euclidean distance) — وهذا متوفر بس لما البيانات رقمية متجهة.

بطاقة بحث: Anomaly Detection (كشف الشذوذ)

- **شئو هو:** اكتشاف النقاط اللي "ما تطابق" باقي البيانات — اللي هي نادرة أو غريبة (تسمى outliers أو anomalies).
- **شئون يشتغل (مثال):** قيمة ضغط = 300 تعتبر شذوذ لأنها بعيدة جداً عن توزيع باقي المرضى. طرق: statistical (z-score)، أو clustering (نقطة ما انتمت لأي عنقود)، أو Isolation Forest.
- **ارتباطه بالمحاضرة:** يظهر مرتين بالمحاضرة (هنا، وفي Time-Series) لأن الشذوذ يهم بكل أنواع البيانات — طبي (مرض)، مالي (احتيال)، حساس للوقت (إنذار مبكر).

2.2 Categorical and Mixed Attribute Data (بيانات تصنيفية ومختلطة)

W2 P1 "Categorical Data: Attributes represent discrete categories/labels."

W2 P1 "Mixed Attribute Data: Contains both numerical and categorical variables."

W2 P1 "Challenges: Need special encoding techniques (e.g., one-hot encoding). Distance metrics are harder to define compared to numerical data."

التعريف: Categorical = سمات تمثل تصنيفات منفصلة (Red/Green/Blue، أو Kenya/India/USA). Mixed = تجمع رقمي + تصنيفي (مثال: {21=Age, Male=Gender, GPA=3.4, CS=Major}). **التحدي:** نحتاج تقنيات ترميز خاصة (مثل one-hot)، وقياس المسافة أصعب من الرقمي.

Categorical & Mixed — labels + numbers

Red

Green

Blue

Mixed record:

Age = 21 (numeric)

GPA = 3.4 (numeric)

Gender = Male (category)

Major = CS (category)

شكل: بيانات تصنيفية ومختلطة — فئات + أرقام

جدول بيانات حقيقي (سجلات طلاب — مختلطة رقمي + تصنيفي):

Student	Age	Gender	GPA	Major
S1	21	Male	3.4	CS
S2	22	Female	3.1	Math
S3	20	Male	2.9	CS
S4	23	Female	3.7	Physics

العمود Gender و Major تصنيفي (nominal)؛ الباقي رقمي. هذا بالضبط اللي يحتاج one-hot.

بطاقة بحث: One-Hot Encoding (الترميز الساخن الواحد)

- **شنو هو:** لكل فئة نسوي عمود ثنائي (0/1). اللون {Green, Blue, Red} يصير 3 أعمدة: $[1,0,0]=\text{Red}$ ، $[0,1,0]=\text{Blue}$ ، $[0,0,1]=\text{Green}$.
- **شلون يشتغل:** المريض P1 بفصيلة A يصير $[1,0,0]$ ، P2 بفصيلة B يصير $[0,1,0]$. الـ 1 يعني "هذا الفئة موجود"، الـ 0 "غايب".
- **ليش ما نكتب $A=1, B=2, O=3$ ؟** لأن هذا يوهم النموذج إنه فيه ترتيب عددي (B أكبر من A؟ ما منطق). فصائل الدم nominal ما بينها ترتيب، ف one-hot هو الصح للـ nominal.
- **ارتباطه بالمحاضرة:** هذا هو الحل لمشكلة "الخوارزميات تريد أرقام" مع البيانات التصنيفية. تذكره دائماً كجسر $\text{Numeric} \rightarrow \text{Categorical}$ (راجع نشوفه بالقسم 6).

بطاقة بحث: Distance Metrics for Categorical (قياس المسافة للتصنيفي)

- **شنو هو:** كيف "نقيس تقارب" سجلين فيهم حقول تصنيفية. بالرقمي نستخدم Euclidean، بالتصنيفي نستخدم مثلاً Hamming distance (عدد الحقول المختلفة) أو Jaccard.
- **شلون يشتغل:** سجلان {CS, Male} و {Math, Male} — يختلفون بـ حقل واحد من 2 → مسافة 0.5.
- **ارتباطه بالمحاضرة:** الدكتور ذكر إن "المسافة أصعب تعريفها" للتصنيفي — لأن مفهوم "البعد" ما ينطبق مباشرة، فلازم نحول أو نستخدم مقاييس بديلة.

2.3 Binary and Set Data (بيانات ثنائية وبيانات مجموعات)

W2 P1 "Binary Data: Attributes with only two possible values {0,1} or {True, False}."

W2 P1 "Set Data: Each object described by a set of items."

W2 P2 "Applications: Association rule mining (e.g., Market Basket Analysis). Recommendation systems."

التعريف: Binary = قيمتين بس {0,1} أو {False,True} (مثال: Smoker نعم/لا، Loan Defaulted نعم/لا). Set = كل غرض يوصف بـ مجموعة عناصر (مثال: سلة تسوق {Eggs, Bread, Milk}). **التطبيقات:** Association rule mining, recommender systems.

Binary & Set — 0/1 matrix + item set

Smoker	Loan	Fraud
1	0	0
0	1	1
1	0	1
0	0	0

Market Basket

- Milk
- Bread
- Eggs

شكل: بيانات ثنائية (مصفوفة 0/1) وبيانات مجموعات (سلة)

جدول بيانات حقيقي (مصفوفة شرائية — كل صف binary set):

Customer	Milk	Bread	Eggs	Cheese
C1	1	1	1	0
C2	0	1	0	1
C3	1	0	1	0
C4	0	0	0	0

سلة C1 = {Eggs, Bread, Milk}. خوارزمية Apriori تبحث الأنماط بين هالسلات.

بطاقة بحث: Association Rule Mining / Market Basket Analysis (تنقيب القواعد الارتباطية / تحليل سلة التسوق)

- **شنو هو:** اكتشاف قواعد من نوع "إذا اشترى X فعالباً يشتري Y" من بيانات المعاملات. أشهر مثال: "حفاضات → بيرة" (أسطورة Walmart).
- **شلون يشتغل:** خوارزمية Apriori: تعدّ تكرار العناصر المفردة، ثم الأزواج، ثم الثلاثيات، وتصفية بالـ support (نسبة الظهور) و الـ confidence (احتمال Y إذا ظهر X) و الـ lift.
- **ارتباطه بالمحاضرة:** بيانات الـ Set (السلة) هي الوقود الطبيعي لها — كل سلة = set، ونبحث الأنماط بين السلات.

بطاقة بحث: Recommendation Systems (أنظمة التوصية)

- **شنو هو:** نظام يقترح عناصر (فيلم، منتج) بناءً على سلوك المستخدم. نوعان رئيسيان: collaborative filtering (بناءً على مستخدمين مشابهين) و content-based (بناءً على خصائص العنصر).
- **ارتباطه بالمحاضرة:** يذكره الدكتور لأنه يأكل بيانات ثنائية/مجموعات (user-item matrix مليون 0/1 = شاف/ما شاف).

2.4 Text Data (بيانات نصية) — ★ أهم نوع عند الدكتور


W2 P2 "Definition: Data stored as unstructured textual information."

W2 P2 "Text is unstructured and must be converted into numerical form (Bag of Words, TF-IDF, word embeddings)."

W2 P2 "Applications: Sentiment analysis, topic modeling, chatbots, search engines."

التعريف: بيانات مخزنة كمعلومات نصية غير مهيكلة (tweets, reviews, articles, emails). **التحدي:** النص غير مهيكل ولا بد نحوله لأرقام (word embeddings, TF-IDF, Bag of Words). **التطبيقات:** Sentiment analysis, topic modeling, chatbots, search engines.

Text — unstructured → numeric vector



→ تحويل لأرقام </>
شكل: نص غير مهيكّل → تحويل لأرقام

جدول بيانات حقيقي (مستندات + تمثيلها):

Doc	Text (raw)	Bag-of-Words vector (cat, dog, mat, log, sat, the, on)
D1	"The cat sat on the mat"	[1, 0, 1, 0, 1, 2, 1]
D2	"The dog sat on the log"	[0, 1, 0, 1, 1, 2, 1]

النص الخام ما يقره النموذج — نحوله لأرقام (BoW/TF-IDF) أولاً.

بطاقة بحث: Bag of Words (BoW — حقيبة الكلمات)

- **شئو هو:** تمثيل النص كـ vector من عدد مرات كل كلمة.

W2 P7 "Represents text as a vector of word counts." **W2 P7** "Vocabulary: [cat, dog, mat, log, sat, the, on] — Sentence 1 → [1, 0, 1, 0, 1, 2, 1]"

- **شلون يشتغل (مثال):**
- ج1: "The cat sat on the mat" — ج2: "The dog sat on the log"
- القاموس: [cat, dog, mat, log, sat, the, on]
- ج1 → [1, 0, 1, 0, 1, 2, 1] (the ظهر مرتين)
- ج2 → [0, 1, 0, 1, 1, 2, 1]
- **المشكلة:** يتجاهل ترتيب الكلمات ومعناها (cat و dog يهمشون بنفس البعد). وهذا يؤدي لـ **sparsity** (أغلب الخانات صفر).

بطاقة بحث: TF-IDF (Inverse Document Frequency – Term Frequency) ★★ — اللي سألت عنه

- **شنو هو:** وزن إحصائي لكل كلمة داخل مستند ضمن مجموعة مستندات (corpus). يكافئ الكلمات المهمة بوزن عالي، والكلمات الشائعة (مثل "the", "is") بوزن منخفض. هو **تطوير** على BoW يحل مشكلة الكلمات التافهة.

W2 P7 " $TF-IDF(t,d) = TF(t,d) \times IDF(t)$ " **W2 P8** "Better than BoW because it reduces the impact of frequent but uninformative words."

- **شلون يشتغل (المعادلة والخطوات):**
- $TF(t,d)$ = عدد مرات الكلمة t بالمستند d ÷ مجموع كلمات d .
- $IDF(t) = \log\left(\frac{N}{1 + df(t)}\right)$ حيث N = عدد المستندات، $df(t)$ = عدد المستندات اللي تحتوي t .
- $TF-IDF(t,d) = TF(t,d) \times IDF(t)$.
- **مثال:** مستندان — د1 "the cat sat"، د2 "the dog ran". كلمة "the" بكليهما $df=2$ ، $N=2 \rightarrow IDF = \log(2/2) = 0$ بس بد1 $IDF = \log(2/2) = 0$ لا، بالصيغة $1 + \log(2/2) = 1$ بالمقام تطلع موجبة ومرتفعة $\rightarrow$ كلمة "cat" ضعيف. وزن "the" $\rightarrow$ سلبي صغير $\approx \log(2/3)$.
- **ليش أحسن من BoW:** يقلل تأثير الكلمات المتكررة لكن غير المفيدة. "cancer" بورقة طبية أهم من "the" رغم إن "the" أكثر عددًا.

بطاقة بحث: Word Embeddings (تضمين الكلمات — FastText , GloVe , Word2Vec)

- **شنو هو:** تمثيل كل كلمة كـ vector كثيف (dense) بأبعاد قليلة (مثل 100–300)، بحيث الكلمات القريبة بالمعنى يكون لها vectors قريبة بالفضاء.

W2 P8 "Advantage: Captures semantic relationships ('king – man + woman $\approx$ queen')."

- **شلون يشتغل (مثال الخرافة المعروفة):** $queen \approx woman + man - king$. النموذج التقط العلاقة الدلالية.
- Word2Vec يتعلم من السياق (الكلمات اللي تطلع جنب بعض)، GloVe من مصفوفة التشارك الإحصائي.
- **ارتباطه بالمحاضرة:** بديل أعمق من BoW/TF-IDF لأنه يفهم المعنى والسياق، يستخدم بـ chatbots والترجمة.

بطاقة بحث: Sentiment Analysis (تحليل المشاعر)

- **شنو هو:** تصنيف النص حسب المشاعر (إيجابي/سلبي/محايد). تطبيق كلاسيكي: مراجعات الأفلام.
- **شلون يشتغل:** نحول المراجعة إلى TF-IDF أو embeddings $\rightarrow$ نمررها لنموذج (BERT أو Bayes Naïve) يصنفها.
- **ارتباطه بالمحاضرة:** من تطبيقات Text $\rightarrow$ Numeric؛ الدكتور يذكره كدليل عملي إن تحويل النص لأرقام يقود لمهام حقيقية.

بطاقة بحث: Topic Modeling (نمذجة المواضيع)

- **شئو هو:** اكتشاف "مواضيع مخفية" داخل مجموعة وثائق (مثال: أخبار مقسمة لرياضة/سياسة/اقتصاد بدون تسمية مسبقة). أشهر خوارزمية: LDA (Latent Dirichlet Allocation).
- **ارتباطه بالمحاضرة:** تطبيق نصي يعتمد على التمثيل الرقمي للوثائق.

بطاقة بحث: Search Engines & Chatbots

- **Chatbots:** نظام يفهم ويرد على النص. يعتمد على embeddings/transformers (BERT/GPT) لتحويل سؤال المستخدم لنص "قابل للمعالجة".
- **Search Engines:** تحول استعلامك والصفحات لأرقام (sentence embeddings) وتقارن التشابه. الدكتور يذكرها لأنها أضخم تطبيق عملي لـ Numeric → Text.

القسم 3 — العائلة الثانية: Dependency-Oriented (4 أنواع)


3.1 Time-Series Data (بيانات سلاسل زمنية)

W2 P2 "Definition: A sequence of values recorded over time."

W2 P2 "Characteristics: Temporal dependency (past values influence future values). Often analyzed using ARIMA, LSTMs, Transformers. Applications: Forecasting, anomaly detection."

التعريف: سلسلة قيم مسجلة عبر الزمن (أسعار أسهم، طقس، إشارات ECG). **الخصائص:** اعتماد زمني (الماضي يؤثر بالمستقبل). تُحلل بـ ARIMA, LSTMs, Transformers. **التطبيقات:** Forecasting, anomaly detection.

Time-Series — values across time



example: stock price / ECG signal / temperature

شكل: سلسلة زمنية — قيم عبر الزمن

جدول بيانات حقيقي (سعر سهم عبر 8 أيام):

Day	1	2	3	4	5	6	7	8
Price	100	102	99	105	103	107	110	108

الترتيب مهم: 100→102→99 له معنى، ما يصير نعيد ترتيبه عشوائي.

بطاقة بحث: ARIMA / LSTM / Transformers

- **ARIMA** (AutoRegressive Integrated Moving Average): نموذج إحصائي كلاسيكي للتنبؤ يعتمد على القيم السابقة والفروق بينها.
- **LSTM** (Long Short-Term Memory): نوع من الشبكات العصبية المتكررة (RNN) "يتذكر" السياق الطويل — ممتاز للسلاسل الزمنية.
- **Transformers** (مثل BERT/GPT لكن للزمن): أحدث نماذج، تلتقط الاعتماديات بعيدة المدى.
- **ارتباطه بالمحاضرة:** الدكتور يذكرها لأن Time-Series تحتاج نماذج "تفهم الترتيب" — عكس ال Quantitative اللي كل صف وحده.

3.2 Discrete Sequences and Strings (سلاسل رموز منفصلة)

W2 P2 "Definition: Data represented as sequences of discrete symbols."

W2 P2 "Challenges: Pattern matching, alignment, and subsequence analysis."

التعريف: تسلسل رموز منفصلة (DNA: ATCG, clickstreams: سلسلة صفحات). **التحدي:** alignment, pattern matching, تحليل الأنظمة الفرعية. **التطبيقات:** Bioinformatics, web usage mining, NLP.

Discrete Sequence — ordered symbols



شكل: سلسلة رموز منفصلة — ترتيب مهم

جدول بيانات حقيقي (سلاسل منفصلة):

ID	Type	Sequence
S1	DNA	A → T → C → G → A → C → G
S2	Clickstream	Home → Search → Product → Cart
S3	DNA	A → T → G → G → A → C → T

تبديل رمز واحد يغير المعنى (مثل الطفرة بالـ DNA) — لذلك الترتيب أساسي.

بطاقة بحث: Pattern Matching / Alignment (مطابقة الأنماط / المحاذاة)

- **شئو هو:** إيجاد تشابه بين تسلسلين (مثل محاذاة تسلسلين DNA لاكتشاف طفرة). أدوات: Wunsch–Needleman, BLAST.
- **ارتباطه بالمحاضرة:** التحدي هنا هو "المسافة" بس، بل "الترتيب مهم" — فلابزم خوارزميات تسلسل لا خوارزميات جدول.


3.3 Spatial Data (بيانات مكانية)

W2 P2 "Definition: Data representing objects in a spatial or geographical context."

W2 P3 "Challenges: Spatial autocorrelation (nearby objects are more related)."

التعريف: بيانات بسياق جغرافي/مكاني (خرائط، صور أقمار، إحداثيات lat/long). **التحدي:** Spatial autocorrelation (الأشياء القريبة مكانياً أكثر ارتباطاً). **التطبيقات:** GIS، مراقبة المرور، النمذجة البيئية.

Spatial — coordinates on a grid



lat/long
32.50, 45.82

شكل: بيانات مكانية — إحداثيات على شبكة

جدول بيانات حقيقي (مواقع مستشفيات — lat/long):

Hospital	Latitude	Longitude	Type
H1	32.50	45.82	General
H2	32.48	45.85	Children
H3	32.55	45.79	Cardiac
H4	32.46	45.90	General

نحسب "المسافة" بينها بالإحداثيات — أقرب مستشفى = الأهم للتحليل المكاني.

بطاقة بحث: Spatial Autocorrelation (الارتباط الذاتي المكاني)

- **شنو هو:** مبدأ "القريب من القريب أقرب" — مدينة تشبه جيرانها أكثر من مدينة بعيدة. يقاس بـ Moran's I.
- **ارتباطه بالمحاضرة:** هذا يكسر فرضية "كل سجل وحدة" (independence) — وبالتالي يصنفها الدكتور Dependency.


3.4 Network and Graph Data (شبكات ورسوم بيانية) — ★★ مهم جداً ومرتبطة بنقطة توقفك

W2 P3 "Definition: Data represented as nodes and edges."

W2 P3 "Characteristics: Strongly structured data. Requires graph algorithms (PageRank, community detection, Graph Neural Networks)."

التعريف: بيانات ممثلة بـ nodes (عقد) و edges (روابط). مثال: Facebook (المستخدمون = nodes، الصداقة = edges)، شبكات الاقتباس. **الخصائص:** بيانات "بنية قوية"، تتطلب خوارزميات رسوم (PageRank, community detection, GNN). **التطبيقات:** تحليل التواصل الاجتماعي، كشف الاحتيال، recommender systems.

Network & Graph — nodes + edges



شكل: شبكة/رسم بياني — عقد + روابط

جدول بيانات حقيقي (شبكة تواصل — قائمة روابط):

Edge	From (node)	To (node)	Relation
e1	Ahmed	Sara	friend
e2	Sara	Omar	friend
e3	Omar	Ahmed	friend
e4	Lina	Omar	colleague

الجدول يحتوي عقد (From/To) وروابط — هذا تمثيل "edge list" لـ graph.

بطاقة بحث: PageRank

- **شنو هو:** خوارزمية جوجل لترتيب الصفحات: العقدة "مهمة" إذا ربطت بها عقد مهمة. تعطي كل node درجة أهمية.
- **ارتباطه بالمحاضرة:** مثال على "قياس أهمية node" داخل graph — راح نحتاجه بالقسم 6 (Numeric → Graph).

بطاقة بحث: Community Detection (كشف المجتمعات)

- **شنو هو:** تقسيم graph لمجموعات (communities) فيها روابط كثيفة داخلياً وخفيفة خارجياً. خوارزميات: Louvain, Newman–Girvan.
- **ارتباطه بالمحاضرة:** يظهر كتطبيق وتكتنية cluster لكن على graphs بدل نقاط إحداثيات.

بطاقة بحث: Graph Neural Networks (GNN — شبكات عصبية رسومية)

- **شنو هو:** شبكات عصبية "تتعلم" من بنية graph نفسها (لكل node تجمع معلومات جيرانها). أمثلة: GCN, GAT, GraphSAGE.
- **ارتباطه بالمحاضرة:** الطريقة الحديثة لتحويل graph → numeric embeddings (نرجع لها بالقسم 6).

القسم 4 — تجهيز البيانات (Data Preparation) — 6 خطوات

هذا إجرائي (مو بحثي)، الدكتور يذكره كـ pipeline. الست خطوات (بالترتيب غالباً) — بالكلام الحرفي للدكتور:

W2 P4 "Data Collection – Gathering data from multiple sources (databases, files, APIs, sensors, etc.)."

W2 P4 "Data Cleaning – Handling missing values, removing duplicates, correcting errors, and resolving inconsistencies."

W2 P4 "Data Integration – Combining data from different sources into a single coherent dataset."


W2 P4 "Data Transformation – Converting data into a consistent format (e.g., encoding categorical variables, normalization, scaling)."

W2 P4 "Data Reduction – Reducing the size/dimensionality of data by removing irrelevant features or aggregating values."

W2 P4 "Data Splitting – Dividing data into training, validation, and test sets (in machine learning tasks)."

1. **Data Collection** — جمع البيانات من مصادر (قواعد، ملفات، APIs، sensors).
2. **Data Cleaning** — معالجة القيم المفقودة، إزالة المكرر، تصحيح الأخطاء، حل التناقضات. (نفسها بالقسم 7)
3. **Data Integration** — دمج بيانات من مصادر مختلفة بـ dataset واحد متماسك.
4. **Data Transformation** — تحويل لصيغة متسقة (scaling, normalization, encoding).
5. **Data Reduction** — تقليل الحجم/الأبعاد بحذف سمات غير مهمة أو تجميع قيم. (نفسها بالقسم 7)
6. **Data Splitting** — تقسيم لـ training / validation / test (بمهام ML).

Data Preparation



Data Preparation pipeline (6–7 steps before modeling)

شكل: خطوة تجهيز البيانات (pipeline)

كل خطوة تأخذ مخرجات السابقة — هذا هو "الأنبوب" قبل ما تدخل البيانات للنموذج.

لماذا مهم؟ (بكلام الدكتور الحرفي): **W2 P4** "Improves (removes errors and inconsistencies) Ensures accuracy" **W2 P4** "Efficiency (organized data is faster to process) Enhances model performance (clean, balanced, and relevant) Supports better decision-making (reliable insights come from well-) (data leads to better predictions) (prepared data)".

القسم 5 — استخراج السمات (Feature Extraction)

W3 P1 "Feature extraction is the process of creating new features from existing data to represent its important characteristics in a form suitable for data mining or machine learning algorithms."

W3 P1 "Instead of giving the complete image directly to a traditional algorithm, we can represent it using useful features."

شئو هو: اشتقاق سمات جديدة "أكثر إفادة" من البيانات الخام لتحسين التحليل/النموذج — بدل استخدام الخام مباشرة. **ليش مهم:** الخام معقد/مزعج؛ يقلل الأبعاد؛ يظهر الأنماط؛ يحسّن الدقة. **أمثلة من المحاضرة:** - **من صورة:** استخراج edges/textures/color histograms أو deep embeddings (من طبقات CNN). مثال: من صورة سرطان ثدي نستخرج shape و texture. - **من نص:** embeddings (BoW, TF-IDF, BERT, Word2Vec). مثال: استخراج كلمات مفتاحية من ملاحظات طبية. - **صوت/إشارة:** MFCC, amplitude, frequency. مثال: كشف murmur بالقلب من ECG. - **من جدول:** سمات مشتقة مثل BMI = height²/weight، أو "فئة العمر" من العمر الخام.

مكانه بال **pipeline**: Collection → Cleaning → Integration → Transformation → **Feature Extraction** → Splitting → Reduction

القسم 6 — قابلية نقل نوع البيانات (Data Type Portability) ★★ الضعف الأساسي

هذا قلب المحاضرة 2 و 3. التعريف الحرفي من الدكتور:

W3 P3 "Data Type Portability means converting data from one representation or type into another representation so that it can be processed by a data mining algorithm."

المعنى: تحويل البيانات من تمثيل لنوع إلى تمثيل آخر علمود الخوارزمية تقدر تعالجه.

العملية العامة: أنواع بيانات مختلفة → تحويل → تمثيل مناسب → خوارزمية تنقيب.

الدكتور يذكر قائمة التحويلات الشائعة (بكلامه):

W3 P4 "Numerical → Categorical: Discretization. Categorical → Numerical: Encoding. Text → Numerical: Vectorization. Time Series → Sequence: Symbolic representation. Time Series → Numerical features: DFT / DWT or feature extraction. Image → Numerical features: Feature extraction. Graph → Numerical representation: Graph embedding. Any data type → Graph: Similarity graph."

الجدول المرجعي الشامل (من المحاضرة 3 — احفظه)

من (From)	إلى (To)	التقنية
Numerical	Categorical	Discretization (تقطيع)
Categorical	Numerical	One-Hot Encoding
Text	Numerical	Vectorization (BoW / TF-IDF / embeddings)
Time Series	Numerical	Feature extraction (DFT/DWT)
Time Series	Sequence	Symbolic representation (SAX)
Image	Numerical	Feature extraction
Sequence	Numerical	Sequence encoding
Spatial	Numerical	Distance / shape features

من (From)	إلى (To)	التقنية
Graph	Numerical	Graph embedding
أي نوع	Graph	Similarity graph

انتبه للسطرين الأخيرين — هما الاتجاهين المختلفين اللي الدكتور قفز بينهم وهذا سبب تشتتك (نفصل تحت).

6.1 Discretization: Categorical → Numerical (التقطيع)


W2 P5 "Discretization is the process of converting continuous numeric data into discrete categorical data by dividing the range of values into intervals (bins)."

W2 P6 "Example: Age = [15, 18, 22, 35, 42, 50, 63, 70]. Equal-Width Binning (width=20): Categories: Teen (0–20), Young (21–40), Middle-aged (41–60), Senior (61–80). Result: [Teen, Teen, Young, Young, Middle-aged, Middle-aged, Senior, Senior]."

شئو هو: تحويل قيم رقمية مستمرة إلى فئات ب تقسيم المدى إلى (bins) intervals. **أنواعه:** - **Equal-Width:** فترات متساوية **Clustering-Based:** نستخدم k-means لتجميع القيم. - **Supervised:** نأخذ التصنيف (class label) بالحساب (مثال: نقسم الدخل ليفصل "مقبول قرض" عن "مرفوض"). **العيب:** ضياع معلومة (21 و 39 يصيرون نفس الفئة "Adult").

Discretization

Numeric → Categorical (Discretization)



→ فئات (Discretization) /> شكل: تقطيع رقمي → فئات (Discretization)

جدول بيانات حقيقي (Categorical → Numeric):

Age	Bin (Equal-Width=20)
15	Teen (0–20)
18	Teen (0–20)
22	Young (21–40)

Age	Bin (Equal-Width=20)
35	Young (21–40)
42	Middle-aged (41–60)
50	Middle-aged (41–60)
63	Senior (61–80)
70	Senior (61–80)

العمر 21 و 39 كلهن "Young" — الفرق الدقيق ضاع (هذا هو العيب).

6.2 Categorical → Numerical: Binarization / One-Hot

غطيناه بالقسم 2.2 — راجع بطاقة One-Hot. النقطة الإضافية من المحاضرة 3 — لا تكتب $A=1, B=2, O=3$ لل nominal. كلام الدكتور الحرفي:

W3 P5 "Why Not Simply Use $A = 1, B = 2, O = 3$? Using $A = 1, B = 2, O = 3$ may incorrectly suggest that the categories have a numerical order. For nominal categories such as blood type, there is no meaningful order. Therefore, one-hot encoding is usually more appropriate for nominal categorical data."

W2 P7 "One-Hot Encoding: Each category gets a new binary column. Example: Color = {Red, Blue, Green} → Red 1 0 0, Blue 0 1 0, Green 0 0 1."

One-Hot Encoding (Categorical → Numeric)

Categories:

Red

Blue

Green

	Red	Blue	Green
Red	1	0	0
Blue	0	1	0
Green	0	0	1

(Numeric →

شكل: One-Hot Encoding (Categorical → Numeric)

جدول بيانات حقيقي (فصائل دم → One-Hot):

Patient	Blood Type	A	B	O
P1	A	1	0	0

Patient	Blood Type	A	B	O
P2	B	0	1	0
P3	O	0	0	1
P4	A	1	0	0

ثلاثة أعمدة بدل رقم واحد — ما كتبنا $A=1, B=2, O=3$ عمداً.

6.3 Text → Numerical

(غطيناه بالقسم 2.4 — TF-IDF, BoW, embeddings. هذا أهم تحويل عند الدكتور).

TF-IDF (Text → Numeric)

TF-IDF
weights

	Doc1	Doc2
the	0.10	0.08
cat	0.91	0.05
dog	0.04	0.88

rare word
→ HIGH

common word
→ LOW

(Numeric →) — الكلمة النادرة وزنها أعلى
شكل: TF-IDF (Text → Numeric) — الكلمة النادرة وزنها أعلى

جدول بيانات حقيقي (مصفوفة Document–Term بأوزان TF-IDF):

ملاحظة	Doc2	Doc1	Term
شائعة → وزن منخفض	0.08	0.10	the
نادرة بـ Doc1 → وزن عالي	0.05	0.91	cat
نادرة بـ Doc2 → وزن عالي	0.88	0.04	dog

الجدول هو التمثيل الرقمي اللي ياكله النموذج — كل خلية = وزن الكلمة بالمستند.


6.4 Time Series → Numerical / → Sequence

- **Numerical** → نستخرج إحصائيات (mean, std, min/max, skewness) أو ميزات ترددية (Fourier/Wavelet) أو shapelets. النتيجة vector ثابت الطول.
- **Sequence (رمزي)**: نحول الأرقام لرموز. مثال الدكتور الحرفي للقلب:

W2 P9 "Instead of keeping raw heart rate values [75, 77, 80, 60, 58, 90], we can convert them into symbols like: [N, N, H, L, L, H] (where N = Normal, H = High, L = Low)."

W2 P10 "SAX Steps: Normalize the series (mean = 0, variance = 1). Divide series into equal-sized segments. Compute average value for each segment. Map averages into symbols using breakpoints."

Time-Series → Sequence Time-Series → Symbolic Sequence (SAX)



→ سلسلة رمزية (SAX) </p>
 <\/p>

جدول بيانات حقيقي (Symbolic Sequence → Time-Series):

Time	1	2	3	4	5	6
Heart Rate	75	77	80	60	58	90
Symbol	N	N	H	L	L	H

بدل الأرقام الخام، صارت رموز — أسهل لاكتشاف الأنماط والشذوذ.

6.5 Image → Numerical

الصورة أساساً matrix من شدة البكسل (grayscale: 0=أسود، 255=أبيض؛ RGB: 3 قنوات). بدل كل بكسل، نستخرج .vector → shape/texture/edges

6.6 Spatial → Numerical

إحداثيات مباشرة (long,lat)، أو مسافات لنقاط مرجعية، أو shape features (compactness, perimeter, area)، أو grid/raster.

6.7 Sequence → Numerical

One-hot لكل رمز، أو k-mer counts (نكسر التسلسل لقطع طول k ونعدها — مفيد بـ DNA)، أو embeddings (DNA2Vec).

★★ القسم 6.8 — Graph → Numerical: Graph Embedding (الأهم للفهم الأول)

هنا نحول الرسم البياني نفسه إلى أرقام علمود الخوارزميات. التعريف الحرفي:

W2 P17 "A graph $G = (V, E)$ consists of nodes (V) and edges (E) that connect them."

طرق:

- **Node-Level**: درجة العقدة (degree), clustering coefficient, (betweenness/closeness/eigenvector) centrality, PageRank. مثال الدكتور:

W2 P17 "Example: Social network node → [degree=5, clustering=0.3, betweenness=0.12]"

- **Edge-Level**: وزن الحافة، edge betweenness، تشابه العقدتين.
- **Graph-Level**: عدد العقد/الروابط، $\text{density} = \frac{|E|}{(|V|(|V|-1))/2}$ ، diameter، متوسط clustering.


W2 P18 "Density = $2*|E| / (|V|*(|V|-1))$ "

- **Adjacency / Laplacian flattening**: نفرد مصفوفة الجوار لأرقام (أو نأخذ eigenvalues).
- **(Node2Vec / GNN) Graph Embedding**: نتعلم vectors كثيفة.

W2 P18 "Node2Vec / DeepWalk: Random walks on the graph → treat as sentences → use Word2Vec to get node embeddings." **W2 P18** "Graph Neural Networks (GNNs): Aggregate features from neighbors → node-level or graph-level embeddings. Examples: GCN, GraphSAGE, GAT."

ارتباطه بالمحاضرة: الدكتور يذكر Node2Vec/GNN كحل لمشكلة "الخوارزميات تريد أرقام وال graph مو أرقام".

Graph Embedding Graph → Numeric (Graph Embedding)



→ Numeric (Graph Embedding) </p>
</div>

شكل: Graph → Numeric (Graph Embedding)

كلية علوم الحاسوب وتكنولوجيا المعلومات — جامعة واسط

Page 20 of 26

جدول بيانات حقيقي (Numeric vector → Graph):

Node	Embedding (dense vector)
A	[0.21, 0.75, 0.43]
B	[0.19, 0.81, 0.39]
C	[0.24, 0.70, 0.51]
D	[0.22, 0.78, 0.44]

كل عقدة صارت متجه أرقام — النموذج يقدر يشتغل عليه.

★★★ القسم 6.9 — Converting Different Data Types INTO a Graph (النقطة اللي وقفت عندها)

هذا هو السبب الحقيقي لتشتتك: المحاضرة 2 كلها كانت "حوّل كل شي إلى أرقام" (Numerical → Graph). بس المحاضرة 3 فجأة قلبت الاتجاه: "بدل ما نحول كل شي أرقام، نمثّل العلاقات كـ graph". الدكتور سماها "Converting Different Data Types into a Graph". هذي نقطة التحول واللي ما فهمتها. كلام الدكتور الحرفي (وهذا اللي لازم تحفظه زين):

W3 P9 "Instead of converting everything into numerical data, relationships between objects can be represented using a graph."

W3 P9 "Suppose we have five patients. If two patients are sufficiently similar, we connect them. The nodes represent objects, and the edges represent similarity."

W3 P10 "A similarity graph can be created using a similarity or distance measure. For example: If $\text{distance}(P_1, P_2) < \text{threshold} \rightarrow \text{Connect } P_1 \text{ and } P_2$. The graph represents which objects are similar to each other."

W3 P10 "Applications: Clustering. Classification. Nearest-neighbor analysis. Outlier detection."

شنو يعني (What)?

بدل التمثيل الرقمي، نمثّل الأغراض (objects) كـ nodes و العلاقات بينها كـ edges. أشهر شكل: Similarity Graph (رسم التشابه) — نربط كل غرضين متشابهين بـ edge.


شلون يشتغل (How) — بالخطوات والمثال:

1. عندنا 5 مرضى، كل واحد عنده سمات رقمية (مثلاً العمر، الضغط، الكوليسترول).
2. نختار مقياس تشابه أو مسافة (مثلاً Euclidean distance على السمات).
3. لكل زوج (P_i, P_j) : إذا $\text{distance}(P_i, P_j) > \text{threshold}$ إذن نربطهم بـ edge.
4. النتيجة: graph يمثل أي مريض يشبه أي مريض.

شكل الرسم الناتج (بالكلمات): العقد P_1, P_2, P_3, P_4 متصلين ببعض ($P_1-P_2, P_2-P_4, P_4-P_3, P_3-P_1$) فيتشكل عنقود واحد، بينما P_5 عقدة معزولة ما انربطت بأحد لأن مسافتها عن الكل فوق الـ threshold.

Similarity Graph

Converting Data INTO a Graph — Similarity Graph



شكل: 5 — Similarity Graph مرضى، 4 عنقود + P5 معزول (outlier)

جدول بيانات حقيقي (5 مرضى + مسافات → روابط):

Pair	Distance	?Connected
P1-P2	0.12	✓ (نفس العنقود)
P2-P4	0.18	✓
P4-P3	0.15	✓
P3-P1	0.20	✓
P5-الكل	0.95	✗ (معزول → outlier)

المسافة > threshold → ربط. P5 بعيدة عن الكل → ما انربتت → شذوذ.

- P1, P2, P3, P4 قريبين من بعض → عنقود (cluster).
- P5 معزول (ما انربط بأحد) → مرشح شذوذ (outlier) — وهذا يربطنا ببطاقة Anomaly Detection من القسم 2.1!

التطبيقات (ليش نسويها؟):

- **Clustering**: كل مكون متصل (connected component) = عنقود.
- **Classification**: نشر لصنف من العقد المعروفة لباقي العقد.
- **Nearest-neighbor analysis**: الجيران = العقد المتصلة.
- **Outlier detection**: العقدة المعزولة = شاذة.

الفكرة الجوهرية: التحويل لـ graph يعكس الاتجاه — هنا نحول إلى graph (من أي نوع بيانات)، بينما بالقسم 6.8 حولنا من graph إلى numbers. الدكتور يدّرس الاتجاهين لأن بعض الخوارزميات (community, spectral clustering, detection, k-NN على graph) تشتغل على البنية العلائقية أحسن من المتجهات.

تحذير الدكتور (مهم للفهم):

W3 P10 "Data type conversion is useful, but it may result in information loss. Example: Original ages: 21, 22, 39. After discretization: Adult, Adult, Adult. The exact ages have disappeared. Therefore: A good conversion should preserve the important information needed for the mining task."

القسم 7 — التنظيف، التحجيم، والتخفيض

7.1 Data Cleaning (تنظيف البيانات)

W2 P21 "MCAR – Missing Completely at Random: The missingness has no relationship with the data (observed or unobserved)." **W2 P21** "MAR – Missing at Random: The missingness depends on observed data but not on the missing data itself." **W2 P21** "MNAR – Missing Not at Random: The missingness depends on the missing data itself."

المشاكل الشائعة: missing entries, incorrect entries (typos), inconsistent entries (تواريخ بصيغ مختلفة), outliers, redundancy (تكرار). **التعامل مع المفقود (Missing Data):** **MCAR** (Missing Completely at Random): عشوائي تماماً. - **MAR** (Missing at Random): يعتمد على قيم موجودة (الدخل مفقود أكثر عند الشباب). - **MNAR** (Missing Not at Random): يعتمد على القيمة المفقودة نفسها (أصحاب الدخل العالي يخفونه). **الاستراتيجيات:**


W2 P21 "Listwise Deletion (row) Remove any record with missing values. Column Deletion (column) Remove any column with too many missing values. Useful if (columns) attributes values are missing in a column 50% <". **Deletion:** حذف الصفوف (listwise) أو الأعمدة (إذا 50% < مفقود). **Imputation:** تعبئة بـ mean/median/mode، أو KNN imputation، أو regression imputation، أو multiple imputation.

7.2 Normalization & Scaling (التحجيم والتطبيع)

W2 P23 "Min-Max Scaling: Rescales values to a fixed range, usually [0, 1]. Formula: $x' = (x - x_{\min}) / (x_{\max} - x_{\min})$." **W2 P23** "Z-Score Standardization: Centers the data at 0 and scales to unit variance. Formula: $x' = (x - \mu) / \sigma$."

ليش؟ الخوارزميات (neural nets, SVM, KNN) تفترض الميزات بنفس المقياس؛ بدونه الميزة الكبيرة تسيطر. - **Min-Max** **Scaling:** $(x - x_{\min}) / (x_{\max} - x_{\min})$ → مدى [0,1]. حساس للـ outliers. **(Standardization) Z-Score:** $(x - \mu) / \sigma$ → متوسط 0 وانحراف 1. أقل حساسية للـ outliers. **Max Abs / Robust / Decimal Scaling:** بدائل حسب الحالة.

Scaling — Min-Max vs Z-Score



شكل: التحجيم — Min-Max مقابل Z-Score

جدول بيانات حقيقي (Scaling على ميزة واحدة):

Raw	Min-Max (0-1)	Z-Score
10	0.00	-1.22
20	0.50	0.00
30	1.00	1.22

بدون التحجيم، القيمة 30 تسيطر على الخوارزمية — بعده كل الميزات بمدى متقارب.

7.3 Transformation & Data Reduction (تخفيض وتحويل)

W2 P25 "Sampling: Selecting a subset of data to represent the entire dataset." **W2 P25** "Filter methods: Evaluate features using statistical measures (correlation, chi-square). Wrapper methods: Use ML algorithms to test feature subsets (e.g., recursive feature elimination). Embedded methods: Feature selection is part of model training (e.g., Lasso regression)."

- **Sampling**: أخذ عيّنة ممثلة (random, stratified, systematic, cluster, reservoir, streams).
- **Feature Subset Selection (3 أنواع — مهمة جداً)**:
- **Filter**: مقاييس إحصائية (correlation, chi-square, mutual information) — سريع، يتجاهل التفاعلات.
- **Wrapper**: نستخدم النموذج لتقييم الأنواع الفرعية (RFE) — أدق بس مكلف حسابياً.
- **Embedded**: الاختيار يصير أثناء التدريب (Lasso/L1, Random Forest importance) — فعال.
- **Dimensionality Reduction** بال **Axis Rotation**:
- **PCA**: إسقاط على مكونات رئيسية تلتقط أقصى تباين (orthogonal). خطوات الدكتور:

W2 P31 "PCA Steps: Standardize the data (mean = 0, variance = 1). Compute the covariance matrix. Compute eigenvectors and eigenvalues. Sort eigenvectors by eigenvalues → choose top-k components. Project data onto these principal components."

• **SVD**: $A = U \Sigma V^T$, يقلل الأبعاد. أساس LSA بالنصوص.

W2 P32 "SVD Factorizes the data matrix A into three matrices: $A = U \Sigma V^T$."

- **Dimensionality Reduction** بال **Type Transformation**
- **Haar Wavelet**: متوسط والفرق بين قيم متجاورة → ضغط.
- **MDS**: يحافظ على المسافات الزوجية للتصور.
- **Spectral Graph Embedding**: eigenvectors للمصفوفة Laplacian → تمثيل رقمي لل graph (يرجع لنفس موضوع 6.8).

خاتمة — ملخص سريع للمراجعة

1. عائلتان: Nondependency (كل سجل وحده) و Dependency (بينهم خيوط وقت/ترتيب/بنية).
2. 8 أنواع: 4 + 4 كما فصلنا.
3. **Data Preparation**: 6 خطوات.
4. **Feature Extraction**: اشتقاق سمات أفضل من الخام.
5. **Portability**: جدول التحويل (استوعب اتجاهين: numeric و graph).
6. نقطة التحول: Similarity Graph = Converting INTO a Graph (بنبي edges بالمسافة > threshold) — هذا اللي وقفت عنده.
7. **Cleaning / Scaling / Reduction**: المكمل الإجرائي.

نصيحة للدكتور: هو "يوزع بحث" — فكل كلمة بسمتها (ARIMA, PageRank, TF-IDF, SAX, ...) هي بطاقة بحث بهالوثيقة. راجع البطاقة قبل أي محاضرة جاية.

Retrieval Set (بطاقات للمراجعة السريعة — لامتحان)

RS-01 ما الفرق بين Nondependency و Dependency data؟

Nondependency: كل سجل مستقل (مثل جدول مرضى). Dependency: القيم بينها علاقة/وقت/بنية (مثل سلسلة زمنية).

RS-02 اذكر ال 4 أنواع من كل عائلة.

Nondependency: Quantitative Multidimensional, Categorical & Mixed, Binary & Set, Text. Dependency: Time-Series, Discrete Sequences, Spatial, Network & Graph.

RS-03 لماذا نستخدم One-Hot بدل $A=1, B=2, O=3$ ؟

لأن $A=1, B=2$ يخلق ترتيباً عددياً غير موجود بالفئات الاسمية (nominal)، فالنموذج يفهمه غلط.

RS-04 اشرح TF-IDF بكلمتين.

يوزن الكلمة ب تكرارها بالمستند $\times$ ندرتها بال corpus؛ يرفع المهم ويخفض التافه ("the").

RS-05 ما هو Similarity Graph ولماذا نبنيه؟

نمّثل الأغراض nodes والعلاقات edges؛ نربط كل زوج مسافته $> \text{threshold}$. يفيد outlier, NN, classification, clustering, detection.

RS-06 اذكر 3 أنواع Feature Selection.

(Filter إحصاء)، Wrapper (نموذج يقيّم)، Embedded (أثناء التدريب ك Lasso).