

وثيقة المراجعة والتلخيص الأكاديمي

ملاحظة مهمة قبل تبدأ: الدكتور ما يعلم — هو يوزع بحث. في هالنسخة v3، كل اقتباس إنكليزي داخل صندوق Verbatim هو حرفياً من كلام الدكتور بالمصادر (ملفات ال docx الأصلية) — ما انجم من راسي. تحته مباشرة الشرح العربي الفهمي. باقي الملزمة كله عربي (والمصطلحات الإنكليزية كما هي بالمحاضرة). قراها كأنك باحث: كل قسم فيه بطاقة بحث تحتها ثلاثة خطوط — شئ هو، شلون يشتغل (مع مثال)، وارتباطه بالمحاضرة.

القسم 1 — التصنيف الكبير: عائلتان من البيانات

قبل أي شيء، الدكتور ي divide البيانات لـ عائلتين (هذا أساس كل المحاضرة، وغالباً يسأل عنه). هما التصنيف الحرفي من كلامه:

نص الملزمة: "Data where values are independent of each other → Nondependency-Oriented Data".
نص الملزمة: "Dependency-Oriented Data" → other Data where values are related or dependent on each other, often involving order or structure.

العائلة	المعنى الحرفي	شلون نعرفها؟
Nondependency-Oriented (غير معتمدة على بعض)	القيم مستقلة، كل سجل وحده ما يعتمد على الثاني	جدول مرضى: العمر والضغط والكوليسترول — كل مريض رقمه بحد نفسه
Dependency-Oriented (معتمدة على بعض)	القيم بينها علاقة / ترتيب / وقت / بنية	سعر السهم عبر الأيام — اليوم يعتمد على الأمس

حفظ سريع: Nondependency = "كل واحد بحده". Dependency = "بينهم خيوط" (وقت، ترتيب، أو بنية شبكية).

الشرح الفهمي: الدكتور يفتح المحاضرة بالخطوة — يقسم البيانات أولاً. العائلة الأولى "ما يهمها الثاني": كل صف بجدول يقف حاله. العائلة الثانية "بين عناصرها خيوط": ترتيب، أو وقت، أو بنية شبكية (زي الروابط ب graph). هالفارق هو اللي يحدد أي خوارزمية نستخدم.

القسم 2 — العائلة الأولى: Nondependency-Oriented (4 أنواع)


2.1 Quantitative Multidimensional Data (بيانات كمية متعددة الأبعاد)

نص الملزمة: "Definition: Data represented by multiple numerical attributes".
نص الملزمة: "Characteristics: Continuous values (real numbers). Can be represented in a vector form. Use cases: anomaly detection, clustering, Regression".

التعريف: بيانات تمثّل بأكثر من سمة رقمية (vector). **مثال الدكتور:** مجموعة طبية فيها Age, Blood Pressure, Cholesterol, BMI. **الخصائص:** قيم مستمرة (أرقام حقيقية)، تمثّل على شكل متجه (vector)، استخداماتها: Regression.

.anomaly detection ,clustering

Quantitative Multidimensional — numeric vector



: Age=25, BP=80, Chol=190, BMI=22 → [25,80,190,22]

شكل: بيانات كمية متعددة الأبعاد — كل سجل = متجه أرقام

جدول بيانات حقيقي (مجموعة طبية — كل صف متجه أرقام):

Patient	Age	Blood Pressure	Cholesterol	BMI
P1	25	120	190	22.1
P2	41	135	210	26.4
P3	33	118	175	23.0
P4	58	150	240	29.8

كل صف = نقطة بـ 4 أبعاد، مثلاً $P1 = [25, 120, 190, 22.1]$.

بطاقة بحث: Regression (الانحدار)

- **شنو هو:** عائلة من النماذج تحاول تتنبأ بقيمة رقمية مستمرة من مدخلات. الفرق الجوهرى عن التصنيف (classification): التصنيف يجاوب "نعم/لا" أو "فئة"، الانحدار يجاوب "كم؟" (سعر، عمر، ضغط).
- **شلون يشتغل (مثال):** لو عندك أعمار وضغط لمرضى، تبني خط $BP \approx a \cdot Age + b$. تعطيه عمر جديد فيتوقع الضغط. أبسط نوع Linear Regression (أقل مربعات). أنواع ثانية: Lasso, Ridge, Polynomial.
- **ارتباطه بالمحاضرة:** هذا النوع (Quantitative Multidimensional) هو "الوقود" الطبيعى للانحدار لأنه أرقام متجهة. لهذا الدكتور خليه ضمن الـ use cases.

بطاقة بحث: Clustering (التجميع)

- **شئو هو:** تقسيم البيانات لـ groups بحيث اللي داخل المجموعة الوحدة يكونون متشابهين، وكل مجموعة تختلف عن الثانية — بدون ما نعرف مقدماً أسماء المجموعات (unsupervised).
- **شلون يشتغل (مثال):** K-Means: تختار K مركز عشوائي، توزع كل نقطة لأقرب مركز، تحسب مراكز جديدة، تكرر لحد يستقر. النتيجة: عناقيد.
- **ارتباطه بالمحاضرة:** ينطبق على البيانات الكمية لأننا نحتاج "مسافة" بين النقاط (Euclidean distance) — وهذا متوفر بس لما البيانات رقمية متجهة.

بطاقة بحث: Anomaly Detection (كشف الشذوذ)

- **شئو هو:** اكتشاف النقاط اللي "ما تطابق" باقي البيانات — اللي هي نادرة أو غريبة (تسمى outliers أو anomalies).
- **شلون يشتغل (مثال):** قيمة ضغط = 300 تعتبر شذوذ لأنها بعيدة جداً عن توزيع باقي المرضى. طرق: statistical (z-score)، أو clustering (نقطة ما انتمت لأي عنقود)، أو Isolation Forest.
- **ارتباطه بالمحاضرة:** يظهر مرتين بالمحاضرة (هنا، وفي Time-Series) لأن الشذوذ يهم بكل أنواع البيانات — طبي (مرض)، مالي (احتيال)، حساس للوقت (إنذار مبكر).

2.2 Categorical and Mixed Attribute Data (بيانات تصنيفية ومختلطة)

نص الملزمة: "Categorical Data: Attributes represent discrete categories/labels."

نص الملزمة: "Mixed Attribute Data: Contains both numerical and categorical variables."

نص الملزمة: "Challenges: Need special encoding techniques (e.g. one-hot encoding). Distance metrics. numerical data are harder to define compared to"

التعريف: Categorical = سمات تمثل تصنيفات منفصلة (Red/Green/Blue، أو Kenya/India/USA). Mixed = تجمع رقمي + تصنيفي (مثال: {Age=21, Gender=Male, GPA=3.4, CS=Major}). **التحدي:** نحتاج تقنيات ترميز خاصة (مثل one-hot)، وقياس المسافة أصعب من الرقمي.

Categorical & Mixed — labels + numbers



Mixed record:

Age = 21 (numeric) GPA = 3.4 (numeric)
Gender = Male (category) Major = CS (category)

شكل: بيانات تصنيفية ومختلطة — فئات + أرقام

جدول بيانات حقيقي (سجلات طلاب — مختلطة رقمي + تصنيفي):

Student	Age	Gender	GPA	Major
S1	21	Male	3.4	CS
S2	22	Female	3.1	Math
S3	20	Male	2.9	CS

Student	Age	Gender	GPA	Major
S4	23	Female	3.7	Physics

العمود Gender و Major تصنيفي (nominal)؛ الباقي رقمي. هذا بالضبط اللي يحتاج one-hot.

بطاقة بحث: One-Hot Encoding (الترميز الساخن الواحد)

- **شنو هو:** لكل فئة نسوي عمود ثنائي (0/1). اللون {Green, Blue, Red} يصير 3 أعمدة: $[1,0,0]=\text{Red}$ ، $[0,1,0]=\text{Blue}$ ، $[0,0,1]=\text{Green}$.
- **شلون يشتغل:** المريض P1 بفصيلة A يصير $[1,0,0]$ ، P2 بفصيلة B يصير $[0,1,0]$. ال 1 يعني "هذا الفئة موجود"، ال 0 "غايب".
- **ليش ما نكتب $A=1, B=2, O=3$ ؟** لأن هذا يوهم النموذج إنه فيه ترتيب عددي (B أكبر من A؟ ما منطق). فصائل الدم nominal ما بينها ترتيب، ف one-hot هو الصح لل nominal.
- **ارتباطه بالمحاضرة:** هذا هو الحل لمشكلة "الخوارزميات تريد أرقام" مع البيانات التصنيفية. تذكره دائماً كجسر Numeric → Categorical (راج نشوفه بالقسم 6).

بطاقة بحث: Distance Metrics for Categorical (قياس المسافة للتصنيفي)

- **شأنو هو:** كيف "نقيس تقارب" سجلين فيهم حقول تصنيفية. بالرقمي نستخدم Euclidean، بالتصنيفي نستخدم مثلاً Hamming distance (عدد الحقول المختلفة) أو Jaccard.
- **شأنون يشتغل:** سجلان {CS, Male} و {Math, Male} — يختلفون بـ حقل واحد من 2 → مسافة 0.5.
- **ارتباطه بالمحاضرة:** الدكتور ذكر إن "المسافة أصعب تعريفها" للتصنيفي — لأن مفهوم "البعد" ما ينطبق مباشرة، فلأزم نحول أو نستخدم مقاييس بديلة.

2.3 Binary and Set Data (بيانات ثنائية وبيانات مجموعات)

نص الملزمة: "Binary Data: Attributes with only two possible values {0,1} or {False, True}."

نص الملزمة: "Set Data: Each object described by a set of items."

نص الملزمة: "Applications: Association rule mining (e.g., Market Basket Analysis). Recommendation systems."

التعريف: Binary = قيمتين بس {0,1} أو {False, True} (مثال: Smoker نعم/لا، Loan Defaulted نعم/لا). Set = كل غرض يوصف بـ مجموعة عناصر (مثال: سلة تسوق {Eggs, Bread, Milk}). **التطبيقات:** Association rule mining, recommender systems.

Binary & Set — 0/1 matrix + item set

Smoker	Loan	Fraud
1	0	0
0	1	1
1	0	1
0	0	0

Market Basket

- Milk
- Bread
- Eggs

شكل: بيانات ثنائية (مصفوفة 0/1) وبيانات مجموعات (سلة)

جدول بيانات حقيقي (مصفوفة شرائية — كل صف binary set):

Customer	Milk	Bread	Eggs	Cheese
C1	1	1	1	0
C2	0	1	0	1
C3	1	0	1	0

Customer	Milk	Bread	Eggs	Cheese
C4	0	0	0	0

سلة C1 = {Eggs, Bread, Milk}. خوارزمية Apriori تبحث الأنماط بين هالسلات.

بطاقة بحث: Association Rule Mining / Market Basket Analysis (تنقيب القواعد الارتباطية / تحليل سلة التسوق)

- **شنو هو:** اكتشاف قواعد من نوع "إذا اشترى X فغالباً يشتري Y" من بيانات المعاملات. أشهر مثال: "حفاضات → بيرة" (أسطورة Walmart).
- **شلون يشتغل:** خوارزمية Apriori: تعدّ تكرار العناصر المفردة، ثم الأزواج، ثم الثلاثيات، وتصفية بالـ support (نسبة الظهور) و الـ confidence (احتمال Y إذا ظهر X) و الـ lift.
- **ارتباطه بالمحاضرة:** بيانات الـ Set (السلة) هي الوقود الطبيعي لها — كل سلة = set، ونبحث الأنماط بين السلات.

بطاقة بحث: Recommendation Systems (أنظمة التوصية)

- **شأنو هو:** نظام يقترح عناصر (فيلم، منتج) بناءً على سلوك المستخدم. نوعان رئيسيان: collaborative filtering (بناءً على مستخدمين مشابهين) و content-based (بناءً على خصائص العنصر).
- **ارتباطه بالمحاضرة:** يذكره الدكتور لأنه يأكل بيانات ثنائية/مجموعات (user-item matrix) مليون 0/1 = شاف/ما شاف).

2.4 Text Data (بيانات نصية) — ★ أهم نوع عند الدكتور


نص الملزمة: "Data stored as unstructured textual information: Definition"

نص الملزمة: "Text is unstructured and must be converted into numerical form (Bag of Words, TF-IDF, word embeddings)." (word embeddings)

نص الملزمة: "Applications: search engines, chatbots, topic modeling, Sentiment analysis."

التعريف: بيانات مخزنة كمعلومات نصية غير مهيكلة (tweets, reviews, articles, emails). **التحدي:** النص غير مهيكل ولا بد نحوله لأرقام (word embeddings, TF-IDF, Bag of Words). **التطبيقات:** search engines, chatbots, topic modeling, Sentiment analysis.

Text — unstructured → numeric vector



→ تحويل لأرقام"/>

شكل: نص غير مهيكل → تحويل لأرقام

جدول بيانات حقيقي (مستندات + تمثيلها):

Doc	Text (raw)	Bag-of-Words vector (cat, dog, mat, log, sat, the, on)
D1	"The cat sat on the mat"	[1, 0, 1, 0, 1, 2, 1]
D2	"The dog sat on the log"	[0, 1, 0, 1, 1, 2, 1]

النص الخام ما يقرأه النموذج — نحوله لأرقام (BoW/TF-IDF) أولاً.

بطاقة بحث: BoW Bag of Words — حقيبة الكلمات

- **شنو هو:** تمثيل النص ك vector من عدد مرات كل كلمة.

نص الملزمة: "Represents text as a vector of word counts". **نص الملزمة:** "Vocabulary: [dog, cat],
[1, 0, 1, 0, 1, 2, 1] → Sentence 1 — [on, the, sat, log, mat]

- **شلون يشتغل (مثال):**
- ج1: "The cat sat on the mat" — ج2: "The dog sat on the log"
- القاموس: [on, the, sat, log, mat, dog, cat]
- ج1 → [1, 0, 1, 0, 1, 2, 1] (the ظهر مرتين)
- ج2 → [1, 0, 1, 1, 0, 2, 1]
- **المشكلة:** يتجاهل ترتيب الكلمات ومعناها (cat و dog يهمشون بنفس البعد). وهذا يؤدي لـ **sparsity** (أغلب الخانات صفر).

بطاقة بحث: TF-IDF (Inverse Document Frequency – Term Frequency) ★★ اللي سألت عنه

- **شنو هو:** وزن إحصائي لكل كلمة داخل مستند ضمن مجموعة مستندات (corpus). يكافئ الكلمات المهمة بوزن عالي، والكلمات الشائعة (مثل "the", "is") بوزن منخفض. هو **تطوير** على BoW يحل مشكلة الكلمات التافهة.

نص الملزمة: " $TF(t,d) \times IDF(t) = (t,d)TF-IDF$ ". **نص الملزمة:** "Better than BoW because it reduces the impact of frequent but uninformative words".

- **شلون يشتغل (المعادلة والخطوات):**
- $TF(t,d)$ = عدد مرات الكلمة t بالمستند d ÷ مجموع كلمات d .
- $IDF(t) = \log\left(\frac{N}{1 + df(t)}\right)$ حيث N = عدد المستندات، $df(t)$ = عدد المستندات اللي تحتوي t .
- $TF-IDF(t,d) = TF(t,d) \times IDF(t)$.
- **مثال:** مستندان — د1 "the cat sat"، د2 "the dog ran". كلمة "the" بكليهما $df=2$ ، $N=2 \rightarrow IDF = \log(2/2) = 0$ بس بد1 $df=1 \rightarrow IDF = \log(2/1) = 1$ ، بالصيغة بـ $1 + \log$ بالمقام تطلع موجبة ومرتفعة $\rightarrow$ "cat" تاخذ وزن عالي لأنها نادرة ومميزة.
- **ليش أحسن من BoW:** يقلل تأثير الكلمات المتكررة لكن غير المفيدة. "cancer" بورقة طبية أهم من "the" رغم إن "the" أكثر عدداً.

بطاقة بحث: Word Embeddings (تضمين الكلمات — FastText ,GloVe ,Word2Vec)

- **شئو هو:** تمثيل كل كلمة كـ vector كثيف (dense) بأبعاد قليلة (مثل 100–300)، بحيث الكلمات القريبة بالمعنى يكون لها vectors قريبة بالفضاء.

نص الملزمة: "Advantage: Captures semantic relationships ('queen ≈ woman + man – king')." .

- **شلون يشتغل (مثال الخرافة المعروفة):** $queen \approx woman + man - king$. النموذج التقط العلاقة الدلالية.
- Word2Vec يتعلم من السياق (الكلمات التي تطلع جنب بعض)، GloVe من مصفوفة التشارك الإحصائي.
- ارتباطه بالمحاضرة: بديل أعمق من BoW/TF-IDF لأنه يفهم المعنى والسياق، يستخدم بـ chatbots والترجمة.

بطاقة بحث: Sentiment Analysis (تحليل المشاعر)

- **شئو هو:** تصنيف النص حسب المشاعر (إيجابي/سلبي/محايد). تطبيق كلاسيكي: مراجعات الأفلام.
- **شلون يشتغل:** تحول المراجعة إلى TF-IDF أو embeddings → نمرها لنموذج (Bayes Naïve أو BERT) → يصنفها.
- ارتباطه بالمحاضرة: من تطبيقات Numeric → Text؛ الدكتور يذكره كدليل عملي إن تحويل النص لأرقام يقود لمهام حقيقية.

بطاقة بحث: Topic Modeling (نمذجة المواضيع)

- **شئو هو:** اكتشاف "مواضيع مخفية" داخل مجموعة وثائق (مثال: أخبار مقسمة لرياضة/سياسة/اقتصاد بدون تسمية مسبقة). أشهر خوارزمية: LDA (Latent Dirichlet Allocation).
- ارتباطه بالمحاضرة: تطبيق نصي يعتمد على التمثيل الرقمي للوثائق.

بطاقة بحث: Search Engines & Chatbots

- **Chatbots:** نظام يفهم ويرد على النص. يعتمد على embeddings/transformers (BERT/GPT) لتحويل سؤال المستخدم لنص "قابل للمعالجة".
- **Search Engines:** تحول استعلامك والصفحات لأرقام (sentence embeddings) وتقارن التشابه. الدكتور يذكرها لأنها أضخم تطبيق عملي لـ Numeric → Text.

القسم 3 — العائلة الثانية: Dependency-Oriented (4 أنواع)


3.1 Time-Series Data (بيانات سلاسل زمنية)

نص الملزمة: "Definition: A sequence of values recorded over time."

نص الملزمة: "Characteristics: Temporal dependency (past values influence future values). Often analyzed using ARIMA, LSTMs, Transformers, anomaly detection, Forecasting, Applications."

التعريف: سلسلة قيم مسجلة عبر الزمن (أسعار أسهم، طقس، إشارات ECG). الخصائص: اعتماد زمني (الماضي يؤثر بالمستقبل). تُحلل بـ ARIMA, LSTMs, Transformers. التطبيقات: Forecasting, anomaly detection.

Time-Series — values across time



Example: stock price / ECG signal / temperature

شكل: سلسلة زمنية — قيم عبر الزمن

جدول بيانات حقيقي (سعر سهم عبر 8 أيام):

Day	1	2	3	4	5	6	7	8
Price	100	102	99	105	103	107	110	108

الترتيب مهم: 100→102→99 له معنى، ما يصير نعيد ترتيبه عشوائي.

بطاقة بحث: ARIMA / LSTM / Transformers

- **ARIMA** (AutoRegressive Integrated Moving Average): نموذج إحصائي كلاسيكي للتنبؤ يعتمد على القيم السابقة والفروق بينها.
- **LSTM** (Long Short-Term Memory): نوع من الشبكات العصبية المتكررة (RNN) "يتذكر" السياق الطويل — ممتاز للسلاسل الزمنية.
- **Transformers** (مثل BERT/GPT لكن للزمن): أحدث نماذج، تلتقط الاعتماديات بعيدة المدى.
- **ارتباطه بالمحاضرة:** الدكتور يذكرها لأن Time-Series تحتاج نماذج "تفهم الترتيب" — عكس ال Quantitative اللي كل صف وحده.

3.2 Discrete Sequences and Strings (سلاسل رموز منفصلة)

نص الملزمة: "Definition: Data represented as sequences of discrete symbols."

نص الملزمة: "Challenges: Pattern matching, alignment, and subsequence analysis."

التعريف: تسلسل رموز منفصلة (DNA: ATCG, clickstreams: سلسلة صفحات). **التحدي:** alignment, pattern matching. تحليل الأنظمة الفرعية. **التطبيقات:** Bioinformatics, web usage mining, NLP.

Discrete Sequence — ordered symbols



شكل: سلسلة رموز منفصلة — ترتيب مهم

جدول بيانات حقيقي (سلاسل منفصلة):

ID	Type	Sequence
S1	DNA	A → T → C → G → A → C → G
S2	Clickstream	Home → Search → Product → Cart
S3	DNA	A → T → G → G → A → C → T

تبدیل رمز واحد یغیر المعنى (مثل الطفرة بال DNA) — لذلك الترتیب أساسی.

بطاقة بحث: Pattern Matching / Alignment (مطابقة الأنماط / المحاذاة)

- **شئو هو:** إيجاد تشابه بين تسلسلين (مثل محاذاة تسلسلين DNA لاكتشاف طفرة). أدوات: Wunsch–Needleman, BLAST.
- **ارتباطه بالمحاضرة:** التحدي هنا هو "المسافة" بس، بل "الترتيب مهم" — فلابزم خوارزميات تسلسل لا خوارزميات جدول.


Spatial Data 3.3 (بيانات مكانية)

نص الملزمة: "Definition: Data representing objects in a spatial or geographical context."

نص الملزمة: "Challenges: Spatial autocorrelation (nearby objects are more related)."

التعريف: بيانات بسياق جغرافي/مكاني (خرائط، صور أقمار، إحداثيات lat/long). **التحدي:** Spatial autocorrelation (الأشياء القريبة مكانياً أكثر ارتباطاً). **التطبيقات:** GIS، مراقبة المرور، النمذجة البيئية.

Spatial — coordinates on a grid



lat/long
32.50, 45.82

شكل: بيانات مكانية — إحداثيات على شبكة

جدول بيانات حقيقي (مواقع مستشفيات — lat/long):

Hospital	Latitude	Longitude	Type
H1	32.50	45.82	General
H2	32.48	45.85	Children
H3	32.55	45.79	Cardiac
H4	32.46	45.90	General

نحسب "المسافة" بينها بالإحداثيات — أقرب مستشفى = الأهم للتحليل المكاني.

بطاقة بحث: Spatial Autocorrelation (الارتباط الذاتي المكاني)

- **شنو هو:** مبدأ "القريب من القريب أقرب" — مدينة تشبه جيرانها أكثر من مدينة بعيدة. يقاس بـ Moran's I.
- **ارتباطه بالمحاضرة:** هذا يكسر فرضية "كل سجل وحده" (independence) — وبالتالي يصنفها الدكتور Dependency.

3.4 Network and Graph Data (شبكات ورسوم بيانية) — ★★ مهم جداً ومرتبطة بنقطة توقفك


نص الملزمة: "Data represented as nodes and edges :Definition"

نص الملزمة: "Characteristics: Strongly structured data. Requires graph algorithms (PageRank, community detection, Graph Neural Networks)".

التعريف: بيانات ممثلة بـ nodes (عقد) و edges (روابط). مثال: Facebook (المستخدمون = nodes، الصداقة = edges)، شبكات الاقتباس. **الخصائص:** بيانات "بنية قوية"، تتطلب خوارزميات رسوم (PageRank, community detection, GNN). **التطبيقات:** تحليل التواصل الاجتماعي، كشف الاحتيال، recommender systems.

Network & Graph — nodes + edges

nodes =
objects
edges =
links



شكل: شبكة/رسم بياني — عقد + روابط

جدول بيانات حقيقي (شبكة تواصل — قائمة روابط):

Edge	From (node)	To (node)	Relation
e1	Ahmed	Sara	friend
e2	Sara	Omar	friend
e3	Omar	Ahmed	friend
e4	Lina	Omar	colleague

الجدول يحتوي عقد (From/To) وروابط — هذا تمثيل "edge list" لـ graph.

 بطاقة بحث: PageRank

- **شنو هو:** خوارزمية جوجل لترتيب الصفحات: العقدة "مهمة" إذا ربطت بها عقد مهمة. تعطي كل node درجة أهمية.
- **ارتباطه بالمحاضرة:** مثال على "قياس أهمية node" داخل graph — راح نحتاجه بالقسم 6 (Numeric → Graph).

📖 بطاقة بحث: Community Detection (كشف المجتمعات)

- **شنو هو:** تقسيم ال graph لمجموعات (communities) فيها روابط كثيفة داخلياً وخفيفة خارجياً. خوارزميات: Louvain, Newman–Girvan.
- **ارتباطه بالمحاضرة:** يظهر كتطبيق وكتقنية cluster لكن على graphs بدل نقاط إحداثيات.

بطاقة بحث: Graph Neural Networks (GNN — شبكات عصبية رسومية)

- **شئو هو:** شبكات عصبية "تتعلم" من بنية الـ graph نفسها (لكل node تجمع معلومات جيرانها). أمثلة: GCN, GAT, GraphSAGE.
- **ارتباطه بالمحاضرة:** الطريقة الحديثة لتحويل graph → numeric embeddings (نرجع لها بالقسم 6).


القسم 4 — تجهيز البيانات (Data Preparation) — 6 خطوات

هذا إجرائي (مو بحثي)، الدكتور يذكره كـ pipeline. الست خطوات (بالترتيب غالباً) — بالكلام الحرفي للدكتور:

نص الملزمة: "(etc ,sensors ,APIs ,files ,databases) Gathering data from multiple sources – Data Collection"
 نص الملزمة: "and resolving ,correcting errors ,removing duplicates ,Handling missing values – Data Cleaning"
 نص الملزمة: "Combining data from different sources into a single – Data Integration"
 نص الملزمة: "inconsistencies ,e.g) Converting data into a consistent format – Data Transformation"
 نص الملزمة: "Reducing the – Data Reduction" (scaling ,normalization ,encoding categorical variables
 نص الملزمة: "Data" irrelevant features or aggregating values size/dimensionality of data by removing
 نص الملزمة: "(in machine learning tasks) and test sets ,validation ,Dividing data into training – Splitting"

1. **Data Collection** — جمع البيانات من مصادر (قواعد، ملفات، APIs، sensors).
2. **Data Cleaning** — معالجة القيم المفقودة، إزالة المكرر، تصحيح الأخطاء، حل التناقضات. (نفسها بالقسم 7)
3. **Data Integration** — دمج بيانات من مصادر مختلفة بـ dataset واحد متماسك.
4. **Data Transformation** — تحويل لصيغة متسقة (scaling، normalization، encoding).
5. **Data Reduction** — تقليل الحجم/الأبعاد بحذف سمات غير مهمة أو تجميع قيم. (نفسها بالقسم 7)
6. **Data Splitting** — تقسيم لـ training / validation / test (بمهام ML).

Data Preparation



Data Preparation pipeline (6–7 steps before modeling)

شكل: خطوة تجهيز البيانات (pipeline)

كل خطوة تأخذ مخرجات السابقة — هذا هو "الأنبوب" قبل ما تدخل البيانات للنموذج.

لماذا مهم؟ (بكلام الدكتور الحرفي): **نص الملزمة:** "(removes errors and inconsistencies) Ensures accuracy".
 Improves efficiency (organized data is faster to process). Enhances model performance (clean, balanced, reliable insights come from). Supports better decision-making (and relevant data leads to better predictions).
 "(well-prepared data)".

القسم 5 — استخراج السمات (Feature Extraction)

نص الملزمة: "Feature extraction is the process of creating new features from existing data to represent its important characteristics in a form suitable for data mining or machine learning algorithms".
نص الملزمة: "Instead of giving the complete image directly to a traditional algorithm, we can represent it using useful features".

شئو هو: اشتقاق سمات جديدة "أكثر إفادة" من البيانات الخام لتحسين التحليل/النموذج — بدل استخدام الخام مباشرة. **ليش مهم:** الخام معقد/مزعج؛ يقلل الأبعاد؛ يظهر الأنماط؛ يحسّن الدقة. **أمثلة من المحاضرة:** - **من صورة:** استخراج edges/textures/color histograms أو deep embeddings (من طبقات CNN). مثال: من صورة سرطان ثدي نستخرج shape و texture. - **من نص:** BoW, TF-IDF, embeddings (BERT, Word2Vec). مثال: استخراج كلمات مفتاحية من ملاحظات طبية. - **من صوت/إشارة:** MFCC, amplitude, frequency. مثال: كشف murmur بالقلب من ECG. - **من جدول:** سمات مشتقة مثل BMI = height²/weight، أو "فئة العمر" من العمر الخام.

مكانه بال pipeline: Collection → Cleaning → Integration → Transformation → **Feature Extraction** → Splitting → Reduction.

القسم 6 — قابلية نقل نوع البيانات (Data Type Portability) ★★ الضعف الأساسي

هذا قلب المحاضرة 2 و 3. التعريف الحرفي من الدكتور:

نص الملزمة: "representation or type into another Data Type Portability means converting data from one algorithm so that it can be processed by a data mining representation".

المعنى: تحويل البيانات من تمثيل لنوع إلى تمثيل آخر علمود الخوارزمية تقدر تعالجه.

العملية العامة: أنواع بيانات مختلفة → تحويل → تمثيل مناسب → خوارزمية تنقيب.
الدكتور يذكر قائمة التحويلات الشائعة (بكلامه):

نص الملزمة: "Numerical → Discretization. Categorical → Numerical → Encoding. Text :Numerical → Symbolic representation. Time Series :Sequence → Vectorization. Time Series :Numerical → Feature extraction. Graph :Numerical features → DFT / DWT or feature extraction. Image :features → Similarity graph :Graph → Graph embedding. Any data type :Numerical representation".

الجدول المرجعي الشامل (من المحاضرة 3 — احفظه)

من (From)	إلى (To)	التقنية
Numerical	Categorical	Discretization (تقطيع)
Categorical	Numerical	One-Hot Encoding
Text	Numerical	Vectorization (BoW / TF-IDF / embeddings)
Time Series	Numerical	Feature extraction (DFT/DWT)
Time Series	Sequence	Symbolic representation (SAX)
Image	Numerical	Feature extraction
Sequence	Numerical	Sequence encoding
Spatial	Numerical	Distance / shape features
Graph	Numerical	Graph embedding
أي نوع	Graph	Similarity graph

انتبه للسطرين الأخيرين — هما الاتجاهين المختلفين اللي الدكتور قفز بينهم وهذا سبب تشتتك (نفصل تحت).

6.1 Numerical → Categorical :Discretization (التقطيع)


نص الملزمة: "Discretization is the process of converting continuous numeric data into discrete categorical data by dividing the range of values into intervals (bins)".

نص الملزمة: "Example: Age : [15, 18, 22, 35, 42, 50, 63, 70] = Equal-Width Binning (20=width) :Categories : Teen (0–20), Young (21–40), Middle-aged (41–60), Senior (61–80). Result : [Teen, Young, Middle-aged, Senior]."

شئو هو: تحويل قيم رقمية مستمرة إلى فئات بـ تقسيم المدى إلى (bins) intervals. **أنواعه:** - **Equal-Width:** فترات متساوية
Clustering-Based: نستخدم k-means لتجميع القيم. - **Supervised:** نأخذ التصنيف (class label) بالحسبان (مثال: نقسم الدخل ليفصل "مقبول قرض" عن "مرفوض"). **العيب:** ضياع معلومة (21 و 39 يصيرون نفس الفئة "Adult").

Discretization

Numeric → Categorical (Discretization)



→ فئات (Discretization) /<
 شكل: تقطيع رقمي → فئات (Discretization)

جدول بيانات حقيقي (Numeric → Categorical):

Age	Bin (Equal-Width=20)
15	Teen (0–20)
18	Teen (0–20)
22	Young (21–40)
35	Young (21–40)
42	Middle-aged (41–60)
50	Middle-aged (41–60)
63	Senior (61–80)
70	Senior (61–80)

العمر 21 و 39 كلهن "Young" — الفرق الدقيق ضاع (هذا هو العيب).

6.2 Categorical → Numerical: Binarization / One-Hot

غطيناه بالقسم 2.2 — راجع بطاقة One-Hot. النقطة الإضافية من المحاضرة 3 — لا تكتب **A=1, B=2, O=3** لل (nominal). كلام الدكتور الحرفي:

may incorrectly suggest $B = 2$, $O = 3$? Using $A = 1$, $B = 2$, $O = 3$, $1 =$ Why Not Simply Use A" نص الملزمة: there is no ,blood type numerical order. For nominal categories such as that the categories have a ".nominal categorical data one-hot encoding is usually more appropriate for ,meaningful order. Therefore ,Blue ,Red} = Color :Each category gets a new binary column. Example :One-Hot Encoding" نص الملزمة: ".Green 0 0 1 ,Blue 0 1 0 ,Red 1 0 0 → {Green

One-Hot Encoding (Categorical → Numeric)

Categories:

Red

Blue

Green

	Red	Blue	Green
Red	1	0	0
Blue	0	1	0
Green	0	0	1

</"(Numeric →

One-Hot Encoding (Categorical → Numeric): شكل

جدول بيانات حقيقي (فصائل دم → One-Hot):

Patient	Blood Type	A	B	O
P1	A	1	0	0
P2	B	0	1	0
P3	O	0	0	1
P4	A	1	0	0

ثلاثة أعمدة بدل رقم واحد — ما كتبنا $A=1, B=2, O=3$ عمداً.

6.3 Text → Numerical

(غطيناه بالقسم 2.4 — TF-IDF, BoW, embeddings. هذا أهم تحويل عند الدكتور).

TF-IDF (Text → Numeric)

TF-IDF

weights

	Doc1	Doc2	
the	0.10	0.08	rare word → HIGH
cat	0.91	0.05	common word → LOW
dog	0.04	0.88	

شكل: TF-IDF (Text → Numeric) — الكلمة النادرة وزنها أعلى
(Numeric → الكلمة النادرة وزنها أعلى)

جدول بيانات حقيقي (مصفوفة Document–Term بأوزان TF-IDF):

ملاحظة	Doc2	Doc1	Term
شائعة → وزن منخفض	0.08	0.10	the
نادرة بـ Doc1 → وزن عالي	0.05	0.91	cat
نادرة بـ Doc2 → وزن عالي	0.88	0.04	dog

الجدول هو التمثيل الرقمي الذي يأكله النموذج — كل خلية = وزن الكلمة بالمستند.


6.4 Time Series → Numerical / → Sequence

- **Numerical** → نستخرج إحصائيات (mean, std, min/max, skewness) أو ميزات ترددية (Fourier/Wavelet) أو shapelets. النتيجة vector ثابت الطول.
- **Sequence (رمزي)**: نحول الأرقام لرموز. مثال الدكتور الحرفي للقلب:

نص الملزمة: "Instead of keeping raw heart rate values, we can convert them into [90, 58, 60, 80, 77, 75]. symbols like [N, N, H, L, L, H]: (Low = H = High, L, Normal = where N)"

نص الملزمة: "SAX Steps: Normalize the series (1 = variance, 0 = mean). Divide series into equal-sized symbols using breakpoints average value for each segment. Map averages into segments. Compute

Time-Series → Sequence Time-Series → Symbolic Sequence (SAX)



→ سلسلة رمزية (SAX) "</p>
 </div>
 <div data-bbox="481 378 939 396" data-label="Section-Header">
 <h4>جدول بيانات حقيقي (Symbolic Sequence → Time-Series):</h4>
 </div>
 <div data-bbox="67 406 930 489" data-label="Table">
 <table>
 <tr>
 <th>Time</th>
 <th>1</th>
 <th>2</th>
 <th>3</th>
 <th>4</th>
 <th>5</th>
 <th>6</th>
 </tr>
 <tr>
 <td>Heart Rate</td>
 <td>75</td>
 <td>77</td>
 <td>80</td>
 <td>60</td>
 <td>58</td>
 <td>90</td>
 </tr>
 <tr>
 <td>Symbol</td>
 <td>N</td>
 <td>N</td>
 <td>H</td>
 <td>L</td>
 <td>L</td>
 <td>H</td>
 </tr>
 </table>
 </div>
 <div data-bbox="447 514 913 533" data-label="Text">
 <p>بدل الأرقام الخام، صارت رموز — أسهل لاكتشاف الأنماط والشذوذ.</p>
 </div>
 <div data-bbox="67 559 292 578" data-label="Section-Header">
 <h3>6.5 Image → Numerical</h3>
 </div>
 <div data-bbox="67 584 940 622" data-label="Text">
 <p>الصورة أساساً matrix من شدة البكسل (grayscale: 0=أسود، 255=أبيض؛ RGB: 3 قنوات). بدل كل بكسل، نستخرج vector → shape/texture/edges.</p>
 </div>
 <div data-bbox="67 638 297 656" data-label="Section-Header">
 <h3>6.6 Spatial → Numerical</h3>
 </div>
 <div data-bbox="77 663 939 682" data-label="Text">
 <p>إحداثيات مباشرة (long,lat)، أو مسافات لنقاط مرجعية، أو shape features (compactness,perimeter,area)، أو grid/raster.</p>
 </div>
 <div data-bbox="67 697 323 716" data-label="Section-Header">
 <h3>6.7 Sequence → Numerical</h3>
 </div>
 <div data-bbox="92 723 940 742" data-label="Text">
 <p>One-hot لكل رمز، أو k-mer counts (نكسر التسلسل لقطع طول k ونعدها — مفيد بـ DNA)، أو embeddings (DNA2Vec).</p>
 </div>
 <div data-bbox="123 770 939 794" data-label="Section-Header">
 <h2>★★ القسم 6.8 — Graph Embedding: Numerical → Graph (الأهم للفهم الأول)</h2>
 </div>
 <div data-bbox="400 807 939 826" data-label="Text">
 <p>هنا نحول الرسم البياني نفسه إلى أرقام علمود الخوارزميات. التعريف الحرفي:</p>
 </div>
 <div data-bbox="241 848 913 866" data-label="Text">
 <p>نص الملزمة: "A graph G consists of nodes (V, E) and edges (V, E) that connect them".</p>
 </div>
 <div data-bbox="887 890 939 908" data-label="Text">
 <p>طرق:</p>
 </div>
 <div data-bbox="67 966 369 981" data-label="Page-Footer">
 <p>كلية علوم الحاسوب وتكنولوجيا المعلومات — جامعة واسط</p>
 </div>
 <div data-bbox="848 966 940 981" data-label="Page-Footer">
 <p>Page 22 of 29</p>
 </div>
 </div>

- **Node-Level**: درجة العقدة (degree), clustering coefficient, centrality (betweenness/closeness/eigenvector), PageRank. مثال الدكتور:

نص الملزمة: "Example: Social network node: [0.12=betweenness, 0.3=clustering, 5=degree]"

- **Edge-Level**: وزن الحافة, edge betweenness, تشابه العقدتين.
- **Graph-Level**: عدد العقد/الروابط, density, diameter, متوسط clustering.
$$2 = \frac{|E|}{(|V|(|V|-1))}$$


نص الملزمة: "Density = $\frac{|E|}{(|V|(|V|-1))}$ "

- **Adjacency / Laplacian flattening**: نفرد مصفوفة الجوار لأرقام (أو نأخذ eigenvalues).
- **(Node2Vec / GNN) Graph Embedding**: نتعلم vectors كثيفة.

نص الملزمة: "Node2Vec / DeepWalk: Random walks on the graph → treat as sentences → use Word2Vec to get node embeddings".
نص الملزمة: "Aggregate (GNNs) Graph Neural Networks".
Examples → features from neighbors, GraphSAGE, GCN: node-level or graph-level embeddings. GAT.

ارتباطه بالمحاضرة: الدكتور يذكر Node2Vec/GNN كحل لمشكلة "الخوارزميات تريد أرقام وال graph مو أرقام".

Graph Embedding Graph → Numeric (Graph Embedding)



→ "Numeric (Graph Embedding)"
شكل: Graph → Numeric (Graph Embedding)

جدول بيانات حقيقي (Graph → Numeric vector):

Node	Embedding (dense vector)
A	[0.21, 0.75, 0.43]
B	[0.19, 0.81, 0.39]

Node	Embedding (dense vector)
C	[0.24, 0.70, 0.51]
D	[0.22, 0.78, 0.44]

كل عقدة صارت متجه أرقام — النموذج يقدر يشتغل عليه.

★★★ القسم 6.9 — Converting Different Data Types INTO a Graph (النقطة اللي وقفت عندها)

هذا هو السبب الحقيقي لتشتتك: المحاضرة 2 كلها كانت "حوّل كل شي إلى أرقام" (Numerical → Graph). بس المحاضرة 3 فجأة قلبت الاتجاه: "بدل ما نحول كل شي أرقام، نمثّل العلاقات كـ graph". الدكتور سماها "Converting Different Data Types into a Graph". هذي نقطة التحول واللي ما فهمتها. كلام الدكتور الحرفي (وهذا اللي لازم تحفظه زين):

نص الملزمة: "Instead of converting everything into numerical data, relationships between objects can be using a graph represented

نص الملزمة: "Suppose we have five patients. If two patients are sufficiently similar, we connect them. The nodes represent objects, and the edges represent similarity."

نص الملزمة: "A similarity graph can be created using a similarity or distance measure. For example, if two objects are similar to each other, connect P1 and P2. The graph represents which threshold $(P1, P2) \text{ distance} > \text{threshold}$."

نص الملزمة: "Applications: Nearest-neighbor, Classification, Clustering, Outlier detection, analysis."

شنو يعني (What)?

بدل التمثيل الرقمي، نمثّل الأغراض (objects) كـ nodes والعلاقات بينها كـ edges. أشهر شكل: Similarity Graph (رسم التشابه) — نربط كل غرضين متشابهين بـ edge.


شلون يشتغل (How) — بالخطوات والمثال:

1. عندنا 5 مرضى، كل واحد عنده سمات رقمية (مثلاً العمر، الضغط، الكوليسترول).
2. نختار مقياس تشابه أو مسافة (مثلاً Euclidean distance على السمات).
3. لكل زوج (P_i, P_j) : إذا $(P_i, P_j) \text{ distance} > \text{threshold}$ إذن نربطهم بـ edge.
4. النتيجة: graph يمثل أي مريض يشبه أي مريض.

شكل الرسم الناتج (بالكلمات): العقد P1, P2, P3, P4 متصلين ببعض (P1—P2, P2—P4, P4—P3, P3—P1) فيتشكل عنقود واحد، بينما P5 عقدة معزولة ما انربطت بأحد لأن مسافتها عن الكل فوق الـ threshold.

Similarity Graph

Converting Data INTO a Graph — Similarity Graph



شكل: 5 — Similarity Graph مرضى، 4 عنقود + P5 معزول (outlier)

جدول بيانات حقيقي (5 مرضى + مسافات → روابط):

Pair	Distance	?Connected
P1-P2	0.12	✓ (نفس العنقود)
P2-P4	0.18	✓
P4-P3	0.15	✓
P3-P1	0.20	✓
P5-الكل	0.95	✗ (معزول → outlier)

المسافة > threshold → ربط. P5 بعيدة عن الكل → ما انربتت → شذوذ.

- P1, P2, P3, P4 قريبين من بعض → عنقود (cluster).
- P5 معزول (ما انربط بأحد) → مرشح شذوذ (outlier) — وهذا يربطنا ببطاقة Anomaly Detection من القسم 2.1!

التطبيقات (ليش نسويها؟):

- **Clustering**: كل مكون متصل (connected component) = عنقود.
- **Classification**: نشر لصنف من العقد المعروفة لباقي العقد.
- **Nearest-neighbor analysis**: الجيران = العقد المتصلة.
- **Outlier detection**: العقدة المعزولة = شاذة.

الفكرة الجوهرية: التحويل لـ graph يعكس الاتجاه — هنا نحول إلى graph (من أي نوع بيانات)، بينما بالقسم 6.8 حولنا من graph إلى numbers. الدكتور يدّرس الاتجاهين لأن بعض الخوارزميات (spectral clustering, community detection, k-NN على graph) تشتغل على البنية العلاقتية أحسن من المتجهات.

تحذير الدكتور (مهم للفهم):

نص الملزمة: "Data type conversion is useful", Example ,Original ages :but it may result in information loss. 21, 22, 39. After discretization ,Adult ,Adult. The exact ages have disappeared. Therefore ,information needed for the mining task conversion should preserve the important

القسم 7 — التنظيف، التحجيم، والتخفيض

7.1 Data Cleaning (تنظيف البيانات)

نص الملزمة: "Missing Completely at Random – MCAR" The missingness has no relationship with the data (observed or unobserved).
نص الملزمة: "Missing at Random – MAR" The missingness depends on observed data but not on the missing data itself.
نص الملزمة: "Missing Not at Random – MNAR" The missingness depends on the missing data itself.

المشاكل الشائعة: missing entries, incorrect entries (typos), inconsistent entries (تواريخ بصيغ مختلفة), outliers, redundancy (تكرار). **التعامل مع المفقود (Missing Data):** MCAR (Missing Completely at Random): عشوائي تماماً. - MAR (Missing at Random): يعتمد على قيم موجودة (الدخل مفقود أكثر عند الشباب). - MNAR (Missing Not at Random): يعتمد على القيمة المفقودة نفسها (أصحاب الدخل العالي يخفونه). **الاستراتيجيات:**


نص الملزمة: "Listwise Deletion" Remove any record with missing values. Column Deletion (row) Remove any record with missing values. Useful if (columns) attributes values are missing in a column $> 50\%$ with too many missing values. **Deletion:** حذف الصفوف (listwise) أو الأعمدة (إذا $> 50\%$ مفقود). **Imputation:** تعبئة بـ mean/median/mode، أو KNN imputation، أو regression imputation، أو multiple imputation.

7.2 Normalization & Scaling (التحجيم والتطبيع)

نص الملزمة: "Min-Max Scaling" Rescales values to a fixed range, usually $[0, 1]$. Formula: $x' = (x - x_{\min}) / (x_{\max} - x_{\min})$. Centers the data at 0 and scales to unit variance. Formula: $x' = (x - \mu) / \sigma$.

ليش؟ الخوارزميات (neural nets, SVM, KNN) تفترض الميزات بنفس المقياس؛ بدونه الميزة الكبيرة تسيطر. - **Min-Max Scaling:** $(x - x_{\min}) / (x_{\max} - x_{\min})$ → مدى $[0, 1]$. حساس للـ outliers. **(Standardization) Z-Score:** $(x - \mu) / \sigma$ → متوسط 0 وانحراف 1. أقل حساسية للـ outliers. **Max Abs / Robust / Decimal Scaling:** بدائل حسب الحالة.

Scaling — Min-Max vs Z-Score



شكل: التحجيم — Min-Max مقابل Z-Score

جدول بيانات حقيقي (Scaling على ميزة واحدة):

Raw	Min-Max (0-1)	Z-Score
10	0.00	-1.22
20	0.50	0.00
30	1.00	1.22

بدون التحجيم، القيمة 30 تسيطر على الخوارزمية — بعده كل الميزات بمدى متقارب.

7.3 Transformation & Data Reduction (تخفيض وتحويل)

نص الملزمة: "Sampling": Selecting a subset of data to represent the entire dataset. **نص الملزمة:** "Filter" methods: Evaluate features using statistical measures (chi-square, correlation). **نص الملزمة:** "Wrapper" methods: Use ML algorithms to test feature subsets (recursive feature elimination, e.g.). **نص الملزمة:** "Embedded" methods: selection is part of model training (e.g., Lasso regression).

- **Sampling:** أخذ عيّنة ممثلة (random, stratified, systematic, cluster, reservoir, streams).
- **Feature Subset Selection (3 أنواع — مهمة جداً):**
- **Filter:** مقاييس إحصائية (correlation, chi-square, mutual information) — سريع، يتجاهل التفاعلات.
- **Wrapper:** نستخدم النموذج لتقييم الأنواع الفرعية (RFE) — أدق بس مكلف حسابياً.
- **Embedded:** الاختيار يصير أثناء التدريب (Lasso/L1, Random Forest importance) — فعال.
- **Dimensionality Reduction:** **Axis Rotation**
- **PCA:** إسقاط على مكونات رئيسية تلتقط أقصى تباين (orthogonal). خطوات الدكتور:

نص الملزمة: "PCA Steps: Standardize the data (1 = variance, 0 = mean). Compute the covariance choose top-k → and eigenvalues. Sort eigenvectors by eigenvalues matrix. Compute eigenvectors principal components components. Project data onto these".

• **SVD:** $A = U \Sigma V^T$, يقلل الأبعاد. أساس LSA بالنصوص.

نص الملزمة: "SVD Factorizes the data matrix A into three matrices: $A = U \Sigma V^T$ ".

- **Dimensionality Reduction** بال **Type Transformation**
- **Haar Wavelet:** متوسط والفرق بين قيم متجاورة → ضغط.
- **MDS:** يحافظ على المسافات الزوجية للتصور.
- **Spectral Graph Embedding:** eigenvectors للمصفوفة Laplacian → تمثيل رقمي لل graph (يرجع لنفس موضوع 6.8).

خاتمة — ملخص سريع للمراجعة

1. عائلتان: Nondependency (كل سجل وحده) و Dependency (بينهم خيوط وقت/ترتيب/بنية).
2. 8 أنواع: 4 + 4 كما فصلنا.
3. **Data Preparation:** 6 خطوات.
4. **Feature Extraction:** اشتقاق سمات أفضل من الخام.
5. **Portability:** جدول التحويل (استوعب اتجاهين: numeric → و graph →).
6. نقطة التحول: Similarity Graph = Converting INTO a Graph (بنية edges بالمسافة > threshold) — هذا اللي وقفت عنده.
7. **Cleaning / Scaling / Reduction:** المكمل الإجرائي.

نصيحة للدكتور: هو "يوزع بحث" — فكل كلمة بسمتها (ARIMA, PageRank, TF-IDF, SAX ...) هي بطاقة بحث بهالوثيقة. راجع البطاقة قبل أي محاضرة جاية.

Retrieval Set (بطاقات للمراجعة السريعة — لامتحان)

RS-01 ما الفرق بين Nondependency و Dependency data؟

Nondependency: كل سجل مستقل (مثل جدول مرضى). Dependency: القيم بينها علاقة/وقت/بنية (مثل سلسلة زمنية).

RS-02 اذكر ال 4 أنواع من كل عائلة.

Nondependency: Quantitative Multidimensional, Categorical & Mixed, Binary & Set, Text. Dependency: Time-Series, Discrete Sequences, Spatial, Network & Graph.

RS-03 لماذا نستخدم One-Hot بدل $A=1, B=2, O=3$ ؟

لأن $A=1, B=2$ يخلق ترتيباً عددياً غير موجود بالفئات الاسمية (nominal)، فالنموذج يفهمه غلط.

RS-04 اشرح TF-IDF بكلمتين.

يوزن الكلمة ب تكرارها بالمستند $\times$ ندرتها بال corpus؛ يرفع المهم ويخفض التافه ("the").

RS-05 ما هو Similarity Graph ولماذا نبنيه؟

نمّثل الأغراض nodes والعلاقات edges؛ نربط كل زوج مسافته $> \text{threshold}$. يفيد outlier, NN, classification, clustering, detection.

RS-06 اذكر 3 أنواع Feature Selection.

(Filter إحصاء)، Wrapper (نموذج يقيّم)، Embedded (أثناء التدريب ك Lasso).