

Data Mining Week 02 — Data Types & Preparation

تنقيب عن البيانات — الأسبوع الثاني: أنواع البيانات وإعدادها

Comprehensive Bilingual Study Pack (English + Arabic) — FULL, Not Compressed

حزمة مراجعة شاملة ثنائية اللغة (إنكليزي + عربي) — كاملة بلا اختصار

Instructor: Asst. Prof. Dr. Ahmed Shakir Abd Al-Rida · Data Mining

الدكتور: أ.م.د. أحمد شاكر عبد الرضا — تنقيب عن البيانات

Built from vault comprehensive notes + lecture originals + Gemini frameworks + Dr. Ahmed exam layer.

WebUI MCQ platform check is NOT counted as a course exam.

مبني على الملاحظات الشاملة بالفلدر + نصوص المحاضرة + قوالب Gemini + طبقة امتحان د. أحمد.
اختبار منصة MCQ لا يُحسب امتحاناً للمادة.

For morning study · Koko · 2026-09-20

لمذاكرة الصباح — كوكو — 20-09-2026

1. Data Object vs Attribute

1. كائن البيانات مقابل الخاصية

A data object represents an entity about which information is collected.

An attribute is a property or characteristic of a data object.

Examples of objects: patient, student, customer, transaction, document, image, geographic location. Examples of attributes: Age, Gender, BMI, Blood pressure, Diabetes status. Each ROW is a data object; each COLUMN is an attribute. Before mining: understand objects, attributes, value types, and data organization — type/structure influence which mining technique to use.

أمثلة الكائنات: مريض، طالب، زبون، معاملة، مستند، صورة، موقع جغرافي. أمثلة الخصائص: العمر، الجنس، BMI، ضغط الدم، حالة السكري. كل صف = كائن بيانات؛ كل عمود = خاصية. قبل التنقيب: افهم الكائنات والخصائص وأنواع القيم وتنظيم البيانات — النوع والهيكل يحددان تقنية التنقيب.

Diabetes	BMI	Gender	Age	Patient
Yes	28.5	Male	45	P1
No	24.1	Female	32	P2

Mental path: Object → Attribute → Value Type → Structure → Technique.

مسار فكري: كائن ← خاصية ← نوع القيمة ← هيكل ← تقنية.

2. Attribute taxonomy — Nominal / Ordinal / Binary / Numerical

2. تصنيف الخصائص — اسمي/ترتيبي/ثنائي/رقمي

A nominal attribute contains categories with no natural order.

An ordinal attribute contains categories with a meaningful order, but the difference between categories is not necessarily measurable.

A binary attribute has only two possible values.

Numerical attributes contain quantitative numerical values.

أمثلة/قاعدة	Key rule	Lecture examples	Type
فئات بلا ترتيب طبيعي	No natural order; Male > Female does not make sense	Gender, Color, Country, Department	Nominal
ترتيب موجود؛ الفجوة غير قابلة للقياس	Order meaningful; gaps not measurable	Low/Medium/High · Poor/Good/Excellent · Small/Medium/Large · Mild/Moderate/Severe	Ordinal
قيمتان فقط	Only two values; common in classification & association	Yes/No · True/False · 0/1 · Disease/No · Purchased/Not	Binary
قيم كمية؛ منفصل/مستمر	Quantitative; Discrete countable vs Continuous in-range	Age, Height, Weight, Temp, Salary, BP	Numerical

منفصل/مستمر	Continuous examples	Discrete examples
عدّ مقابل قياس ضمن مدى	Height 175.5 cm · Weight 72.4 kg · Temp 36.7°C · Glucose 125.6 mg/dL	children, # transactions, # students, # visits = # ...0,1,2,3

سؤال القرار	Numerical	Binary	Ordinal	Nominal	Decision question
ترتيب طبيعي؟	—	—	Yes	No	?Natural order
فجوات قابلة للقياس؟	Yes	—	Not necessarily	—	?Measurable gaps
قيمتان فقط؟	No	Yes	No	No	?Only two values
كمية عددية؟	Yes	No	No	No	?Quantity

Classification algorithm: (1) only two values? → Binary. (2) quantitative? → Numerical (then Discrete/Continuous; optionally Interval/Ratio). (3) ranked categories? → Ordinal. Else → Nominal.

خوارزمية التصنيف: (1) قيمتان فقط؟ ← ثنائي. (2) كمية رقمية؟ ← رقمي (ثم منفصل/مستمر؛ وربما فاصل/نسبة). (3) فئات مرتبة؟ ← ترتيب. وإلا ← اسمي.

المتغير/النوع	Type	Variable
اسمي	Nominal	Gender / Country / Color
اسمي	Nominal	URL
ترتبي	Ordinal	Satisfaction Poor/Good/Excellent
ترتبي	Ordinal	Disease severity Mild/Moderate/Severe
ثنائي	Binary	Diabetes Yes/No or 0/1
رقمي منفصل	Numerical Discrete-ish / Discrete	Age 45 / # children
رقمي مستمر/نسبي	Numerical Continuous / Ratio-like	Height 175.5 / Salary / BP

Dr. Ahmed standing question — URL

سؤال د. أحمد المفتوح — الرابط

What is the data type of a URL? Answer: Nominal. A URL is a label/identifier — no natural order, no meaningful distance between URLs. Safe sentence: "A URL is a Nominal attribute: categories/identifiers with no natural order and no meaningful distance between values."

شنو نوع بيانات الرابط؟ الجواب: Nominal. الرابط وسم/معرف — بلا ترتيب طبيعي وبلا فجوة قابلة للقياس بين الروابط.

Anchor — attribute types

مرساة أنواع الخصائص

No order → Order with unknown gap → Two values → Quantity. (اسمي → ترتيب → ثنائي → رقمي)

بلا ترتيب → ترتيب بلا قياس → صفر/واحد → عدد.

3. Interval vs Ratio + normalization formulas (Dr. Ahmed)

3. الفاصل مقابل النسبة + صيغ التطبيع (د. أحمد)

الصفء/الأمثلة	Examples	?Ratios	Zero means	Subtype
صفء اعتباطي؛ النسب غير معنوية	Celsius, calendar years	No — 20°C not twice 10°C	Arbitrary reference (not absence)	Interval-scaled
صفء مطلق؛ النسب معنوية	Kelvin, salary, weight, height, BP	Yes — 20kg is twice 10kg	Absolute physical zero (absence)	Ratio-scaled

Min-Max (into [0,1]): $x' = (x - \min) / (\max - \min)$

تطبيع المدى إلى [0,1]

Worked Min-Max (lecture)

مثال Min-Max محلول (المحاضرة)

min age=20, max=60, x=40 → $x' = (40-20)/(60-20) = 20/40 = 0.5$ → 40 years = 0.5

أدنى عمر=20، أقصى=60، $0.5 = (40-20)/(60-20) = 0.5$ ← $x=40$ ← العمر = 40

$$\text{Z-score: } z = (x - \text{mean}) / \sigma$$

زد-سكور

$$|\text{Z-score MAD: } v' = (v - \text{mean}) / s_A, s_A = (1/n) \sum |x_i - \text{mean}|$$

زد-سكور بالانحراف المطلق

$$\text{Decimal scaling: } v' = v / 10^j \text{ (max}|v'| < 1)}$$

التوسيع العشري

Doctor protocol

بروتوكول الدكتور

Write symbolic formula first → define symbols → show intermediate arithmetic → state final value and range.

Arithmetic discipline: divide missing-value mean by observed count (4 not 5).

اكتب المعادلة الرمزية أولاً ← عرّف الرموز ← وسّط الحساب ← اذكر الناتج والمدى. انضباط حسابي: متوسط القيم المفقودة يُقسم على عدد الموجود (4 مو 5).

Anchor Interval vs Ratio

مرساة الفاصل/النسبة

Interval: zero is a ruler mark. Ratio: zero is nothing left.

الفاصل: الصفر علامة على المسطرة. النسبة: الصفر يعني ما بقى شيء.

4. 8 Data Structures (attributes vs organization)

4. الهيكلية الثمانية (خصائص مقابل تنظيم البيانات)

Nominal, ordinal, binary, and numerical describe attributes. Record, transaction, text, sequence, temporal, spatial, image, and graph data describe how the data is organized or represented.

Hard separation: attribute types answer "what kind of value is this column?" Data structures answer "how is the whole dataset shaped?"

فصل صارم: أنواع الخصائص تجيب «شنو نوع القيمة بهالعمود؟»؛ الهياكل تجيب «شنو شكل مجموعة البيانات كاملة؟»

بالعربي	Mining finds	Example	Core form	Structure	#
مجموعة سجلات؛ كل سجل خصائص؛ صف = كائن	classification, clustering, regression, outliers	Patient/Student table	Collection of records; each record = set of attributes	Record	1
كل معاملة مجموعة عناصر؛ قواعد ارتباط	Association rule mining	T1={Bread,Milk,Eggs}; rule Bread→Milk	Each transaction = set of items	Transaction	2
نصوص غير مهيكلة؛ تنقيب نصوص	frequent words, topics, sentiment, similarity, text classification	emails, reviews, papers, posts	Unstructured documents	Text/Document	3
عناصر مرتبة؛ الترتيب جزء من المعلومة	ordered patterns	A→B→C→D; Login→Search→Product→Purchase; DNA	Elements in specific order; order matters	Sequence	4
ملاحظات مرتبطة بالوقت؛ اتجاهات وشذوذ	trends, seasonal/periodic, anomalies	stock, weather, ECG, rainfall, sensors	Observations tied to time	Temporal/Time-Series	5
مواقع جغرافية؛ علاقات مكانية	location-based relationships	maps, satellite, GPS (32.48,45.82), roads	Geographic/physical locations	Spatial	6
بكسلات؛ صور طبية؛ أشكال وأنسجة	objects, shapes, patterns, textures, regions (CNN)	X-ray, MRI, CT, satellite, faces	Pixels; Gray H×W; RGB H×W×3	Image/Multimedia	7
عقد وحواف؛ مجتمعات ومسارات	communities, important nodes, paths	social, citation, road, financial, knowledge graphs	Nodes (objects) + Edges (relationships)	Graph/Network	8

Structure anchor

مرساة الهياكل

Row → Basket → Document → Path → Clock → Map → Picture → Network

صف ← سلة ← مستند ← مسار ← ساعة ← خريطة ← صورة ← شبكة

Safe answer

إجابة آمنة

"The dataset is organized as [structure]. Mining techniques follow this structure — e.g. association rules for transactions, text mining for documents, graph mining for networks."

«مجموعة البيانات منظمّة ك [هيكل]. تقنيات التنقيب تتبع هذا الهيكل — مثلاً قواعد ارتباط للمعاملات، تنقيب نصوص للمستندات، تنقيب شبكات للرسوم.»

5. Data Preparation — definition, dirty data, pipeline

5. إعداد البيانات — تعريف وبيانات قدرة وخط سير

Data Preparation is the process of preparing raw data so that it can be used effectively by Data Mining algorithms.

Real-world data is often incomplete, noisy, inconsistent, duplicated, in different formats, containing irrelevant attributes, and different numerical scales.

بيانات الواقع غالباً ناقصة أو مشوشة أو غير متسقة أو مكررة أو بتنسيقات مختلفة أو بخصائص غير ذات صلة أو بمقياس رقمي مختلف.

Raw Data → Data Preparation → Data Mining → Knowledge / Patterns

البيانات الخام ← إعداد ← تنقيب ← معرفة/أنماط

Quality of prepared data strongly affects quality of discovered patterns and model performance.

جودة البيانات المجهزة تؤثر بقوة على جودة الأنماط المكتشفة وأداء النموذج.

Raw → Cleaning → Integration → Transformation → Reduction → Discretization → Prepared → Algorithm → Patterns

خام ← تنظيف ← دمج ← تحويل ← تقليل ← تجزئة ← مجهز ← خوارزمية ← أنماط

Important lecture point

نقطة المحاضرة المهمة

These steps are not necessarily performed in exactly the same order for every dataset. Data Preparation is NOT simply "removing missing values" — it is the complete process of making raw data suitable for discovering useful patterns. Good preparation → better data → more reliable results.

الخطوات ليست إجبارياً بنفس الترتيب لكل بيانات. الإعداد ليس مجرد «حذف القيم المفقودة» — بل العملية الكاملة لجعل الخام صالحاً لاكتشاف أنماط مفيدة. إعداد جيد ← بيانات أفضل ← نتائج أوثق.

6. Data Cleaning — missing (6 methods), noise, outliers, duplicates, inconsistency

6. تنظيف البيانات — مفقود (6 طرق)، ضوضاء، شذوذ، تكرار، عدم اتساق

Data Cleaning is the process of detecting and correcting problems in the data.

Common problems: missing values, noisy data, outliers, duplicate records, inconsistent data.

مشاكل شائعة: قيم مفقودة، ضوضاء، قيم شاذة، سجلات مكررة، عدم اتساق.

الطريقة/المثال	Lecture example	When / note	Missing method
تجاهل السجل إذا القليل فقط	Remove row	Only if very few missing; else lose info	Ignore record 1
خبير يحدّد القيمة	Expert sets value	Domain expert (doctor)	Fill manually 2
متوسط: $75 = 4 \div 300$	sum 300 / count 4 = 75 → 90,?,60,70,80	Numerical data	Mean 3
وسيط عند القيم المتطرفة	extreme → median 200 — 60,65,70,75,200 better	When extreme values exist	Median 4
منوال للفئوي	Male, Female, Male, Male, ? → Male	Categorical / most frequent	Mode 5
تنبؤ بنماذج تعلم آلي	Regression, Decision tree, k-NN	DM/ML model	Predict 6

Mean trap

فخ المتوسط

Divide by observed count (4), not 5, when one value is missing.

اقسم على عدد القيم الموجودة (4) مو 5 إذا وحدة مفقودة.

Noise = random errors or unwanted variation. Lecture example: true ages 21,22,23,24,25 but dataset has 223 — likely entry error. Approaches: binning, regression, clustering, outlier detection.

الضوضاء = أخطاء عشوائية أو تغير غير مرغوب. مثال: أعمار حقيقية 21..25 لكن الداتا فيها 223 — غالباً خطأ إدخال. طرق: binning، انحدار، تجميع، كشف شذوذ.

Binning: divide numerical values into bins. Example 10,12,13,20,22,25,30,31 → Bin1 10–13 · Bin2 20–25 · Bin3 30–31. Helps smooth noisy numerical data.

Binning: تقسيم القيم الرقمية إلى فئات. مثال 10..31 → فئة 10–13 و 20–25 و 30–31. يساعد على تنعيم بيانات مشوشة.

Outlier — critical exam rule

القيمة الشاذة — قاعدة امتحانية

An outlier is a data object whose value differs significantly from others (e.g. 65,67,68,70,69,300). An outlier is NOT necessarily an error — high BP may be a real condition. Investigate before removing. Detection: statistical, distance-based, clustering, visualization, ML.

القيمة الشاذة تختلف بقوة عن البقية (مثال 300). ليست بالضرورة خطأ — ضغط مرتفع قد يكون حالة حقيقية. تحقق قبل الحذف. الكشف: إحصائي، مسافات، تجميع، رؤية، تعلم آلي.

Duplicates: same object appears more than once (ID 101 Ahmed 45 twice). Harm: inflate size, bias analysis, affect frequencies and model performance. Handle appropriately.

التكرار: نفس الكائن مرتين (معرف 101 مكرر). الضرر: تضخم الحجم، تحيز التحليل، أثر على التكرارات والأداء. عالجها بشكل مناسب.

Inconsistency: same category different formats — Male / M / male → standardize to Male; Iraq / IRAQ / iraq → Iraq. عدم الاتساق: نفس الفئة بتنسيقات مختلفة — ذكر/M/male ← توحيد Male؛ العراق بثلاث صيغ ← توحيد Iraq.

7. Integration · Transformation · Reduction · Discretization

7. الدمج · التحويل · التقليل · التجزئة

Data Integration combines data from multiple sources into a single dataset.

University example: DB1 student info + DB2 grades joined on student ID. Problems: different attribute names, formats, duplicates, units (kg vs pounds), schemas.

مثال الجامعة: قاعدة معلومات طلاب + قاعدة درجات تُدمج بمعرف الطالب. مشاكل: أسماء مختلفة، تنسيقات، تكرار، وحدات (كجم/رطل)، مخططات مختلفة.

Data Transformation converts data into a suitable format for Data Mining algorithms.

Techniques: Normalization, Aggregation, Generalization, Encoding, Feature construction. Why normalize? Age 0–100 vs Salary 300–10,000 vs Income up to 100,000 — large ranges dominate some algorithms.

تقنيات: تطبيع، تجميع، تعميم، ترميز، بناء ميزات. ليش نطبع؟ العمر مقابل الراتب مقابل الدخل — المدى الكبير قد يسيطر على خوارزميات.

Encoding: Male=1, Female=0 possible but may imply false order; for Red/Blue/Green use one-hot (each category its own binary column).

الترميز: ذكر=1 أنثى=0 ممكن لكنه قد يوحي بترتيب وهمي؛ للألوان استعمل one-hot (عمود ثنائي لكل فئة).

Data Reduction attempts to reduce size or complexity while preserving important information.

Techniques: dimensionality reduction, feature selection, sampling, aggregation, numerosity reduction.

تقنيات: تقليل أبعاد، اختيار ميزات، معاينة، تجميع، تقليل عددية.

Feature selection example: keep Age, Gender, BMI, Blood Pressure; drop Patient Name, Phone, Address for disease prediction.

مثال اختيار الميزات: احتفظ بالعمر والجنس و BMI وضغط الدم؛ احذف الاسم والهاتف والعنوان للتنبؤ بالمرض.

Feature Selection vs Extraction

الاختيار مقابل الاستخراج

Selection: pick EXISTING features (Age). Extraction: CREATE new features from originals (PCA components; BMI from weight/height). Mnemonic: Pick vs Build.

الاختيار: تأخذ ميزات موجودة (العمر). الاستخراج: تنشئ ميزات جديدة من الأصلية (مكوّنات PCA؛ BMI من الوزن/الطول). الحفظ: اختر مقابل ابن.

Dimensionality reduction example: 100 features → 10 principal components (PCA). Reduces cost, storage, complexity; may help visualization.

مثال تقليل الأبعاد: 100 ميزة ← 10 مكوّنات رئيسية (PCA). يقلل الكلفة والتخزين والتعقيد.

Discretization: continuous → intervals/categories. Age 18,25,32,47,65,72 → 0–17 Child · 18–35 Young Adult · 36–60 Adult · 61+ Senior.

التجزئة: مستمر ← فئات. أعمار معيّنة ← طفل/شاب/بالغ/كبار السن.

Medical dataset walkthrough (lecture)

مشي المثال الطبي (المحاضرة)

Diabetes data with missing Glucose: (1) handle missing (2) check outliers (3) encode Gender (4) normalize Age/Glucose/BMI if needed (5) select useful features (6) apply classifier — Decision Tree, Naïve Bayes, k-NN, Logistic Regression, Random Forest.

بيانات سكري بجلوكوز مفقود: (1) عالج المفقود (2) تحقق من الشذوذ (3) رمّز الجنس (4) طَبّع الرقمية إن لزم (5) اختر ميزات مفيدة (6) طبّق تصنيف — شجرة قرار، نايف بايز، k-NN، انحدار لوجستي، غابة عشوائية.

8. Data Preparation vs Preprocessing + exam sheet

8. الإعداد مقابل المعالجة الأولية + ورقة الامتحان

النطاق	Contents	Scope	Term
عملية أوسع	Cleaning · Integration · Transformation · Reduction · Discretization	Broader process preparing data for mining	Data Preparation
عمليات أضيق قبل النمذجة	missing, noise, encoding, scaling/normalization, feature selection	Often narrower pre-modeling ops	Data Preprocessing

Preprocessing is an important part of the broader preparation process. Terminology can vary between textbooks.

المعالجة الأولية جزء مهم من الإعداد الأوسع. المصطلحات تختلف بين الكتب.

لازم تحفظ	Details	Must memorize
الأنواع ومسار القرار	?order? gap? two values? quantity	Attribute types + decision path
الرابط اسمي	no order, no measurable gap	URL = Nominal
الهياكل والمرساة	Row→Basket→...→Network	structures + anchor 8
فصل الخصائص عن التنظيم	values vs organization	Attribute vs structure separation
5 خطوات + ملاحظة الترتيب	not always same order; not only missing values	Prep pipeline 5 steps
6 طرق + مثال 75	mean example 75; median if outliers	Missing 6 methods
شذوذ ≠ خطأ	investigate first	Outlier ≠ error
تطبيع مثال 0.5	formula first + range [0,1]	Min-Max 40→0.5
اختيار مقابل استخراج	Pick vs Build	Selection vs Extraction
فئات العمر	Age groups example	Discretization bins
بروتوكول د. أحمد	formula → symbols → steps → result+range	Doctor protocol

Coverage check (builder self-audit)

فحص التغطية (تحقق ذاتي)

- W1: Definition + KDD + warehouses + beyond simple analysis + applications intro entities — YES
- W1: 7 advantages + 3 Gemini levels + anchor — YES
- W1: Disadvantages including American Express + tools + training + imprecision + anchor — YES
- W1: 8 applications with 2-keyword + lecture detail + safe sentences — YES
- W1: 6 challenges Nature/Cause/Effect + \$500 story + outlier rule — YES
- W2: Object vs attribute — YES
- W2: Nominal/Ordinal/Binary/Numerical + decision template + URL=Nominal — YES
- W2: Interval/Ratio + Min-Max/Z-score/decimal + worked 0.5 — YES
- W2: 8 structures + separation rule + anchor — YES
- W2: Prep definition + dirty data + pipeline + not-only-missing — YES
- W2: Cleaning 6 missing + noise/binning + outlier≠error + duplicates + inconsistency — YES
- W2: Integration/Transformation/Reduction/Discretization + Selection vs Extraction + medical walkthrough — YES
- W2: Prep vs Preprocess + exam quick tables — YES

التحقق: الأقسام أعلاه موجودة كاملة في الملفين — بلا ضغط ولا حذف جوهري للمادة.